

西安电子科技大学

硕士学位论文

基于非支配个体自适应划分策略的进化多目标优化及应用

姓名：程刚

申请学位级别：硕士

专业：电路与系统

指导教师：杜海峰

20100101

摘 要

进化算法的出现为复杂优化问题的求解提供了新的思路,由于它具有智能性、通用性、稳健性、本质并行性和全局搜索能力,已在各个领域得到了广泛的成功应用。进化多目标优化研究如何利用进化计算方法求解多目标优化问题,经过 20 多年的发展逐渐成为进化计算的主要研究热点之一。1999 年以前的进化多目标优化算法以基于 Pareto 等级的选择和基于适应度共享的多样性保持为主要特点。从二十世纪末期开始,进化多目标优化的研究趋势转向注重算法的效率,以精英保留机制为特征的算法相继被提出。近几年,进化多目标优化前沿领域的研究呈现出新的特点。一方面,粒子群优化、人工免疫系统、分布估计算法等越来越多的进化范例被引入多目标优化领域,一些新颖的受自然系统启发的多目标优化算法相继提出;另一方面,为了更有效的求解高维目标优化问题,一些区别于传统 Pareto 占优的机制也相继涌现。

多目标问题解的分布主要体现在两个方面,即分布的广度和均匀程度。本文在分析了传统多目标进化算法保持解分布方式的基础之上,提出了一种基于自适应划分(Adaptive Partition,简称 ADP)的非支配个体选取策略。新策略根据非支配个体在目标空间的相似性程度对由当前非支配个体构成的前沿面进行自适应划分,在划分出的各区域选择最具代表性的个体,实现对非支配个体的修剪操作。

本文将此策略应用于两类典型的多目标进化算法 NSGA-II 及 PESA-II 中,基于 13 个标准测试问题的仿真结果表明,引入了自适应划分策略的算法较之原算法,最终求得最优解的均匀性和广度都得到了很好的提升。随后,基于生物免疫学中的抗体克隆选择机理,通过引入自适应划分的非支配个体选择策略,我们构造了一种新型的免疫算法,该算法弥补了传统的非支配个体选择方式的多样性不足的缺陷,充分利用了抗体的结构信息,很大程度上提升了估计 Pareto 解的多样性。

最后,我们将自适应划分选择策略用于解决工程实践问题。通过处理多目标组播路由问题,验证了自适应划分选择克隆算法相比于其他算法具有更好解决工程问题的能力。

本文的工作得到了国家自然科学基金(No.60703107),国家 863 高技术研究发展计划(No.2009AA12Z210)的资助。

关键词: 人工免疫系统 多目标优化 自适应划分 多目标路由

Abstract

Evolutionary Algorithm provides a new direction to complex optimization problems. Because of its intelligence, universality, robustness, global search ability and parallelism, it has been widely used in many fields. After 20 years' development, multi-objective evolutionary algorithm (MOEA), whose main task is to deal with multi-objective optimization problems (MOP) by evolutionary computation, has become one of the hot issues in evolutionary computation community gradually. Evolutionary multi-objective optimization algorithms proposed before 1999, are based on selection scheme by Pareto ranks and diversity maintain by fitness sharing respectively. Towards the ends of the 1990s, emphasis on algorithmic efficiency which is the main characteristic of EMO and several algorithms based on elitism has been proposed later. More recently, current research in EMO reveals new traits. On one hand, more new evolutionary paradigms have been introduced in EMO community, such as particle swarm optimization, artificial immune system, estimation distribution algorithm, and several novel multi-objective optimization algorithms inspired by natural system have been proposed. On the other hand, in order to deal with multi-objective optimization problems, several new dominance schemes different from traditional Pareto dominance come forth.

The distribution of MOP's solution mainly manifests in two aspects: breadth and uniformity. This article has analyzed two traditional ways which were used to maintenance the diversity of individual in MOEAs, then give a novel selection strategy based on adaptive partition of nondominated individuals for Multi-objective optimization. By the different level of the individual's similarity in object space, the Pareto front which consists of nondominated individuals is partitioned adaptively with this strategy. Then some typical individuals are selected to prune the nondominated individuals.

When applied in two typical MOEAs: NSGA-II and PESA-II, the simulation results based on thirteen benchmark problems show that the new strategy performs better upon two others in terms of population diversity and convergence in solving most of the test problems. Then, based on the antibody clonal selection theory of immunology, by introducing adaptive partition of nondominated individuals, we propose a novel

immune algorithm to deal with complex multi-objective optimization problems. The new algorithm can make the most of the structure information of antibodies, perform better in terms of population diversity and convergence, and also accelerate the convergence and obtain the global optimization quickly.

Finally, a practical case, QoS multicast routing, is adopted to validate the efficiency of ADP Clonal Selection Strategy. And the results demonstrate that the new algorithm can solve the problem successfully.

This work was supported by the National Natural Science Foundation of China (Grant No. 60703107), the National High Technology Research and Development Program (863 Program) of China (Grant No. 2009AA12Z210).

Keyword: artificial immune system multi-objective optimization adaptive partition multicast routing

创新性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得西安电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：程刚

日期 2010.1.19

关于论文使用授权的说明

本人完全了解西安电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属西安电子科技大学。本人保证毕业后离校后，发表的论文与本论文工作成果有关时署名单位仍然为西安电子科技大学。学校有权保留送交论文的复印件，允许查阅和借阅论文；学校可以公布论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存论文。（保密的论文在解密后遵守此规定）。

本人授权西安电子科技大学图书馆保存学位论文，并同意将论文在互联网上发布。

本人签名：程刚

日期 2010.1.19

导师签名：程刚

日期 2010.12.20

第一章 绪论

1.1 人工智能与进化计算

19 世纪以来, 数理科学、心理学以及生物科学的发展为人工智能的发展提供了理论基础和生物基础^[1], 尤其是控制论和信息论的产生为人工智能的发展做出了具有开创性的工作。然而人工智能的发展并不是一帆风顺的, 许多研究人员深感现在的人工智能距离真正意义上的智能还有很长的一段距离^[2]。因此, 智能算法成为计算机科学的一个主要研究目标^[3]。

生物是自然智能的载体, 自然而然成为人工智能研究灵感的重要来源, 从信息处理的角度来看, 生物个体本身就是一台优秀的信息处理机, 而相继出现的人工神经网络及以后的进化计算都是模拟生物个体的某些特征而发展起来的智能算法, 这些算法具有高度的并行性, 并且具有自组织、自适应、自学习等特征越来越得到大家的普遍关注^[4,5]。借鉴生物学理论解决实际问题是一种非常有效的方法, 发展至今已经形成了一个专门的分支—仿生学。

进化计算技术是一种更为宏观意义下的仿生优化算法, 它通过模仿达尔文提出的“优胜劣汰、适者生存”的进化原理与孟德尔等人的遗传变异理论, 在优化过程中模拟自然界的生物进化过程与机制用于求解现实中的问题。它的核心思想源于这样的基本知识: 生物进化过程本身是一个由简单到复杂, 由低级到高级的演变过程, 是一种自然、并行并且稳健的优化过程, 它的结果在于使生命体达到适应环境的最佳结构与效果。

进化计算正是基于上述思想而发展起来的一种新的领域, 它采用简单的编码技术, 对一组编码实施进化操作, 包括遗传、变异等, 从而实现优胜劣汰的自然选择, 以此达到指导学习和确定搜索方向的目的。由于它采用基于种群的方式进行搜索, 因此具有自学习、自组织和自适应的智能特征, 而且跳出了传统方法中受搜索空间约束的限制, 能很好的切合自然的选择方式, 再加上它本身不需要其他的辅助信息, 因此越来越得到研究者的普遍关注^[6,7,11]。目前基于生物免疫系统的机理而开发的人工免疫系统将在下节中重点论述。

1.2 人工免疫系统

遗传算法是一种采用“生成+检测”的多点全局并行搜索方式^[8]。该算法虽然在全局搜索方面具有较强的能力, 但在局部空间的搜索效果却不明显。免疫遗传算法是借鉴生物免疫系统的基本原理, 利用它具有的学习、记忆、识别、功能来

改造 GA 的不足。近年来,先后有 Toyoo Fukuda 等提出的基于信息熵的免疫算法^[9], chun 等人将其应用于解决电磁器件的形态优化问题^[10], 王磊、焦李成等人提出的基于疫苗的免疫计算(包括免疫规划、免疫算法、免疫策略等)^[11,12,13]等。

1.2.1 免疫算法的基本框架

免疫系统通过从许多抗体中选择最匹配抗原的一种类型来消灭或排除抗原,因此,如果我们将要求解的问题当作抗原,把问题的解作为抗体,则免疫系统可以看作一个优化过程。根据这个原理, Fukuda 提出了一种免疫算法,见图 1.1。

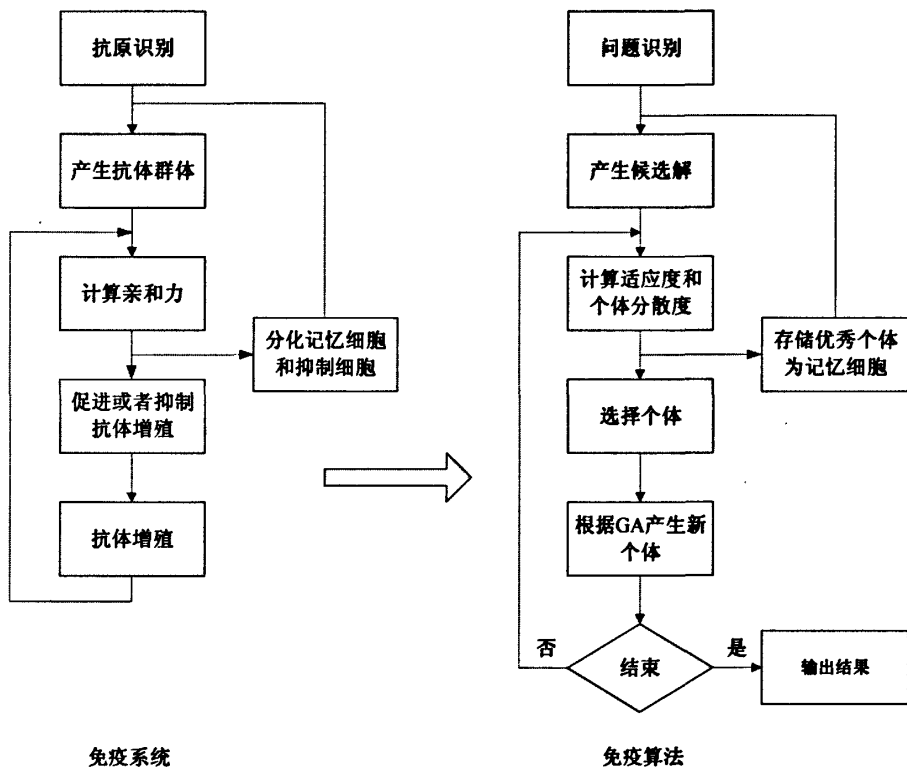


图1.1 免疫系统与免疫算法


1.2.2 免疫算法的流程

- ① 抗原识别。输入待求解问题作为免疫算法的抗原,针对待求解问题,判断是否曾求解过此类问题。
- ② 产生初始群体。若系统曾求解过此类问题,则从记忆库中搜寻该类问题的记忆抗体,作为求解该问题的初始解,否则在解空间中用随机的方法产生初始群体。

- ③ 计算亲和性。根据抗体在群体中与其相似的个体所占的比重及抗体和抗原的结合程度分别计算抗体与抗体与抗体与抗原之间的亲和性。
- ④ 记忆单元更新。将与抗原亲和性高的抗体加入到记忆库中，由于记忆库容量有限，所以在记忆库中用新加入的抗体取代与其亲和性最高的原有抗体。
- ⑤ 促进和抑制抗体的产生。与抗原亲和性高的抗体和低浓度的抗体的生存几率较大。高亲和性的抗体得到促进，而浓度高的抗体受到抑制。
- ⑥ 产生抗体。通过遗传算法的杂交和变异算子，产生进入下一代的抗体。
- ⑦ 终止条件。终止条件（如最大迭代次数等）满足后，优化过程结束。

1.2.3 免疫算法的收敛性分析

免疫算法的状态转移可用如下随机过程来表示：



其中 k 表示迭代的次数，由于抑制细胞仅仅用来调节抗体浓度，保证生产抗体的多样性，而记忆细胞是用来加速抗体局部收敛，所以随机过程 $\{A_k | k=1, 2, \dots\}$ 仍是一个马尔可夫链。我们将规模为 N 的群体认为是状态空间 $S = X^N$ 中的一个点，其每个分量就是群体中的一个个体。用 $S_i \in S$ 表示 S_i 是 S 中的第 i 个状态， A'_k 表示随机变量 A_k 处于状态 S_i ，或者说在第 k 代时群体 A_k 处于状态 S_i 。设 f 是 X 上的适应度函数，令

$$X^* = \left\{ x \in X \mid f(x) = \max_{x_i \in X} f(x_i) \right\} \quad \text{式 (1-1)}$$

则定义算法的收敛性如下。

定义 1.1 如果对于任意的初始分布均有：

$$\lim_{k \rightarrow \infty} \sum_{S_i \in X^*} P\{A'_k\} = 1 \quad \text{式 (1-2)}$$

则称免疫算法收敛。

该定义表明：算法收敛是指当算法迭代到足够多的次数之后，群体中包含全局最佳个体的概率接近于 1。这种定义即为通常所说的概率 1 收敛。

定理 1.1 如果在代的演化过程中，遗传算法保留最好的解，并且算法以杂交和变异作为随机化算子，则对于一个全局优化问题，随着演化代数趋向于无穷，遗传算法将以概率 1 找到全局最优解。

由于记忆细胞机制为下次遇到同类问题的群体初始化提供参考^[8]，只会影响到算法收敛的快慢，而抑制细胞机制为免疫系统的自适应、自恢复机制、维持抗体

浓度在消灭抗原过后恢复为初始状态。因此，只要我们的选择算子以概率 1 保留最好的解，则免疫算法的收敛性将等同于遗传算法。

命题 1.1 如果在代的演化过程中算法保留最好的解，则免疫遗传算法是以概率 1 收敛的。

1.3 免疫算法及研究现状

1.3.1 人工免疫系统的发展

随着近年来国际上在生命自然科学领域的长足发展，人们对于 AIS 中信息处理机制的模型和相应算法的研究也逐渐活跃起来。1996 年 12 月，在日本首次举行了基于免疫性系统的国际专题探讨会，并首次提出了“人工免疫系统”的概念；1997 年，IEEE 的“System, Man and Cybernetics (SMC)”组织专门成立了“人工免疫系统及应用”的分会组织，并于当年年底在美国的 Orlando 召开的年会上开始收录有关 AIS 方面的论文。国际学术界的上述活动大大提高了 AIS 研究与应用的影响程度，同时掀起了对智能信息处理系统的研究中继模糊系统、人工神经网络、演化计算等领域之后的又一个研究热点，其成果也开始涉及到自动控制^[14,15,16,17]、故障诊断^[18,19]、模式识别^[20]、图像识别^[21,22]、优化设计^[23,24,25,26,27]、机器学习^[28,29,30,31,32]、联想记忆^[33,34]和网络安全^[35,36,37,38]等诸多领域。

基于生物免疫系统的机理而开发的计算模型主要集中在人工免疫网络模型和免疫学习算法两个方面^[39]，之前我们已经介绍了相关人工免疫网络模型的框架，下面将给出目前已有的典型免疫学习算法。

1.3.2 免疫学习算法

A. 负向选择算法

基于免疫系统的自己—非己识别原理，Forrest 等人提出了一种用于检测数据变化状况的负向选择算法^[38]。该算法主要通过系统对异常变化的成功检测而使免疫系统发挥作用的。考虑到 T 细胞的表面可以检测到异（抗原）的状态，所以参考 T 细胞的性能来制做了一个识别接收器，其算法概括如下：

- ① 定义一组长度为 l 的有限字符串 S 以表示“自己”；
- ② 生成检测器集 R 。其中， R 的每个检测器与 S 中的串都不匹配；
- ③ 通过不断地将 R 中的检测器与 S 比较来监控 S 的变化状况。

以上算法主要依赖于以下三个重要原理：

检测算法的每个拷贝是唯一的；

检测行为是概率发生的；

检测行为是在检查任何异常活动，而不是寻找特定的已知改变模式的鲁棒系统。

B. 免疫学习算法

受生物免疫系统的启发，Hunt和Cooke提出了一种新的人工免疫系统及其学习算法^[34]。该系统模型主要由骨髓、*B*细胞网络、抗原和抗体等成份组成。AIS的许多处理包含在*B*细胞和它们的抗体里；*B*细胞网络是由一组相互联接的*B*细胞实现的。骨髓节点用于模拟实现骨髓的功能并且选定免疫网络中的位置以插入一个给定的抗原。如果有*B*细胞死亡，则骨髓节点会激发一些新的细胞添加到免疫网络中去。Hunt等人提出的人工免疫系统的主要算法如下所示。

Begin

调入抗原个体代；

随机初始化初始*B*细胞个体代；

do

从抗原个体代中随机选择一个抗原；

在*B*细胞网络中随机选择一点来插入抗原；

选择*B*细胞地点/插入点的百分比；

对于选择的每个*B*细胞显现抗原且要求免疫反应；

若没有*B*细胞能结合抗原则产生一个新的能结合抗原的*B*细胞；

按刺激程度对*B*细胞进行排序；

删除细胞个体代中最坏的5%；

产生 n 个新的*B*细胞（ $n = B$ 细胞个体代的5%）；

选择 m 个*B*细胞添加到免疫网络中（ $m = B$ 细胞个体代的5%）。

End。

上述算法中，骨髓节点将抗原提供给*B*细胞，用于初始化免疫响应。在算法主循环的每次迭代以后，免疫系统节点也随机地产生新的*B*细胞，并插入到免疫网络中。*B*细胞是AIS中最复杂的概念，每个*B*细胞具有一个模式匹配元件，它是模拟自然免疫系统中抗体形成的遗传机理来产生的；另一方面，*B*细胞允许复杂记忆和促使模式匹配文件的多样化。遗传机理采用一个基因库，并对应于DNA转换成蛋白质的过程，进而最终形成抗体。*B*细胞同时记录自己的刺激程度并保持与网络中与之相连的其它*B*细胞的联系。在一个新的*B*细胞进行创建时，它以产生一个抗体的方式试来探映象基因的选择、折叠、传输和翻译等步骤（这些步骤都发生于自然免疫系统中的*B*细胞里）。

C. 免疫遗传算法

遗传算法是一种采用“生成+检测”的多点全局并行搜索方式。该算法虽然在全局搜索方面具有较强的能力，但在局部空间的搜索效果却不明显。免疫遗传算法是借鉴生物免疫系统的基本原理，利用它具有的学习、记忆、识别、功能来改

造GA的不足。近年来,先后有Toyoo Fukuda等提出的基于信息熵的免疫算法^[9], chun等人将其应用于解决电磁器件的形态优化问题^[10]。王磊、焦李成等人提出的基于抗体的免疫计算(包括免疫规划、免疫算法、免疫策略等)^[11,12,13]等。

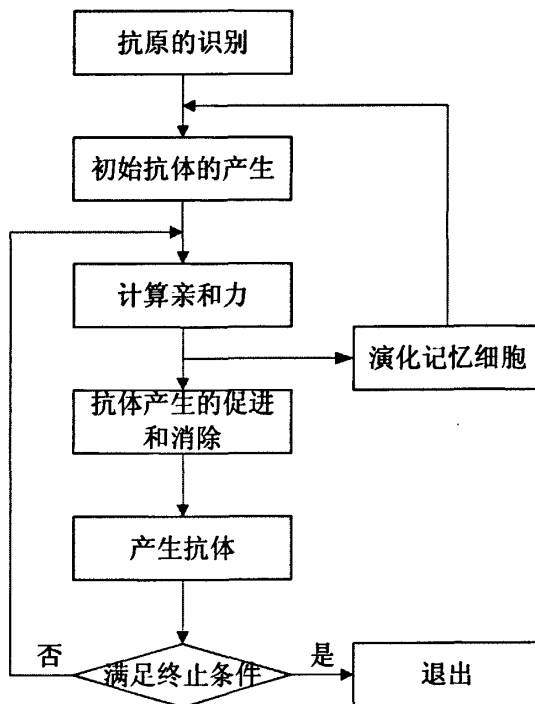


图1.2 免疫遗传算法框图

D. 免疫Agent算法

Ishida等人基于免疫系统的局部记忆学说和免疫网络学说提出了一个基于Agent结构的人工免疫系统(其中的B细胞可以看作是Agent)^[40],从而借助Agent的技术来设计AIS及其免疫Agent算法。该算法分三个步骤步进行:

- ① 多样性的产生;
- ② 自忍耐机制的建立;
- ③ 记忆非己物质。

免疫Agent算法可用于计算机病毒Agent的进化和网络防御系统,也可用于噪声的自适应控制。

免疫系统是以一种完全以分布式的方式来实现复杂计算,具有进化学习、联想记忆和模式识别等能力。免疫系统的机理非常复杂,有些机理甚至连免疫学家还没有很好地理解,这也使得现有的人工免疫系统模型局限于免疫系统的某一种机理,且其稳定性和收敛性等理论分析也还非常欠缺。所以,我们应进一步从工程应用的角度理解免疫系统中各组成部分的功能和内在机理,在一个整体的框架下对免疫系统的所有潜在的有用特性进行集成研究,以开发鲁棒强、并行性好的

自适应免疫计算机系统。

1.4 论文的章节安排

本文在分析了已有多目标进化算法保持解的多样性策略的基础上,提出了一种基于自适应划分的非支配个体选取策略。新策略根据非支配个体在目标空间的相似性程度对由当前非支配个体构成的前沿面进行自适应划分,在划分出的各区域选择最具代表性的个体,实现对非支配个体的修剪操作。按照论述的内容,本文共分为六章,各章主要内容安排如下:

第一章 绪论。主要介绍论文的选题背景和来源,以及论文的内容组织。

第二章 多目标优化问题及进化算法。概要介绍了多目标问题的定义及 Pareto 占优机制,通过回顾一些典型的解决多目标优化问题的算法,给出了常用的一些选点策略。

第三章 基于自适应划分的非支配个体选择策略。在分析和总结了传统选点方式特点的基础之上,指出它们存在的缺陷,同时给出了自适应划分选点方式的具体步骤,通过将此策略应用于两类典型的多目标进化算法中,基于 13 个标准测试问题的仿真结果表明,自适应划分策略使最优解的均匀性和广度得到了很好的提升。

第四章 基于自适应划分的多目标优化非支配近邻免疫算法。将自适应划分选点方式引入非支配近邻免疫算法 (NNIA),替代原法中的拥挤距离选点方式。此项操作使新算法选择更具代表性的个体进入下代进化,使算法具有较强的搜索能力。基于 13 个标准测试问题的仿真结果表明,NNIA+ADP 在多数问题上比 NNIA 算法获得的种群具有更好的多样性和收敛性。

第五章 基于免疫克隆的多目标组播路由优化方法。将 NNIA+ADP 应用于多目标组播路由优化问题,该方法可用于解决基于度约束和负载均衡的 QoS (Quality of Service) 组播路由问题,即通过优化路由算法,更加合理的配置网络资源。

第六章 总结与展望。概述了本文的工作,给出了多目标优化问题目前所面临的问题和挑战,并展望了下一步的研究工作。

1.5 参考文献

- [1] 史忠植. 高级人工智能. 北京: 科学出版社, 1998.
- [2] Flasiński Mariusz. Every Man in his notions or Alchemists' discussion on artificial intelligence. *Foundations of Science*. 1997,2(1):107-121.
- [3] 孟红云. 多目标进化算法及其研究. 西安电子科技大学博士论文, 2005.

- [4] 杨行峻, 郑君里. 人工神经网络. 北京: 高等教育出版社, 1992.
- [5] 潘正君, 康立山, 陈毓屏. 演化计算. 北京: 清华大学出版社, 1998.
- [6] 王正志, 薄涛. 进化计算. 长沙: 国防科技大学出版社, 2000.
- [7] 周明, 孙树栋. 遗传算法原理及应用. 长沙: 国防科技大学出版社, 1999.
- [8] 付朋辉. 基于免疫原理的遗传算法及其在优化问题中的应用. 武汉大学硕士学位论文, 2003.
- [9] Dasgupta D. Artificial Immune Systems and Their Applications Berlin Heidelberg: Springer-Verlang, 1999.
- [10] J. S. Chun, H. K. Jung. S. K. Hong Shape Optimization of Electromagnetic Devices Using Immune Algorithm Trans, Magn.1997, 33(2):1876-1879.
- [11] 王磊. 免疫进化计算理论及应用. 西安电子科技大学博士学位论文.2001.
- [12] 王磊, 潘进, 焦李成. 免疫算法. 电子学报. 2000, 28(7):74-78.
- [13] 王磊, 潘进, 焦李成. 免疫规划. 计算机学报. 2000, 23(8):806-812.
- [14] KrishnaKuma K, Neidhoefer J. Immunized adaptive critics for level 2 intelligent control. 1997 IEEE International Conference on Computational Cybernetics and Simulation. Institute of Electrical and Electronics Engineers, Incorporated, 1997:856-861.
- [15] Sasaki M, Kawafuku M, Takahashi K. An immune feedback mechanism based adaptive learning of neural network controller. ICONIP'99.6th International Conference on Neural Information Processing. IEEE Computer Society Press, 1999:502-507.
- [16] 丁永生, 唐明浩. 一种智能调节的免疫反馈控制系统. 自动化仪表, 2001, 22(10):5-7.
- [17] 李海峰, 王海风等. 免疫系统建模及其在电力系统电压调节中的应用. 电力系统自动化, 2001(12):17-23.
- [18] 刘树林, 张嘉钟, 王日新等. 基于免疫系统的旋转机械在线故障诊断. 大庆石油学院学报, 2001, 25(4):96-100.
- [19] 杜海峰, 王孙安. 基于 ART-人工免疫网络的多级压缩机故障诊断. 机械工程学报, 2002, 38(4):88-90.
- [20] Hunt J. E, Cooke D. E. Learning Using an Artificial Immune System. Journal of Network and Computer Applications, 1996, Vol.19, 189-212.
- [21] McCoy D F, Devarajan V. Artificial immune systems and aerial image segmentation. 1997 IEEE International Conference on Systems, Man, and Cybernetics. Institute of Electrical and Electrical and Electronics Engineers, Incorporated, 1997:867-872.

- [22] 王肇捷, 黄文剑. 立体匹配的免疫算法. 电脑与信息技术, 2001(4):4-6.
- [23] 曹先彬, 刘克胜, 王煦法. 基于免疫遗传算法的装箱问题求解. 小型微型计算机系统, 2000, 21(4):361-363.
- [24] 王煦法, 张显俊, 曹先彬等. 一种基于免疫原理的遗传算法. 小型微型计算机系统, 1999, 20(2):117-120.
- [25] 刘克胜, 曹先彬, 郑浩然等. 基于免疫算法的 TSP 问题求解. 计算机工程, 2000, 26(1):1-2.
- [26] Gong Maoguo, Jiao Licheng, et al. An artificial immune system for CDMA multiuser detection over multi-path channels. In proceedings of the genetic and evolutionary computation conference, 2005:2105-2111.
- [27] 曹先彬, 郑振, 刘克胜等. 免疫进化策略及其在二次布局求解中的应用. 计算机工程, 2000, 26(3):1-2.
- [28] Dasgupta D. An artificial immune system as a multi-agent decision support system. 1998 IEEE International Conference on Systems, Man, and Cybernetics. Institute of Electrical and Electronics Engineers, Incorporated, 1998:3816-3820.
- [29] H. Meshref, H. VanLandingham. Artificial immune systems: application to autonomous agents. 2000 IEEE International Conference on Systems, Man, and Cybernetics. Institute of Electrical and Electronics Engineers, Incorporated, 2000:61-66.
- [30] Jun J H, Lee D W, Sim K B. Realization of cooperative strategies and swarm behavior in distributed autonomous robotic systems using artificial immune system. IEEE SMC'99 Conference Proceedings. Institute of Electrical and Electronics Engineers, Incorporated, 1999:614-619.
- [31] King R L, Russ S H, Lambert A B, et al. Artificial immune system model for intelligent agents. MSU/NSF Engineering Research Cent for Computational Field Simulation Source: Future Generation Computer Systems. Elsevier Science Publishers, 2001:335-343.
- [32] 刘克胜, 张军, 曹先彬等. 一种基于免疫原理的自律机器人行为控制算法. 计算机工程与应用, 2000(5):30-32.
- [33] Abbattista F, Gioia G D, Santo G D. Associative Memory Based on the Immune Networks. Proceeding 1996 IEEE International Conference on Neural networks, Washing DC, USA, 1996, 519-523.
- [34] Gilbert C. J, Routen T. W. Associative Memory in an Immune-based System. Proceeding the 12th National Conference on Artificial Intelligence, Seattle,

- 1994,852-857.
- [35] D'haeseleer P, Forrest S, Herman P. An Immunological Approach to Change Detection: Algorithms, Analysis and Applications. Proceeding IEEE Symposium on Research in Security and Privacy, Oakland, CA, USA, 1996,110-119.
- [36] Kephart J. O. Biological Inspired Defenses against Computer Viruses. Proceeding 14th International Joint Conference Artificial Intelligence, San Mateo, CA, USA,986-996.
- [37] Kephart J. O, Sorkin G. B, Swimmer M. Immune System for Cyberspace. Proceeding 1997 IEEE International Conference on System, Man and Cybernetics, Orlando, FL, USA, 1997,879-884.
- [38] Forrest S, Perelson A. S, Allen L, Cherukuri R. Self-nonself Discrimination in a Computer. Proceeding IEEE Symposium on Research in Security and Privacy, Oakland, CA, USA, 1994,202-212.
- [39] 张立宁. 基于抗独特型和班德文效应的免疫优化计算及应用. 西安电子科技大学硕士论文, 2008.
- [40] Ishida Y, Adachi N. Active Noise Control by an Immune Algorithm: AdaptationImmune System as an Evolution. Proceeding 1996 IEEE International Conference on Evolutionary Computation, Nagoya, 1996,150-153.

第二章 多目标优化问题及进化算法

进化多目标优化研究如何利用进化计算方法求解多目标优化问题,经过20多年的发展逐渐成为进化计算的主要研究热点之一。1999年以前的进化多目标优化算法以基于Pareto等级的选择和基于适应度共享的多样性保持为主要特点。从二十世纪末期开始,进化多目标优化的研究趋势转向注重算法的效率,以精英保留机制为特征的算法相继被提出来。近几年,进化多目标优化前沿领域的研究呈现出新的特点。一方面,粒子群优化、人工免疫系统、分布估计算法等越来越多的进化范例被引入多目标优化领域,一些新颖的受自然系统启发的多目标优化算法相继提出;另一方面,为了更有效的求解高维目标优化问题,一些区别于传统Pareto占优的占优机制也相继涌现^[1]。

2.1 多目标优化问题

2.1.1 多目标优化问题的发展简史

最优化问题是工程实践和科学研究中主要的问题形式之一,其中,仅有一个目标函数的最优化问题称为单目标优化问题,目标函数超过一个并且需要同时处理的最优化问题称为多目标优化问题(multi-objective optimization problems, MOPs)。对于多目标优化问题,一个解对于某个目标来说可能是较好的,而对于其他目标来讲可能是较差的,因此,存在一个折衷解的集合,称为 Pareto 最优解集(Pareto-optimal set)或非支配解集(nondominated set)^[2]。起初,多目标优化问题往往通过加权等方式转化为单目标问题,然后用数学规划的方法来求解,每次只能得到一种权值情况下的最优解。同时,由于多目标优化问题的目标函数和约束函数可能是非线性、不可微或不连续的,传统的数学规划方法往往效率较低,且它们对于权重值或目标给定的次序较敏感。

进化算法(Evolutionary Algorithm, EA)通过在代与代之间维持由潜在解组成的种群来实现全局搜索,这种从种群到种群的方法对于搜索多目标优化问题的 Pareto 最优解集是很有用的。早在 1985 年, Schaffer 就提出了矢量评价遗传算法(vector evaluated genetic algorithms, VEGA)^[3],被看作是进化算法求解多目标优化问题的开创性工作。20 世纪 90 年代以后,各国学者相继提出了不同的进化多目标优化算法。1993 年, Fonseca 和 Fleming 提出了 Multiobjective Genetic Algorithm(MOGA)^[4], Srinivas 和 Deb 提出了 Non-Dominated Sorting Genetic Algorithm(NSGA)^[5], Horn

和 Nafpliotis 提出了 Niched Pareto Genetic Algorithm (NPGA)^[6], 这些算法习惯上被称为第一代进化多目标优化算法 (Multi-objective Evolutionary Algorithms, MOEAs)。第一代进化多目标优化算法的特点是采用基于 Pareto 等级的个体选择方法和基于适应度共享机制的种群多样性保持策略。从 1999 年到 2002 年, 以精英保留机制为特征的第二代进化多目标优化算法相继被提出来: 1999 年, Zitzler 和 Thiele 提出了 Strength Pareto Evolutionary Algorithm (SPEA)^[7], 3 年之后, 他们提出了 SPEA 的改进版本 SPEA2^[8]; 2000 年, Knowles 和 Corne 提出了 Pareto Archived Evolution Strategy (PAES)^[9], 很快, 他们也提出了改进的版本 Pareto Envelope-Based Selection Algorithm (PESA)^[10] 和 PESA-II^[11]; 2001 年, Erichson, Mayer 和 Horn 提出了 NPGA 的改进版本 NPGA2^[12]; Coello Coello 和 Pulido 提出了 Micro-Genetic Algorithm (Micro-GA)^[13]; 2002 年, Deb 等学者通过对 NSGA 进行改进, 提出了非常经典的算法: NSGA-II^[14]。随后, 一些新的进化机制^[15]也被引入进化多目标优化领域, 如 Coello Coello 等人基于粒子群优化提出的 Multi-objective Particle Swarm Optimization (MOPSO)^[16], Gong 和 Jiao 等人基于免疫算法提出的 Nondominated Neighbor Immune Algorithm (NNIA)^[2], Zhang 和 Zhou 等人基于分布估计算法提出的 Regularity Model Based Multi-Objective Estimation of Distribution Algorithm (RM-MEDA)^[17], Zhang 和 Li 将传统的数学规划方法与进化算法结合起来提出的 Multi-Objective Evolutionary Algorithm Based on Decomposition (MOEA/D)^[18], Bandyopadhyay 等人基于模拟退火算法提出的 Archived Multiobjective Simulated Annealing Algorithm (AMOSA)^[19]。

在对多目标进化算法的研究中, 如何提升算法的收敛性^[20]与算法求得 Pareto 最优解的多样性是算法设计的两个核心内容^[21]。解的多样性主要体现在两个方面, 即解分布的广度和解分布的均匀程度。在 MOEAs 的设计中, 解的多样性保持策略一般放在种群维护 (population maintenance) 中实现, 当非支配个数超过一定规模时, 就需要利用修剪操作 (truncation operator) 来去除个体。去除个体不是随机的, 而是根据一定的多样性保持策略来进行。以往的一些 MOEAs, 如 NSGA-II、PESA-II 及 SPEA2, 本质上都遵循了进化算法框架, 它们之间的主要区别之一就在于采取何种方式选择个体。

2.1.2 多目标优化问题的数学描述

多目标优化问题又称为多标准优化问题。不失一般性, 一个具有 n 维决策变量, m 维子目标的多目标优化问题^[22,23]可表述为:

$$\begin{cases} \min & \mathbf{y} = \mathbf{F}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x}))^T \\ \text{s.t.} & g_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, q \\ & h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, p \end{cases} \quad \text{式(2-1)}$$

其中, $x=(x_1, \dots, x_n) \in X \subset R_n$ 为 n 维的决策矢量, X 为 n 维的决策空间, $y=(y_1, \dots, y_m) \in Y \subset R_m$ 为 m 维的目标矢量, Y 为 m 维的目标空间。目标函数 $F(x)$ 定义了 m 个由决策空间向目标空间的映射函数; $g_i(x) \leq 0 (i=1, 2, \dots, q)$ 定义了 q 个不等式约束; $h_j(x) \leq 0 (j=1, 2, \dots, p)$ 定义了 p 个等式约束。在此基础上, 给出以下几个重要的定义。

定义 1(可行解) 对于某个 $x \in X$, 如果 x 满足式(2-1)中的约束条件 $g_i(x) \leq 0 (i=1, 2, \dots, q)$ 和 $h_j(x) \leq 0 (j=1, 2, \dots, p)$, 则称 x 为可行解。

定义 2(可行解集合) 由 X 中的所有的可行解组成的集合称为可行解集合, 记为 X_f , 且 $X_f \subseteq X$ 。

定义 3(Pareto 占优) 假设 $x_A, x_B \in X_f$ 是式(2-1)所示多目标优化问题的两个可行解, 则称与 x_B 相比, x_A 是 Pareto 占优的, 当且仅当

$$\forall i=1, 2, \dots, m, f_i(x_A) \leq f_i(x_B) \wedge \exists j=1, 2, \dots, m, f_j(x_A) < f_j(x_B) \quad \text{式(2-2)}$$

记作 $x_A \succ x_B$, 也称为 x_A 支配 x_B 。

定义 4(Pareto 最优解) 一个解 $x^* \in X_f$ 被称为 Pareto 最优解(或非支配解), 当且仅当满足如下条件:

$$\neg \exists x \in X_f : x \succ x^* \quad \text{式(2-3)}$$

定义 5(Pareto 最优解集) Pareto 最优解集是所有 Pareto 最优解的集合, 定义如下:

$$P^* \triangleq \{x^* \mid \neg \exists x \in X_f : x \succ x^*\} \quad \text{式(2-4)}$$

定义 6(Pareto 前沿面) Pareto 最优解集 P^* 中的所有 Pareto 最优解对应的目标矢量组成的曲面称为 Pareto 前沿面 PF^* :

$$PF^* \triangleq \{F(x^*) = (f_1(x^*), f_2(x^*), \dots, f_m(x^*))^T \mid x^* \in P^*\} \quad \text{式(2-5)}$$

2.2 进化多目标优化的主要算法

1967 年, Rosenberg^[24]就建议采用基于进化的搜索来处理多目标优化问题, 但他没有具体实现。1975 年, John Holland^[25]提出了遗传算法。1984 年, David Schaffer^[3]首次实现了矢量评价遗传算法 (Vector evaluated genetic algorithm, VEGA), 第一次实现了将遗传算法与多目标优化问题的结合。1989 年, David Goldberg^[26]在其著作《Genetic algorithms for search, optimization, and machine learning》中, 提出了用进化算法实现多目标的优化技术, 对于第一代进化多目标优化算法的研究具有重要指导意义。随后, 进化多目标优化算法引起了很多学者的广泛关注, 并且涌现了大量的研究成果。据我们统计, 进化计算的权威期刊《IEEE Transactions on Evolutionary Computation》从 1997 年创刊至 2007 年底发表的文章中, 被 SCI 引用次数最多的前两名文章均是关于 EMO 的研究成果, 分别是 Deb 的 NSGA-II^[14](被

引用 321 次)和 Zitzler 的 SPEA2^[8](被引用 320 次)。可以看出, 进化多目标优化在进化计算领域是一个非常热的研究方向。

2.2.1 MOEA 解决多目标优化问题的一般框架

多目标进化算法的基础是进化算法, 它的处理对象是多目标优化问题。由于 MOEA 种类较多, 所采用的方法和技术有较大的差异, 难以用一般框架来刻画。为了便于理解, 这里给出一类基于 Pareto 的多目标进化算法的一般流程, 如图 2.1 所示。首先产生一个初始种群 P , 然后选择某个进化算法对 P 执行进化操作(如交叉、变异和选择), 得到新的种群 R 。按照定义 3 识别出 $P \cup R$ 中的非支配个体, 组成非支配解集 Q , 一般情况下在设计算法时已设置了非支配解集的上限(如 N), 若当前非支配解集 Q 的大小大于 N 时, 需要按照某种策略对非支配解进行修剪, 一方面使 Q 满足大小要求, 同时也尽量使保留在 Q 的非支配个体具有好的多样性。之后判断是否满足终止条件, 若满足终止条件, 则结束, 否则将 Q 中的个体复制到 P 中并继续下一轮进化。对于多目标优化算法, 很难明确地给出最优停止准则, 国内外的学者大多设定迭代次数或函数评价次数作为算法终止条件。

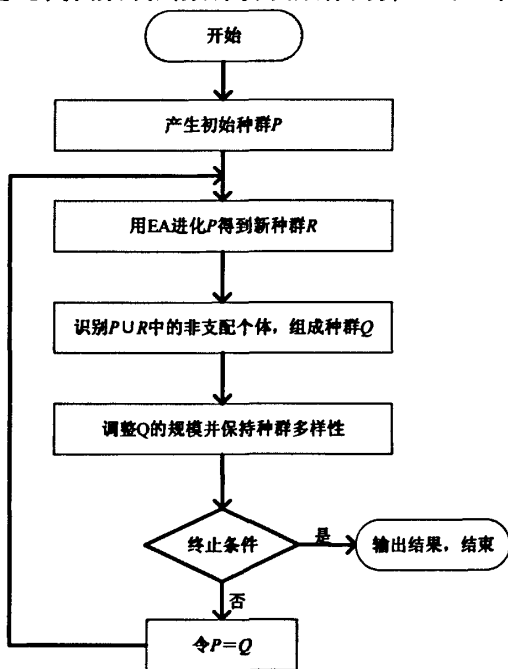


图2.1 一类多目标进化算法的基本框架

在 MOEA 中, 保留上一代的非支配解集, 并使之参与下一代的多目标进化操作是非常重要的, 这类似于进化算法中保留上一代的最优个体, 从而使新一代的非支配解集不比上一代差, 这也是算法收敛的必要条件。这样, 随着一代代的进化, 群体的非支配解集不断地逼近真正的 Pareto 前沿面, 最终得到近似的最优解

集。就一个具体的 MOEA 来说, 如何选择构造非支配解集的方法, 采用什么样的策略来调整非支配解集的大小, 以及如何保持非支配解集的多样性, 是影响一个 MOEA 性能的重要内容。

2.2.2 进化多目标优化的主要算法

- SPEA^[7]是 Zitzler 和 Thiele 在 1999 年提出来的算法, 在该算法中, 个体的适应度又称为强度, 非支配解集中个体的适应度定义为其所支配的个体总数在群体中所占的比重, 其它个体的适应度定义为支配它的个体总数加 1, 约定适应度低的个体对应着较高的复制概率。当外部种群的个体数目超过约定值时, 则用聚类技术来删减个体, 采用锦标赛选择从种群和外部非支配解集中选择个体进入交配池, 进行交叉、变异操作。外部种群中个体所支配的区域定义为它的小生境, 具有较多邻居的个体将拥有较高的适应度, 具有较少邻居的个体将拥有较低的适应度。该算法的特点如下: ①时间复杂度为种群大小的立方; ②除进化种群外, 还设置了一个非支配外部集合, 该集合中个体随种群的进化而不断更新; ③采用支配关系来维持种群多样性和分配个体的适应度; ④采用聚类来维持外部集合中的个体。
- SPEA2^[8]是 Zitzler 和 Thiele 在 2001 年提出的 SPEA 的改进版本。他们在适应度分配策略、个体多样性的评估方法以及非支配解集的更新等方面进行了改进。算法利用环境选择来构造新群体, 选择适应度小于 1 的个体进入外部集, 当这些个体数目小于外部集合的大小时, 选择进化种群中适应度较低的个体; 当这些个体数目大于外部集合的大小时, 则运用近邻规则进行删减。该算法特点如下: ①计算个体适应度的时间复杂度为 $O(m(N + \bar{N})^2 \log(N + \bar{N}))$, 环境选择的时间复杂度为 $O(m(N + \bar{N})^2)$, 其中, m 为目标个数, N 为进化种群大小, \bar{N} 为外部集合的大小。②该算法引入了基于近邻规则的环境选择, 简化了 SPEA 中基于聚类的外部解集更新方法。SPEA2 的时间复杂度仍较高, 但是, 该算法得出的解分布的均匀性是迄今为止所有算法中最好的。
- PESA^[10]设置了一个内部种群和一个外部种群, 进化时将内部种群的非支配个体并入到外部种群中, 当一个新个体进入外部种群时, 同时要在外部种群中淘汰一个个体, 具体的方法是在外部种群中寻找拥挤系数最大的个体并将它删除, 如果同时存在多个个体具有相同的拥挤系数, 则随机地删除一个。每个个体的拥挤系数是指该个体所对应的超格中所聚集个体的数目。Corn 等人在 2001 年对 PESA 做了进一步改进, 称为 PESA-II^[11], 提出了基于区域选择的概念, 与基于个体选择的 PESA 相比, PESA-II 用网格选择代替个体选择, 在一定程度上提高了算法的效率。

- NSGA-II^[14]是迄今为止,最优秀的进化多目标优化算法之一。算法在执行选择操作之前,根据种群间个体的支配与非支配关系进行等级划分。首先找出当前种群中的所有非支配个体,得到第一级非支配个体集合;然后,不考虑第一级非支配个体的情况下,对种群中的剩余个体继续按照支配与非支配关系找出非支配个体,得到第二级非支配个体集合,对剩下的个体继续上述操作,直到种群中的所有个体均归属于某等级。算法按照等级优先进行选择,在同一等级中进行个体选择时,为了保证解群体的多样性,为个体定义了一种拥挤距离,个体的拥挤距离通过计算与其相邻的两个个体在每个子目标上的距离差之和来求取。算法依据个体所属的非支配等级及拥挤距离,对个体进行选择操作。

2.3 多目标进化算法的研究现状及设计目标

从2003年以来,进化多目标优化前沿领域的研究呈现出新的特点。首先,一些新的进化范例被引进多目标优化领域,如粒子群优化、人工免疫系统、分布估计算法,从而许多优秀的算法相继被提出来。其次,如何解决高维目标优化问题(一般指目标个数大于5的多目标优化问题),成为进化多目标领域当前一段时期内面临的难题。为此,有些学者提出了新的占优机制,如Laumanns和Deb^[27]提出了 ϵ -占优,Alfredo和Coello Coello等学者提出了自适应占优^[28],Brockhoff和Zitzler^[29]提出了部分占优。下面,我们讨论几个最近被提出的比较典型的算法,这些算法都是近两年在进化计算领域的顶级期刊《IEEE Transactions on Evolutionary Computation》或《Evolutionary Computation》(MIT press)上发表的成果,代表着当今进化多目标优化的发展潮流和趋势。

2.3.1 多目标进化算法的研究现状

下面,我们罗列出几个最近提出的比较典型的算法^[1],它们代表着当今进化多目标优化的发展潮流和趋势。

➤ 基于粒子群优化的多目标优化

粒子群优化(Particle Swarm Optimization, PSO)是1995年由Kennedy和Eberhart提出来的群智能优化技术。该模型中的每个个体都有一定的感知能力,能够感知自己周围的局部最好位置的个体和整个群体的全局最好位置的个体的存在,并根据当前的状态,调整自己的下一步的行为,从而整个种群表现出一定的智能性。近些年,基于粒子群的进化多目标算法也是一个研究的热点, Li^[30]等把粒子群进化和NSGA-II结合起来,其算法性能优于NSGA-II。Fieldsend和Singh^[31]等采用没有固定大小的外部种群集合,把局部搜索算子定义为外部种群和内部种群的相互作

用,并引入了一个扰动算子保持多样性。Coello Coello^[16]等提出了MO-PSO,该算法引入了自适应网格机制的外部种群,不仅对群体的粒子进行变异,对于粒子的取值范围也进行变异,且变异的程度与种群进化的代数成比例。2005年, Sierra和Coello^[32]等提出了基于拥挤距离和占优机制粒子群多目标算法。

➤ 基于人工免疫系统的多目标优化

人工免疫系统是模仿自然免疫系统功能的一种智能方法,它实现一种受生物免疫系统启发,通过学习外界物质的自然防御机理的学习技术,提供噪声忍耐、无教师学习、自组织、记忆等进化学习机理,结合了分类器、神经网络和机器推理等系统的一些优点,因此具有提供新颖的解决问题方法的潜力。2002年,Coello提出了MISA^[33],随后一些用免疫结合多目标问题的算法涌现出来。Cutello^[34]等提出了I-PAES, Freschi等提出了VAIS^[35], Jiao和Gong^[36]等提出了NNIA和IDCMA。

➤ 基于分布估计算法的多目标优化

分布式估计算法是进化计算领域新兴的一类随机优化算法,它是遗传算法和统计学习的结合,该算法用统计学习的手段构建解空间内个体分布的概率模型,然后运用进化的思想进化该模型。该算法没有传统的交叉、变异操作,是一种全新的进化模式。随着分布式估计算法的发展,以及该算法在解决一些问题时所表现出来的优越性能,一些基于分布式估计思想的多目标优化算法相继被提出来。Khan^[37]等学者提出了mBOA,他将NSGA-II中的选择策略和贝叶斯优化算法(BOA)结合起来,用于解决欺骗的多目标优化问题,取得了比NSGA-II更好的效果。Laumanns^[38]等学者把SPEA2和BOA结合起来,用于解决多目标背包问题。Zhang和Zhou等学者提出了RM-MEDA,该算法是比较经典的结合分布式估计算法和多目标优化问题的算法。

➤ 新型占优机制研究

对传统Pareto占优机制的改进是当前进化多目标优化的研究热点之一。2002年,Laumanns和Deb^[27]等学者提出了占优的概念,对传统Pareto占优机制发起了挑战。占优机制是基于空间超格思想的。每个格子内只允许存在一个解,决策者可以动态调节格子的数目或者大小。这样,由原来的基于个体的占优机制就成为基于格子的占优机制。2007年, Alfredo和Coello Coello^[28]等对占优机制的改进做了进一步改进,提出了Pareto自适应占优机制。Koduru^[39]等提出模糊占优的概念,该方法类似于聚集函数和SPEA的适应度分配的结合,用模糊支配函数为每个占优目标加权,所有的目标加权后求和就是该个体的模糊占优程度。

➤ 高维多目标优化的研究

如何有效求解高维目标优化问题(many-objective optimization problems,一般指目标个数大于5的多目标优化问题),是当今进化多目标优化领域所面临的难题之一。对于维数高的多目标优化问题,要想找到一组有代表性的Pareto最优解是十

分困难的,一些处理低维数目标时不会遇到的问题凸显出来。为了解决高维目标函数问题,一些学者对原来的经典算法在高维多目标情况下的性能进行了实验对比研究。2003年,V.Khare, X.Yao, K.Deb^[15]比较了,当目标维数是2~8时,NSGA-II, SPEA2, PESA等算法的性能。总体来说,这三个算法对于高目标问题,都表现出一定的不足。

2.3.2 设计多目标进化算法的目标

进化算法的出现为求解多目标优化问题带来了新的生机与希望^[40],但是由于多目标优化问题的自身特点决定了求解多目标优化问题的近似解集这一任务的过程也是一个多目标优化问题。通常,在设计多目标进化算法时应注意以下几个方面:

- 希望算法找到的 Pareto 前端与实际的 Pareto 前端的距离应尽可能的接近;
- 希望找到的 Pareto 最优解具有较好的分布;
- 希望所找到的 Pareto 前端的分布范围尽可能的宽广,即尽可能的覆盖每个子目标函数的可能取值范围;
- 算法具有较快的收敛速度。

目前进化算法在求解多目标优化问题方面已涌现出了许多有效的算法,但大量的工作都集中在如何得到尽可能满足上述要求的近似 Pareto 最优集。而上述的三个要求本身即为一个多目标优化问题,为此在设计多目标进化算法时必须要考虑以下两个关键问题:一是为了保证进化群体朝 Pareto 前端的方向搜索,如何定义个体适应度和进行选择以使种群收敛到问题的 Pareto 前端;二是如何保持个体的多样性以避免早熟收敛并获得具有良好分布且范围宽广的 Pareto 前端。而上述两个关键问题的核心在于如何保证在群体进化过程中不丢失 Pareto 最优解,即如何在多目标进化算法中实现最优保留策略。

2.4 总结与讨论

进化算法的出现为多目标优化问题的求解开辟了一条新的途径,进化算法适合于求解多目标优化问题的原因在于:其一,进化算法基于种群的搜索方式实现了搜索的多向性和全局性,使其能够在一次运行中获得多个 Pareto 最优解,用以近似问题的 Pareto 最优解集;其二,进化算法不需要许多数学上的必备条件,可以处理所有类型的目标函数和约束,因此多目标优化问题是进化算法能比其他搜索方法做的更好的一个领域。而当代进化多目标优化又呈现出多样性的特点,新的进化范例被引进多目标优化问题领域,一些性能很好的算法相继被提出来。我们认

为, 只有把多目标优化问题本身的特点和这些进化范例有机的结合起来, 才能设计出更好的算法。同时, 目前对多目标优化问题的认识仍然具有历史局限性, 如何引入新的占优机制和如何高效解决高维目标优化问题, 是当今进化多目标优化领域研究的热点和难点。

2.5 参考文献

- [1] 公茂果, 焦李成, 杨咚咚等. 进化多目标优化算法研究. 软件学报. 2009,20(2):271-289.
- [2] Maoguo Gong, Licheng Jiao, Haifeng Du, Liefeng Bo. Multiobjective Immune Algorithm with Nondominated Neighbor-based Selection. *Evolutionary Computation*, MIT Press, 2008,16(2):225-255.
- [3] Schaffer J D. Multi-objective optimization with vector evaluated genetic algorithms. *Proceedings of the International Conference on Genetic Algorithms and their Applications*, 1985, 93-100.
- [4] Fonseca C M, Fleming P J. Genetic algorithm for multi-objective optimization: formulation, discussion and generation. In Stephanie Forrest (editor), *Proceedings of the Fifth International Conference on Genetic Algorithms*, San Mateo: Morgan Kauffman Publishers, 1993, 416-423.
- [5] Srinivas N, Deb K. Multi-objective optimization using non-dominated sorting in genetic algorithms. *Evolutionary Computation*, 1994, 2(3):221-248.
- [6] Horn J, Nafpliotis N, Goldberg D E. A niche Pareto genetic algorithm for multi-objective optimization. *Proceeding of the First IEEE Conference on Evolutionary Computation*, 1994, 82-87.
- [7] Zitzler E, Thiele L. Multi-objective evolutionary algorithms: a comparative case study and the strength Pareto approach. *IEEE Trans on Evolutionary Computation*, 1999, 3(4):257-271.
- [8] Zitzler E, Laumanns M, Thiele L. SPEA2: improving the strength Pareto evolutionary algorithm. In *Evolutionary Methods for Design, Optimization and Control with Applications to Industrial Problems*, Athens, Greece, 2002, 95-100.
- [9] Knowles J D, Corne D W. Approximating the non-dominated front using the Pareto archived evolution strategy. *Evolutionary Computation*, 2000, 8(2):149-172.
- [10] Corne D W, Knowles J D, Oates M J. The Pareto-envelope based selection algorithm for multi-objective optimization. In *Parallel Problem Solving from Nature-PPSN VI*, Springer Lecture Notes in Computer Science, 2000, 869-878.

- [11] Corne D W, Jerram N R, Knowles J D, Oates M J. PESA-II: region-based selection in evolutionary multi-objective optimization. Proceedings of the Genetic and Evolutionary Computation Conference (GECCO-2001). Morgan Kaufmann Publishers, San Francisco, California, 2001, 283-290.
- [12] Erickson Mark, Alex Mayer, Jeffrey Horn. The niched Pareto genetic algorithm 2 applied to the design of groundwater remediation system. In Eckart Zitzler, Kalyanmoy Deb, Lothar Thiele, Carlos Coello Coello, and David Corne (editor). First International Conference on Evolutionary Multi-Criterion Optimization. Springer-Verlag, 2001, 681-695.
- [13] Coello Coello C A, Pulido G T. Multi-objective optimization using a micro-genetic algorithm. Proceedings of Genetic and Evolutionary Computation Conference, GECCO 2001, Morgan Kaufmann Publishers, San Francisco, California, 2001, 274-282.
- [14] Deb K, Pratap A, Agarwal S, Meyarivan T. A fast and elitist multi-objective genetic algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation, 2002, 6(2):182-197.
- [15] Khare, V., Yao, X., and Deb, K. (2003). Performance scaling of Multi-objective evolutionary algorithms. Proceedings of the Second International Conference on Evolutionary Multi-Criterion Optimization, EMO 2003, volume 2632 of Lecture Notes in Computer Science, 376-390.
- [16] Coello Coello C A, Pulido G T, Lechuga M S. Handling multiple objectives with particle swarm optimization. IEEE Transactions on Evolutionary Computations. June 2004, 8(3):256-279.
- [17] Zhang, Q.F., Zhou, A.M., and Jin, Y. RM-MEDA: A regularity model based multi-objective estimation of distribution algorithm. IEEE Transactions on Evolutionary Computation, 2008, 12(1):41-63.
- [18] Zhang, Q.F., and Li, H. MOEA/D: a multi-objective evolutionary algorithm based on decomposition. IEEE Transactions on Evolutionary Computation, 2007, 11(6):712-731.
- [19] Bandyopadhyay, S., Saha, S., Maulik, U. and Deb, K. A Simulated Annealing Based Multi-objective Optimization Algorithm: AMOSA. IEEE Transaction on Evolutionary Computation, 2008, 12(3):269-283.
- [20] Villalobos-Arias M, Coello C A. Asymptotic convergence of metaheuristics for Multi-objective optimization problems. Soft Computing, 2006, 10(11):1001-1005.
- [21] Bosman P A N, Thierens D. The balance between proximity and diversity in

- Multi-objective evolutionary algorithms. IEEE Trans on Evolutionary Computation, 2003, 7(2):174-188.
- [22] Deb K. Multi-objective optimization using evolutionary algorithms. John Wiley & Sons, Chichester, UK, 2001.
- [23] Coello Coello C A, Van Veldhuizen D A, Lamont G B. Evolutionary algorithms for solving multi-objective problems. Kluwer Academic Publishers, New York, USA, 2002.
- [24] Rosenberg R S. Simulation of genetic populations with biochemical properties. [PhD thesis]. University of Michigan, 1967.
- [25] Holland J H. Adaptation in natural and artificial systems. The University of Michigan Press, Ann Arbor, 1975.
- [26] Goldberg D E. Genetic algorithm for search, optimization, and machine learning. MA: Addison-Wesley, 1989.
- [27] Laumanns M, Thiele L, Deb K, and Zitzler E. Combining convergence and diversity in evolutionary multi-objective optimization. Evolutionary Computation (MIT press), 2002.
- [28] Alfredo G H-D, Luis V S-Q. Coello Coello C A. and Molina J. Pareto-adaptive -dominance. MIT. Evolutionary Computation, 2007, 15(4):493-517.
- [29] Brockhoff D, Zitzler E. Are all objective necessary? On dimensionality reduction in evolutionary multi-objective optimization. T.P. Runarsson et al (Eds.) PPSN IX, LNCS 4193, Springer Verlag, 2006, 533-542.
- [30] Li X. A non-dominated sorting particle swarm optimizer for multi-objective optimization. In Lecture Notes in Computer Science, vol. 2723, Proc. Genetic and Evolutionary Computation –GECCO 2003-Part I, E. Cantu-Paz et al., Eds., Berlin, Germany, July 2003, 37-48.
- [31] Fieldsend J E, Sing S. A multi-objective algorithm based upon particle swarm optimization, an efficient data structure and turbulence, in Proc. 2002 U.K. Workshop on Computational Intelligence, Birmingham, U.K., Sept. 2002, 37-44.
- [32] Sierra M R, Coello C C A. Improving PSO-based multi-objective optimization using crowding, mutation and e-dominance, in Carlos A. Coello Coello and Arturo Hernandez Aguirre and Eckart Zitzler (editors), Evolutionary Multi-Criterion Optimization. Third International Conference, EMO 2005, 505-519, Springer. Lecture Notes in Computer Science Vol. 3410, Guanajuato, Mexico, March 2005.
- [33] Coello Coello C A, Cortes N C. An approach to solve multi-objective optimization problem based on an artificial immune system. Springer-Verlag, 2005, Genetic

- Programming and Evolvable Machines, 6:163-190.
- [34]Cutello V, Narzisi G, and Nicosia G. A class of Pareto archived evolution strategy algorithms using immune inspired operators for ab-initio protein structure prediction. Springer-Verlag. F. Rothlauf et al (eds): EvoWorkshops 2005, LNCS 3449,54-63.
- [35]Freschi F, Repetto M. Multi-objective optimization by a modified artificial immune system algorithm. In Proceedings of the 4th International Conference on artificial immune systems, ICARIS 2005. Springer. Lecture Notes in Computer Science, Vol. 3627,248-261.
- [36]Jiao L C, Gong M G, Shang R H, Du H F, and Lu B. Clonal selection with Immune dominance and anergy based multi-objective optimization. In Proceedings of the Third International Conference on Evolutionary Multi-Criterion Optimization, EMO 2005, Guanajuato, Mexico, March 9-11, 2005. Springer-Verlag, Lecture Notes in Computer Science, Vol. 3410,474-489.
- [37]Khan N. Bayesian optimization algorithm for multi-objective and hierarchically difficult Problems [Master's thesis]. University of Illinois at Urbana-Champaign, 2003.
- [38]Laumanns M, Ocenasek J. Bayesian optimization algorithms for multi-objective Optimization. In Proceedings of 7th International Conference on Parallel Problem Solving from Nature. London UK. Springer-Verlag, 2002, 298-307.
- [39]Korudu P, Das S, Welch S M. Multi-objective hybrid PSO Using ϵ -fuzzy dominance. London, England, United Kingdom, GECCO'07, 2007.
- [40]孟红云.多目标进化算法及其研究.西安电子科技大学博士论文, 2005.

第三章 基于自适应划分的非支配个体选择策略

如前文所述,多目标进化算法中个体的选择策略都是以保持非支配解的多样性为出发点,以此确保求得解的广度和均匀性。在分析和总结现有策略存在缺陷的基础之上,本章提出一种基于自适应划分的非支配个体选取策略,根据非支配个体在目标空间的相似性程度对由当前非支配个体构成的前沿面进行自适应划分,在划分出的各区域选择最具代表性的个体,实现对非支配个体的修剪操作。

3.1 常用非支配个体选择策略及存在的问题

在对多目标进化算法的研究中,如何提升算法的收敛性^[1]与算法求得 Pareto 最优解的多样性是算法设计的两个核心内容^[2]。解的多样性主要体现在两个方面,即解分布的广度和解分布的均匀程度。在 MOEAs 的设计中,解的多样性保持策略一般放在种群维护(population maintenance)中实现,当非支配个数超过一定规模时,就需要利用修剪操作(truncation operator)来去除个体。去除个体不是随机的,而是根据一定的多样性保持策略来进行。以往的一些 MOEAs,如 NSGA-II、PESA-II 及 SPEA2,本质上都遵循了进化算法框架,它们之间的主要区别之一就在于采取何种方式选择个体。

3.1.1 基于拥挤距离选择策略

图3.1中圆点表示非支配个体,方点为支配个体。它是NSGA-II算法所采用的基于拥挤距离的个体选择策略。基于拥挤距离的个体选择策略在一次种群更新中,个体的拥挤距离是不变的,即一次种群更新中个体的聚集距离只需计算一次。若当前种群的非支配个体数超过一定规模时,就需要计算所有非支配个体的拥挤距离,将拥挤距离最小的超出规模的个体数一次性去除,从而达到修剪的目的。图中由于C、D、E的聚集距离均较小,如果一次性去除所有聚集距离小的个体,则会出现个体B与F之间个体缺失,从而影响解的多样性;对于个体B,由于在目标 f_1 上的差值很大,而在目标 f_2 上的差值却很小,使得B的聚集距离也较小,个体F由于在两个目标上的差值均较大,使得F的拥挤距离也较大,此时,会误认为F的多样性较B要好,而去除B,事实上,B的多样性比F要好。由此可以看出,这种策略虽然简单,但过于粗糙,解的多样性保持较差。




图3.1 基于拥挤距离的个体选择策略

3.1.2 基于网格的个体选择策略

图3.2表示的是PESA-II算法所采用的基于网格的个体选择策略，每个个体的拥挤系数是指该个体所对应的超格中聚集个体的数目。当一个新个体进入外部种群时，同时要在外部种群中淘汰一个个体，具体的方法是在外部种群中寻找拥挤系数最大的个体并将它删除，如果同时存在多个个体具有相同的拥挤系数，则随机地删除一个。图中可以看出非支配个体A、B、C的拥挤系数相同，个体X由于拥挤系数较小而被保留，这里我们希望能保留A，而将C点淘汰，当执行选择操作时如果删除掉个体A，将会使得解的多样性变差。同时，基于网格的个体选择策略中，网格的个数是一个预先设定的参数，该参数对算法的性能影响很大，很大程度上影响了算法的自适应性^[3,4]。




图3.2 基于网格的个体选择策略

3.2 基于非支配个体自适应划分的选择策略

3.2.1 基于非支配个体自适应划分的选择策略的主要思想

假设当前非支配解集为 $Q = \{q_1, \dots, q_M\}$ ，其中 M 为当前找到的非支配个体的数目，若 M 大于预先设置的非支配解集的上限 N 时，需要通过一个准则在 M 个非支配个体中选择 N 个个体，并尽量保证保留下来的非支配个体分布的广度和均匀性。与目前 MOEAs 中已有的非支配个体选择策略不同，本文提出的基于非支配个体自适应划分的个体选择策略如下：

首先确定出在目标空间中处于边缘的个体（假设有 N_1 个），然后从剩余的 $M - N_1$ 个个体中选择 $N - N_1$ 个个体。距离 $M - N_1$ 个个体的几何中心最近的个体认为多样性保持最好而优先保留下来，添加其余个体中的任一个体，执行 $M - N_1$ 次 K 均值算法^[5]将 $M - N_1$ 个个体划分为两个子区间 (C_1, C_2) ，并得到它们的中心 (c_1, c_2) ，选择距离它们最近的两个个体，这样假设选出的 $s-1$ 个个体为 (q^1, \dots, q^{s-1}) ，此时的子区间为 (C_1, \dots, C_{s-1}) ，那么第 s 个个体是在 (q^1, \dots, q^{s-1}) 的基础之上通过添加一个个体，执行 $M - N_1$ 次 K 均值算法得到的，如此下去，直到得到 $N - N_1$ 个个体。最后将其与之前选择的 N_1 个个体合并共同参与到下一代的进化中。

3.2.2 基于非支配个体自适应划分的选择策略的算法流程

- ① 初始化操作 $t=1$ ，将非支配解集 Q 中在目标空间处于边缘的个体（假设有 N_1 个）挑选出来，选出距离 $M - N_1$ 个个体在目标空间的几何中心 c_1 最近的个体 q^1 。
- ② 添加 $M - N_1$ 中剩余的任一个体 q^m ，执行 $M - N_1$ 次 K 均值算法，以最小 $E(c_1, c_2, \dots, c_{k-1}, c_k) = \sum_{i=1}^M \sum_{j=1}^k I(x_i \in C_j) \|x_i - c_j\|^2$ 值作为确定 c_k 的准则，得到 (c_1, \dots, c_k) ，其中 X 为真时 $I(X)=1$ ，否则为 0。
- ③ 保留 $M - N_1$ 中距 (c_1, \dots, c_k) 最近的那些个体 (q^1, \dots, q^t) 。
- ④ 若求得 (q^1, \dots, q^{N-N_1}) ，执行步骤⑤；否则， $t=t+1$ ，转到步骤②。
- ⑤ 将 N_1 个边缘个体和求得的 $N - N_1$ 个个体一起作为活性群体参与到下一代进化。

由以上步骤可以看出，基于非支配个体的自适应划分策略在保证进行种群的多样性方面表现出两类重要特点：

- a) 逐个从当前非支配解集中选择个体，这样就避免了一次性去除多个个体而造成某一区域个体缺失的现象，故而可以得到多样性更好的 Pareto 前沿面。
- b) 本策略无需引进新的参数，实现上较为容易。

3.3 引入自适应划分策略 ADP 的 MOEAs

基于上一节提出的自适应划分个体选择策略, 本节分别设计了两种典型多目标进化算法 NSGA-II^[6]及 PESA-II^[7]的改进算法。

3.3.1 引入新策略的 NSGA-II 改进算法

将 NSGA-II 中基于拥挤距离的个体选择策略用上一节提出的自适应划分个体选择策略代替, 得到一种 NSGA-II 的改进算法 ADP+NSGA-II, 具体的算法步骤如下:

- ① 令 $t=0$, 随机产生一个初始种群 P_0 , $Q_0=\Psi(P_0)$, 其中 Ψ 为交叉、变异操作。
- ② 将 P_t 和 Q_t 合并组成 R_t , 对 R_t 执行等级划分, 直至所有个体均归属于某等级, 标记等级划分结果为 $F=(F_1, F_2, \dots)$, 其中 F_i 表示第 i 级非支配个体集合。
- ③ 置 $P_{t+1}=\phi$, 按照等级序号从小到大顺序从 F 中选择个体填充到 P_{t+1} , 直到 $|P_{t+1}|+|F_i|\geq N$, 其中 N 为种群的规模。
- ④ 若 $|P_{t+1}|+|F_i|=N$, 则将 F_i 中的个体添加到 P_{t+1} 中; 否则, 采用自适应划分策略在 F_i 中选择 $N-|P_{t+1}|$ 个个体添加到 P_{t+1} , 转到⑤。
- ⑤ 满足迭代终止条件, 停止; 否则, 转②。

3.3.2 引入新策略的 PESA-II 算法流程

采用自适应划分选择策略替代 PESA-II 中基于网格的选择策略, 得到了 PESA-II 的一种改进算法 ADP+PESA-II, 下面给出改进算法的具体流程:

- ① 产生一个初始的内部群体 IP , 并对它进行评价, 同时初始化外部群体 EP 使之为空。
- ② 将 IP 中的非支配个体添加到 EP 中, 当 EP 超过预先设定的规模时, 采用自适应划分选择策略对个体进行修剪操作。
- ③ 若满足迭代终止条件, 停止; 否则, 清除 IP 中的所有个体, 从 EP 中选取两个个体, 采用二元锦标赛选择、交叉和变异操作产生一个新个体, 直至 IP 达到预先设定的规模, 转②。

3.4 实验分析

如前文所述, 为了解决多目标优化问题, 许多进化多目标算法相继被提出来, 其中, NSGA-II^[6]和 PESA-II^[7]都是当今进化多目标优化领域具有代表性的算法。本文中, 我们将 ADP+NSGA-II 与 NSGA-II, ADP+PESA-II 与 PESA-II, 分别在 13 个基

准多目标优化问题上进行了实验比较。这13个测试函数包括3个著名的两目标问题：SCH^[8]、DEB^[9]和KUR^[10]；5个DTLZ问题^[11]，5个ZDT问题^[12]。它们是当今国际上EMO领域被广泛采用的测试函数。实验在Intel Core 2，2G内存配置的PC机上完成。

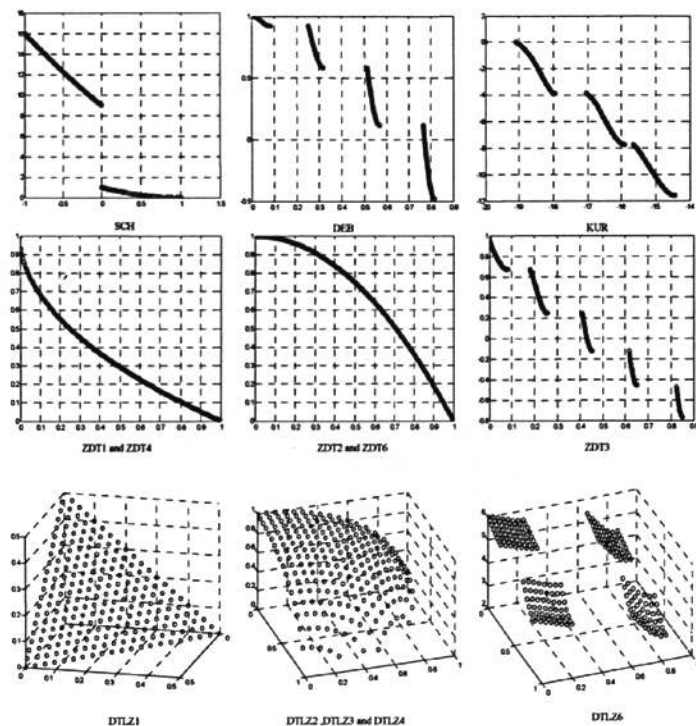


图3.3 测试函数Pareto前沿面上均匀分布的200个采样点

3.4.1 实验测试函数

首先描述实验中用到的13个问题。前3个两目标测试函数SCH，DEB和KUR分别由Schaffer^[8]，Deb^[12]和Kursawe^[13]提出来。DTLZ问题由Deb，Thiele，Laumanns和Zitzler在2002年提出^[11]。ZDT问题由Zitzler，Deb和Thiele在2000年提出^[12]。前3个问题比较简单，不可扩展，其决策变量的数目不超过3个；5个DTLZ问题的决策变量和目标维数可以扩展到任何数目，本文中，对 k 和 $|x_k|$ 的取值，我们采用文献^[11]的做法，即对于DTLZ1， $k=3$ ， $|x_k|=7$ ；对DTLZ2，DTLZ3和DTLZ4， $k=3$ ， $|x_k|=12$ ，对于DTLZ6， $k=3$ ， $|x_k|=22$ ；ZDT1~ZDT3有30个决策变量，ZDT4和ZDT6有10个决策变量。图3.3是这13个问题的Pareto前沿面上均匀分布的200个采样点。

表3.1 实验中用到的测试函数

Problems	Dimension n	Variable domain	Objective functions (minimized)
SCH	1	$[-5, 10]$	$f_1(x) = \begin{cases} -x, & \text{if } x \leq 1 \\ -2+x, & \text{if } 1 < x < 3 \\ 4-x, & \text{if } 3 < x \leq 4 \\ -4+x, & \text{if } x > 4 \end{cases}, \quad f_2(x) = (x-5)^2$
DEB	2	$[0, 1]$	$f_1(x) = x_1$ $f_2(x) = (1+10x_2) \times [1 - (\frac{x_1}{1+10x_2})^2 - \frac{x_1}{1+10x_2} \sin(8\pi x_1)]$
KUR	3	$[-5, 5]$	$f_1(x) = \sum_{i=1}^{n-1} (-10e^{(-0.2)\sqrt{\frac{1}{n-1} \sum_{i=1}^{n-1} x_i^2}})$ $f_2(x) = \sum_{i=1}^n (x_i ^{0.8} + 5 \sin(x_i))^2$
DTLZ1	$k+ X_k -1$	$[0, 1]$	$f_1(x) = \frac{1}{2} x_1 x_2 \dots x_{k-1} (1 + g(x_k))$ $f_2(x) = \frac{1}{2} x_1 x_2 \dots (1 - x_{k-1}) (1 + g(x_k))$ \vdots $f_{k-1}(x) = \frac{1}{2} x_1 (1 - x_2) (1 + g(x_k))$ $f_k(x) = \frac{1}{2} (1 - x_1) (1 + g(x_k))$ $\text{where } g(x_k) = 100 \left[x_k + \sum_{x_i \in x_k} ((x_i - 0.5)^2 - \cos(20\pi(x_i - 0.5))) \right]$
DTLZ2	$k+ X_k -1$	$[0, 1]$	$f_1(x) = (1 + g(x_k)) \cos(x_1 \pi / 2) \cos(x_2 \pi / 2) \dots \cos(x_{k-2} \pi / 2) \cos(x_{k-1} \pi / 2)$ $f_2(x) = (1 + g(x_k)) \cos(x_1 \pi / 2) \cos(x_2 \pi / 2) \dots \cos(x_{k-2} \pi / 2) \sin(x_{k-1} \pi / 2)$ \vdots $f_{M-1}(x) = (1 + g(x_k)) \cos(x_1 \pi / 2) \sin(x_2 \pi / 2)$ $f_M(x) = (1 + g(x_k)) \sin(x_1 \pi / 2)$ $\text{where } g(x_k) = \sum_{x_i \in x_k} (x_i - 0.5)^2$
DTLZ3	$k+ X_k -1$	$[0, 1]$	$f_1(x) = (1 + g(x_k)) \cos(x_1 \pi / 2) \cos(x_2 \pi / 2) \dots \cos(x_{k-2} \pi / 2) \cos(x_{k-1} \pi / 2)$ $f_2(x) = (1 + g(x_k)) \cos(x_1 \pi / 2) \cos(x_2 \pi / 2) \dots \cos(x_{k-2} \pi / 2) \sin(x_{k-1} \pi / 2)$ \vdots $f_{k-1}(x) = (1 + g(x_k)) \cos(x_1 \pi / 2) \sin(x_2 \pi / 2)$ $f_k(x) = (1 + g(x_k)) \sin(x_1 \pi / 2)$ $\text{where } g(x_k) = 100 \left[x_k + \sum_{x_i \in x_k} ((x_i - 0.5)^2 - \cos(20\pi(x_i - 0.5))) \right]$
DTLZ4	$k+ X_k -1$	$[0, 1]$	$f_1(x) = (1 + g(x_k)) \cos(x_1^\alpha \pi / 2) \cos(x_2^\alpha \pi / 2) \dots \cos(x_{k-2}^\alpha \pi / 2) \cos(x_{k-1}^\alpha \pi / 2)$ $f_2(x) = (1 + g(x_k)) \cos(x_1^\alpha \pi / 2) \cos(x_2^\alpha \pi / 2) \dots \cos(x_{k-2}^\alpha \pi / 2) \sin(x_{k-1}^\alpha \pi / 2)$ \vdots $f_{k-1}(x) = (1 + g(x_k)) \cos(x_1^\alpha \pi / 2) \sin(x_2^\alpha \pi / 2)$ $f_k(x) = (1 + g(x_k)) \sin(x_1^\alpha \pi / 2)$ $\text{where } g(x_k) = \sum_{x_i \in x_k} (x_i - 0.5)^2, \alpha = 100$
DTLZ6	$k+ X_k -1$	$[0, 1]$	$f_1(x) = x_1$ $f_2(x) = x_2$ \vdots $f_{k-1}(x) = x_{k-1}$ $f_k(x) = (1 + g(x_k)) h(f_1, f_2, \dots, f_{k-1}, g)$ $\text{where } g(x_k) = 1 + \frac{9}{ x_k } \sum_{x_i \in x_k} x_i,$ $h(f_1, f_2, \dots, f_{k-1}, g) = k - \sum_{i=1}^k \left[\frac{f_i}{1 + g} (1 + \sin(3\pi f_i)) \right]$

ZDT1	30	[0, 1]	$f_1(x) = x_1, f_2(x) = g(x) \left[1 - \sqrt{x_1/g(x)} \right]$ $g(x) = 1 + 9 \left(\sum_{i=2}^n x_i \right) / (n-1)$
ZDT2	30	[0, 1]	$f_1(x) = x_1, f_2(x) = g(x) \left[1 - (x_1/g(x))^2 \right]$ $g(x) = 1 + 9 \left(\sum_{i=2}^n x_i \right) / (n-1)$
ZDT3	30	[0, 1]	$f_1(x) = x_1, f_2(x) = g(x) \left[1 - \sqrt{x_1/g(x)} - \frac{x_1}{g(x)} \sin(10\pi x_1) \right]$ $g(x) = 1 + 9 \left(\sum_{i=2}^n x_i \right) / (n-1)$
ZDT4	10	$x_1 \in [0, 1]$ $x_i \in [-5, 5]$ $i=2, \dots, n$	$f_1(x) = x_1, f_2(x) = g(x) \left[1 - \sqrt{x_1/g(x)} \right]$ $g(x) = 1 + 10(n-1) + \sum_{i=2}^n [x_i^2 - 10 \cos(4\pi x_i)]$
ZDT6	10	$x_1 \in [0, 1]$	$f_1(x) = 1 - \exp(-4x_1) \sin^6(6\pi x_1)$ $f_2(x) = g(x) [1 - (f_1(x)/g(x))^2]$ $g(x) = 1 + 9 \left(\sum_{i=2}^n x_i / (n-1) \right)^{0.25}$

3.4.2 度量标准

实验中我们采用三种度量准则, 分别为Coverage of two sets^[14], Convergence^[15]和Spacing^[16]。这三种度量的定义如下:

Coverage of Two Sets: 如果 A, B 为 2 个近似 Pareto 最优解集。覆盖率指标 $I_C(A, B)$ 按下式计算

$$I_C(A, B) \triangleq \frac{|\{b \in B; \exists a \in A: a \succeq b\}|}{|B|} \quad \text{式(3-1)}$$

其中 \succeq 表示支配或等于(也叫做弱支配)。 $I_C(A, B) = 1$ 表示所有在 B 中的决策向量均由 A 中的向量弱支配。 $I_C(A, B) = 0$ 指 B 中没有决策向量被 A 中的向量弱支配。

Convergence: 令 $P^* = (p_1, p_2, p_3, \dots, p_{|P^*|})$ 为理想 Pareto 前沿面上的均匀分布的 Pareto 最优解集合, $A = (a_1, a_2, a_3, \dots, a_{|A|})$ 是通过 EMO 算法得到的近似 Pareto 最优解集。对于集合 A 中的每个解 a_i , 我们可以通过下式得到该解距离 P^* 的最小归一化欧式距离:

$$d_i = \min_{j=1}^{|P^*|} \sqrt{\sum_{m=1}^k \left(\frac{f_m(a_i) - f_m(p_j)}{f_m^{\max} - f_m^{\min}} \right)^2} \quad \text{式(3-2)}$$

其中, f_m^{\max} 和 f_m^{\min} 是参考集合 P^* 中第 m 个目标函数的最大值和最小值。收敛性度量值被定义为集合 A 中所有点的归一化距离的平均值, 如下式所示。

$$C(A) \triangleq \frac{\sum_{i=1}^{|A|} d_i}{|A|} \quad \text{式(3-3)}$$

收敛性指标代表着算法得到的近似 Pareto 最优解集和理想 Pareto 前沿面的距离。因此, 该指标值越低, 表明算法求得解的收敛性越好, 越接近理想 Pareto 前沿面。

Spacing: 令 A 表示算法得到的近似 Pareto 最优解集合。均匀性指标 S 定义为:

$$S(A) \triangleq \sqrt{\frac{1}{|A|-1} \sum_{i=1}^{|A|} (\bar{d} - d_i)^2}$$

式(3-4)

其中

$$d_i = \min_j \left\{ \sum_{m=1}^k |f_m(a_i) - f_m(a_j)| \right\} \quad a_i, a_j \in A \quad i, j = 1, 2, \dots, |A|$$

式(3-5)

\bar{d} 是所有 d_i 的平均值, k 是目标函数的个数。如果该指标值为零, 表明我们得到的非支配解在目标空间是等均匀性指标分布的。此外, Schott^[17], Rudolph^[18], Zitzler, Deb 和 Thiele^[19], Van Veldhuizen 和 Lamont^[20]等学者也提出类似的收敛性度量的准则。

3.4.3 仿真实验结果

在本章的算法比较中, 我们采用了模拟二元交叉(simulated binary crossover)和多项式变异(polynomial mutation)^[21]。在许多经典文献中我们可以看到, 一些研究进化多目标优化的知名学者也采用模拟二元交叉和多项式变异^[4,5,15,22,23]。为了在公平的前提下比较新策略与原有策略的差异性, 各种算法的参数尽量参考算法原著中的取值。具体参数取值情况见表3.2, 其中 n 为决策变量的维数。对于NSGA-II和ADP+NSGA-II, 种群大小为100; 对于PESA-II和ADP+PESA-II, 内部进化种群的大小和外部集合的大小均设为100, 在空间超格划分中, 每维目标被划分的数目为10。下面的实验中, 对于每个测试问题, 各算法独立运行30次。正如Coello Coello^[24]所分析的, 对于一种多目标优化算法, 很难明确地给出最优停止准则, 国内外的学者大多设定迭代次数或函数评价次数作为算法终止条件。本文也是采用这种方式, 当函数评价次数达到50000时, 算法停止运行。

表3.2 参数设置

Parameter	NSGA-II	ADP+ NSGA-II	PESA-II	ADP+PESA-II
Crossover probability	0.8	0.8	0.8	0.8
Distribution index for crossover	15	15	15	15
Mutation probability	1/ n	1/ n	1/ n	1/ n
Distribution index for mutation	20	20	20	20

我们利用盒图(boxplot)^[25]来表示每种算法对于各测试问题的统计结果。盒图一

直是经济学领域统计分析的重要工具，它可以很好地反映数据的统计分布情况。本章用该工具来表现文中引入新策略的两种算法独立运行 30 次得到解的统计特性。图 3.4 及 3.5 显示的是用盒图表示的改进算法和原算法关于 Coverage of Two Sets 指标的评价结果。其中，盒子的上下两条线分别表示样本的上下四分位数，盒子中间的水平线为样本的中位数。盒子上下虚线表示样本的其余部分(野值除外)，样本最大值为虚线顶端，样本最小值为虚线底端，“+”表示野值，盒子的切口为样本的置信区间。在下面的叙述中，AN 表示由 ADP+NSGA-II 得到的解集合，N 表示由 NSGA-II 得到的解集合，AP 表示由 ADP+PESA-II 得到的解集合，P 表示由 PESA-II 得到的解集合。

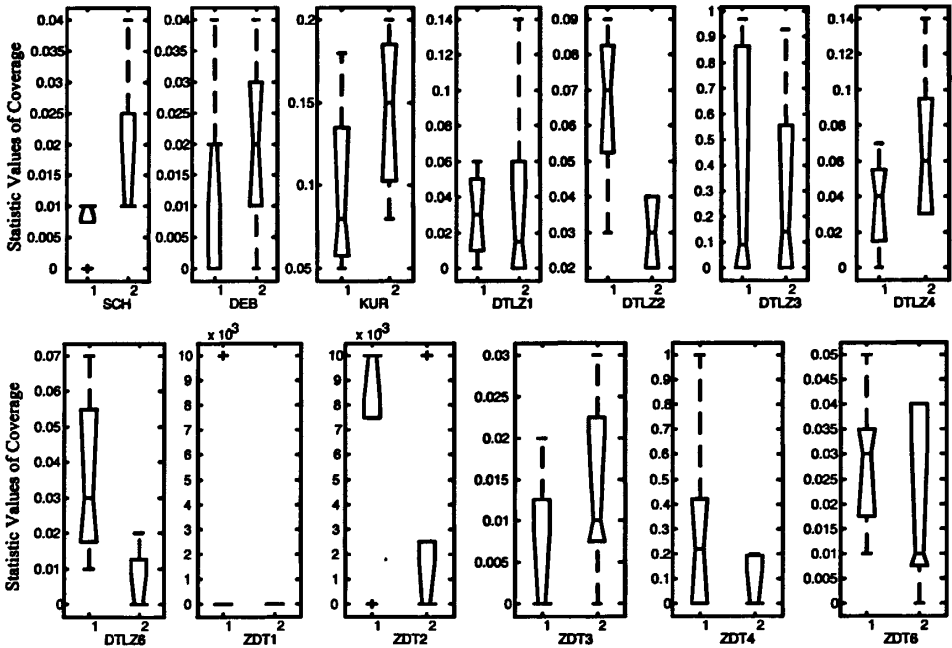


图 3.4 ADP+NSGA-II 和 NSGA-II 求解 13 个测试问题的 Coverage of Two Sets 指标的统计盒图，在每一幅图中，左边的盒子表示 $I_c(AN, N)$ 的分布，右边的盒子表示 $I_c(N, AN)$ 的分布

图 3.4 可以得出，引进了自适应划分策略的 NSGA-II，对于 DEB, DTLZ1, DTLZ2, DTLZ6, ZDT1, ZDT2, ZDT4 及 ZDT6 八个问题，盒图中的 $I_c(AN, N)$ 数值高于 $I_c(N, AN)$ 的数值；对于 SCH, KUR, DTLZ3, DTLZ4 和 ZDT3 五个问题，盒图中的 $I_c(N, AN)$ 数值高于 $I_c(AN, N)$ 的数值。 $I_c(AN, N)$ 表示通过 NSGA-II 得到的解被 ADP+NSGA-II 得到的解弱支配的数目在所有 NSGA-II 解中所占的比率。所以，从这个意义上说，引进了新策略的算法在 DEB, DTLZ1, DTLZ2, DTLZ6, ZDT1, ZDT2, ZDT4 及 ZDT6 八个问题上性能较好；而在 SCH, KUR, DTLZ3, DTLZ4 和 ZDT3 五个问题上原算法效果较好。

同样，引入自适应划分策略的 PESA-II 算法效果更加明显，图 3.5 清楚的表现了这一点，PESA-II 仅在 SCH 一个问题上的性能好于 ADP+PESA-II，而

ADP+PESA-II 在其他 12 个问题上的性能均好于 PESA-II, 这更进一步显示了自适应划分选择策略的有效性。

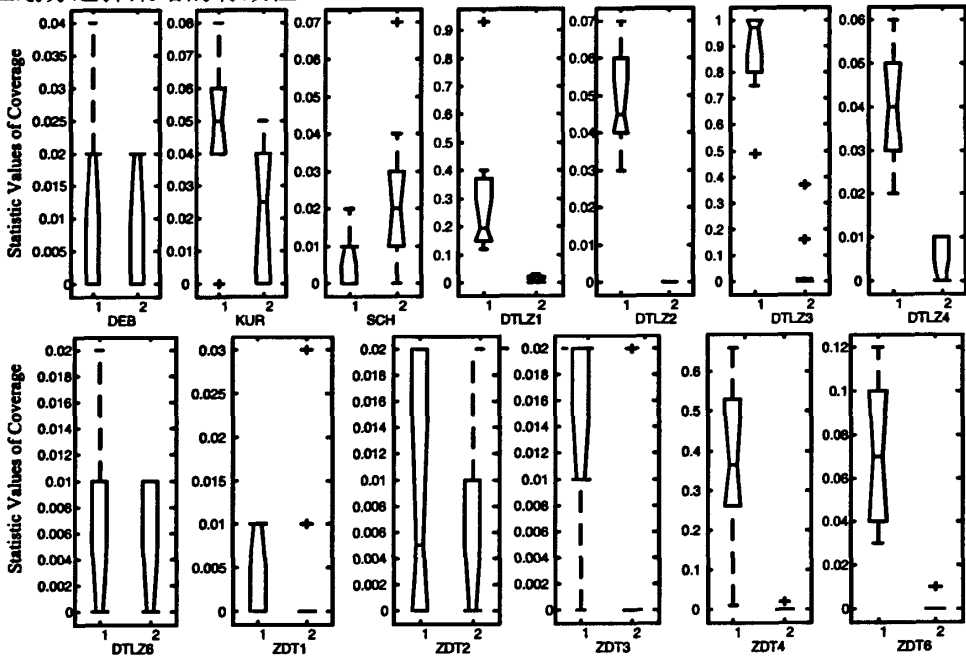


图 3.5 ADP+PESA-II 和 PESA-II 求解 13 个测试问题的 Coverage of Two Sets 指标的统计盒图, 在每一幅图中, 左边的盒子表示 $I_c(AP, P)$ 的分布, 右边的盒子表示 $I_c(P, AP)$ 的分布

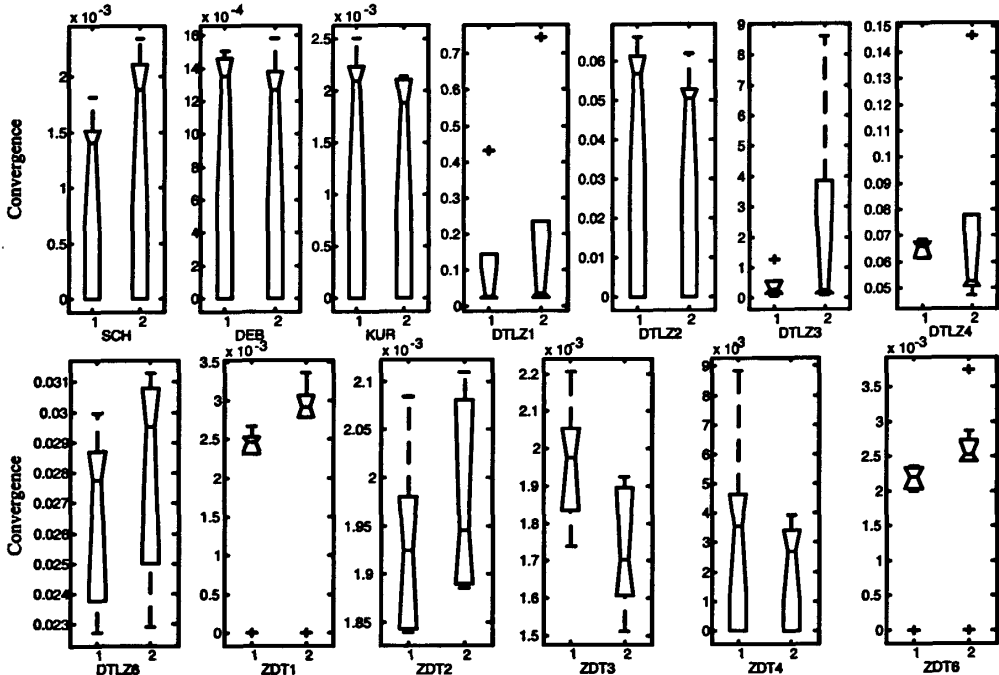


图 3.6 ADP+NSGA-II 和 NSGA-II 求解 13 个测试问题的 Convergence 指标的统计盒图, 在每一幅图中, 左边的盒子表示 $C(AN)$ 的分布, 右边的盒子表示 $C(N)$ 的分布

图 3.6 和图 3.7 中的盒图表示的是引入新策略的 MOEAs 和原算法在 13 个问题上独立运行 30 次得到的 Coverage 指标统计结果。

从图中可以看出, 对于 SCH、DEB 和 KUR 问题, 由于它们本身比较简单, 因此算法独立运行 30 次的结果中, 几乎每次得到的收敛性度量值都小于 10^{-2} 。图 3.6 中的五个 DTLZ 问题中, 对于 DTLZ1, DTLZ3 和 DTLZ6 问题, 引进了新策略的算法效果较好, 而对 DTLZ2 及 DTLZ4 问题, 原算法效果相对好些, 图 3.7 也有类似结论。总体看来, 在 DTLZ 问题上, 引进了自适应划分策略的 MOEAs 性能没有变差, 对于 ZDT 问题, 可以得出相似结论。

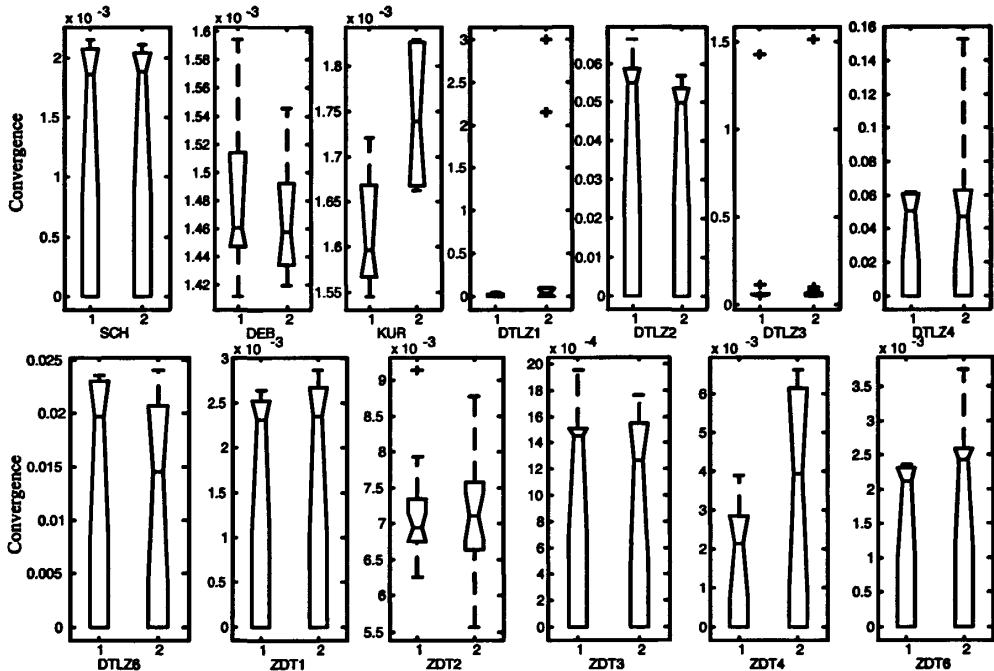


图 3.7 ADP+PESA-II 和 PESA-II 求解 13 个测试问题的 Coverage 指标的统计盒图, 在每一幅图中, 左边的盒子表示 $C(AP)$ 的分布, 右边的盒子表示 $C(P)$ 的分布

图 3.8 及 3.9 表示的是引进了新策略的 MOEAs 和原算法在 13 个问题上独立运行 30 次得到的 Spacing 指标的统计结果。

图 3.8 中可以看到, 对于 SCH, DEB, KUR, DTLZ1, DTLZ3, DTLZ6, ZDT6 问题, 引进新策略的 NSGA-II 较之原算法在此指标上性能明显, 而对 DTLZ2, DTLZ4, ZDT2, ZDT3, ZDT4 问题略显不足, 但指标的差值均小于 10^{-2} , 可以说性能没有变差。图 3.9 则也有相似结论, 引进新策略的 PESA-II 对于 SCH, KUR, DTLZ1, DTLZ2, DTLZ3, ZDT1, ZDT2, ZDT4, ZDT6 问题效果好于原算法, 对 DEB, DTLZ4, DTLZ6, ZDT3 问题, 指标间的差量小于 10^{-2} 。由图 3.8 和 3.9 可以得出, 引进新策略的 MOEA 较之原算法多样性得到了很大提高。

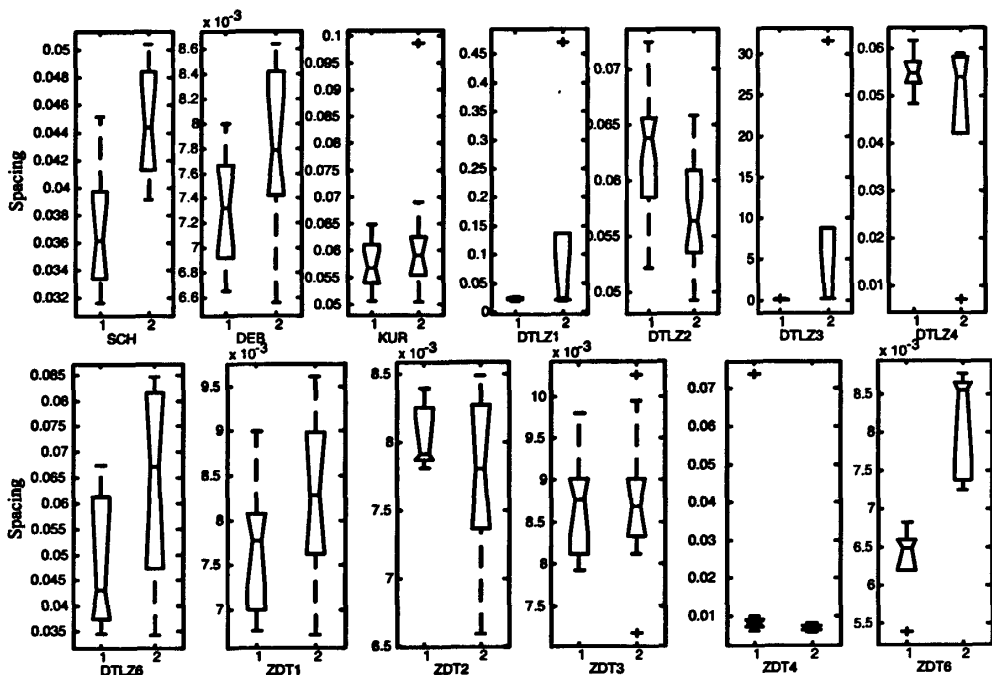


图 3.8 ADP+NSGA-II 和 NSGA-II 求解 13 个测试问题的 Spacing 指标的统计盒图, 在每一幅图中, 左边的盒子表示 $S(AN)$ 的分布, 右边的盒子表示 $S(N)$ 的分布

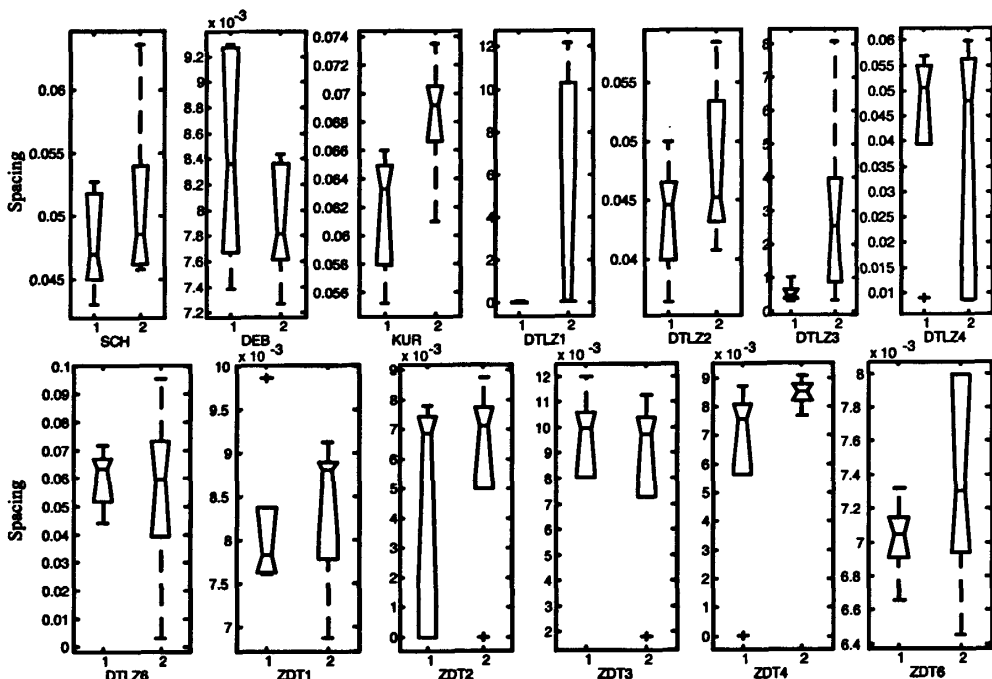


图 3.9 ADP+PESA-II 和 PESA-II 求解 13 个测试问题的 Spacing 指标的统计盒图, 在每一幅图中, 左边的盒子表示 $S(AP)$ 的分布, 右边的盒子表示 $S(P)$ 的分布

基于以上的结果分析, 我们可以得出如下结论: 基于自适应划分的个体选择策略在保证解收敛性不变差的条件之下, 能一定程度提高解的多样性, 新策略是

行之有效的, 可以作为进化算法求解多目标优化时一种新的多样性保持策略。

3.5 总结与讨论

种群维护是多目标进化算法的重要组成部分, 维护方法的好坏决定着最终解集的多样性状况。本章在分析了基于拥挤度距离和网格选择个体策略的基础之上, 提出了一种基于自适应划分的个体选择策略, 它根据非支配个体在目标空间的相似性程度对由当前非支配个体构成的前沿面进行自适应划分, 在划分出的各区域选择最具代表性的个体, 实现对非支配个体的修剪操作。该策略有两个特点: a) 在种群维护的过程中有效避免了某些区域个体密集, 另一些区域个体稀疏的现象, 提高了非支配解集的多样性; b) 新策略没有引进新的参数, 实现较为容易。在实验部分, 我们将新策略应用于两类典型的多目标进化算法NSGA-II及PESA-II中, 通过对13个测试函数三个度量指标的统计分析, 结果表明自适应划分选点策略在保证解收敛性不变差的基础之上, 能一定程度提高解的多样性, 从而可以作为进化算法求解多目标问题时一种新的多样性保持策略。

3.6 参考文献

- [1] Villalobos-Arias M, Coello C A. Asymptotic convergence of metaheuristics for Multi-objective optimization problems. *Soft Computing*, 2006, 10(11):1001-1005.
- [2] Bosman P A N, Thierens D. The balance between proximity and diversity in Multi-objective evolutionary algorithms. *IEEE Trans on Evolutionary Computation*, 2003, 7(2):174-188.
- [3] Maoguo Gong, Licheng Jiao, Haifeng Du, Liefeng Bo. Multiobjective Immune Algorithm with Nondominated Neighbor-based Selection. *Evolutionary Computation*, MIT Press, 2008, 16(2):225-255.
- [4] Khare, V., Yao, X., and Deb, K. (2003). Performance scaling of Multi-objective evolutionary algorithms. *Proceedings of the Second International Conference on Evolutionary Multi-Criterion Optimization, EMO 2003*, volume 2632 of *Lecture Notes in Computer Science*, 376-390.
- [5] Igel C, Hansen N, Roth S. Covariance matrix adaptation for multi-objective optimization. *Evolutionary Computation*, 2007, 15(1):1-28.
- [6] Deb K, Pratap A, Agarwal S, Meyarivan T. A fast and elitist multi-objective genetic

- algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation, 2002, 6(2):182-197.
- [7] Corne D W, Jerram N R, Knowles J D, Oates M J. PESA-II: region-based selection in evolutionary multi-objective optimization. Proceedings of the Genetic and Evolutionary Computation Conference (GECCO-2001). Morgan Kaufmann Publishers, San Francisco, California, 2001,283-290.
- [8] Coello Coello C A, Van Veldhuizen D A, Lamont G B. Evolutionary algorithms for solving multi-objective problems. Kluwer Academic Publishers, New York, USA, 2002.
- [9] Zitzler E, Thiele L, Laumanns M, Fonseca CM, da Fonseca VG. Performance assessment of multiobjective optimizers: An analysis and review. IEEE Trans. on Evolutionary Computation, 2003, 7(2):117-132.
- [10] Deb K. Multi-Objective genetic algorithms: Problem difficulties and construction of test problems. Evolutionary Computation, 1999, 7(3):205-230.
- [11] Deb K, Thiele L, Laumanns M, Zitzler E. Scalable multi-objective optimization test problems. In: Fogel DB, ed. Proc. of the IEEE Congress on Evolutionary Computation, CEC 2002. Piscataway: IEEE Service Center, 2002, 825-830.
- [12] Zitzler E, Deb K, Thiele L. Comparison of multi-objective evolutionary algorithms: Empirical results. Evolutionary Computation, 2000, 8(2):173-195.
- [13] Kursawe F. A variant of evolution strategies for vector optimization. In: Schwefel HP, Männer R. Parallel Problem Solving from Nature-PPSN I. Berlin: Springer-Verlag, 1991,193-197.
- [14] Zitzler E, Thiele L. Multiobjective optimization using evolutionary algorithms-A comparative case study. Parallel Problem Solving from Nature-PPSN V, volume 1498 of Lecture Notes in Computer Science, 1998,292-301.
- [15] Deb K, Jain S. Running performance metrics for evolutionary multi-objective optimization. Technical Report, No.2002004, Kanpur: Indian Institute of Technology Kanpur, 2002.
- [16] Schott, JR. Fault tolerant design using single and multicriteria genetic algorithm optimization [MS. Thesis]. Cambridge: Massachusetts Institute of Technology, 1995.

- [17]Schott J R. Fault Tolerant Design Using Single and Multictiteria Gentetic Algorithm Optimization. Master thesis, Massachusetts Institute of Technology, Cambridge, 1995.
- [18]Rudolph G. On a multi-objective evolutionary algorithm and its convergence to the pareto set. In: Proceedings of the 5th IEEE Congress on Evolutionary Computation, CEC 1998, IEEE Service Center: Piscataway, New Jersey, 511-516.
- [19]Zitzler E, Thiele L, Laumanns M, Fonseca C M. ,Fonseca V G. Performance assessment of multi-objective optimization analysis and review. IEEE Transactions on Evolutionary Computation, 2003, 7(2):117-132.
- [20]Van Veldhuizen D A, Lamont G B. On measuring multiobjective evolutionary algorithm performance. In Proceedings of the 2000 IEEE Congress on Evolutionary Computation, CEC 2000, IEEE Service Center: Piscataway, New Jersey,204-211.
- [21]Deb K, Beyer HG. Self-Adaptive genetic algorithms with simulated binary crossover. Evolutionary Computation, 2001, 9(2):197-221.
- [22]Zitzler E, Thiele L. Multi-objective evolutionary algorithms: a comparative case study and the strength Pareto approach. IEEE Trans on Evolutionary Computation, 1999, 3(4):257-271.
- [23]Deb K, Pratap A, Agarwal S, Meyarivan T. A fast and elitist multi-objective genetic algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation, 2002, 6(2):182-197.
- [24]Coello Coello C A. Recent trends in evolutionary multi-objective optimization. Evolutionary Multi-objective Optimization: Theoretical Advances and Applications. London: Springer Verlag, 2004,7-32.
- [25]McGill R, Tukey JW, Larsen WA. Variations of boxplots. The American Statistician, 1978, 32(1):12-16

第四章 基于自适应划分的多目标优化非支配近邻免疫算法

2003年以来,很多新的进化范例被引进多目标优化领域。其中,将人工免疫系统应用于求解多目标优化问题的研究引起了很多学者的兴趣。早在1999年,Yoo等人就试图将免疫网络的思想用到多目标优化领域中^[1]。Coello Coello等人于2002年基于克隆选择理论提出了一种多目标免疫系统算法MISA^[2]。Luh等人基于克隆选择理论等生物学模型思想提出了多目标免疫算法MOIA^[3]。Freschi等人提出的Vector artificial immune system(VAIS)^[4]。近几年,焦李成、公茂果等人对基于人工免疫系统的多目标优化展开了深入的研究^[5,6,7,8,9],其中,非支配近邻免疫算法NNIA^[10]获得了国际同行的认可,在进化计算领域的顶级期刊《Evolutionary Computation》上发表。

4.1 克隆选择算法

4.1.1 克隆选择学说

1958年Burnet等提出了抗体克隆选择学说,指出抗体是天然产物,以受体的形式存在于细胞表面,抗原可与之选择性地反应。抗原与相应抗体受体的反应可导致细胞克隆性增殖,该群体具有相同的抗体特异性,其中某些细胞克隆分化为抗体生成细胞,另一些形成免疫记忆细胞以参加之后的二次免疫反应。在此过程中,主要借助克隆使之激活、分化和增殖,以增加抗体的数量,通过进行免疫应答最终清除抗原。因此,克隆选择是生物免疫系统自适应抗原刺激的动态过程,在这一过程中所体现出的学习、记忆、抗体多样性等生物特性,正是人工免疫系统所借鉴的^[20]。

4.1.2 克隆选择基本流程

目前对抗体克隆选择机理进行模拟最为经典的算法是de Castro在2000年提出CLONALG^[11],它通过克隆、超变异、选择等操作来完成对抗体种群成熟过程的模拟。后续有许多研究人员分别从不同的角度重提出了一系列的高级克隆选择算法^[12,13]。下面对CLONALG概括如下:

- ① 生成初始种群(p), (p)由一组记忆单元(M)和保留种群(p_r)构成,即 $(p = p_r + M)$;
- ② 依据抗体-抗原亲和度,从中选择 n 个抗体细胞组成抗体种群(p_n);

- ③ 针对抗体种群(p_n)执行克隆操作, 得到临时种群(C), 克隆规模与抗体-抗原亲和度成正比;
- ④ 对克隆临时种群进行高频超变异, 变异概率与亲和度成正比。变异操作之后获得的抗体种群为(C');
- ⑤ 从(C')重新选择改进的个体组成记忆单元 M , P 中的一些个体也被(C')其他一些改进个体替代;
- ⑥ 利用新产生的抗体代替 d 个旧抗体, 亲和度低的抗体更容易被替代。

以上给出了 CLONALG 的算法流程, 此过程正是对抗体克隆选择机理的一个简单的模拟, 此后的许多算法都是在此算法的基础上改进获得的。具体的典型克隆选择算法流程见图 4.1。

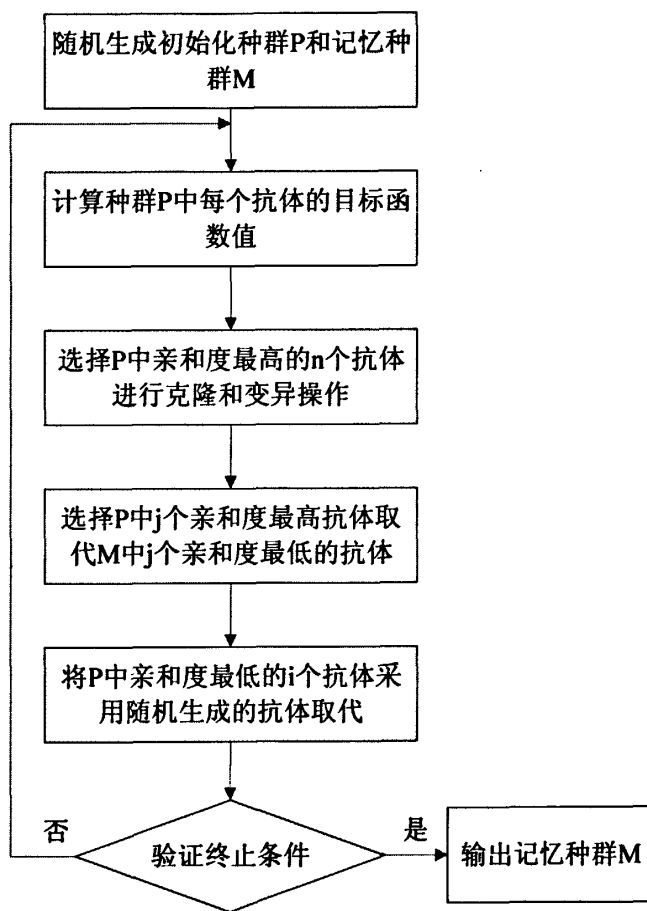


图4.1 典型的克隆选择算法流程图

4.2 基于自适应划分选择策略的非支配邻域免疫算法

4.2.1 非支配邻域免疫算法 NNIA

NNIA^[10]模拟了免疫响应过程中多样性抗体共生、少数抗体激活的现象,利用基于非支配邻域的个体选择方法,只选择少数相对孤立的非支配个体作为活性抗体,根据活性抗体的拥挤程度进行比例克隆复制,对克隆后的抗体群进行亲合度成熟操作,以此加强对当前Pareto前沿面中较稀疏区域的搜索。若 t 时刻的优势抗体群、活性抗体群、克隆抗体群分别用 t 变矩阵 D_t , A_t , C_t 表示,则非支配邻域免疫算法可描述如下:

- ① 初始化: 随机产生初始抗体种群 B_0 , 令 $D_0=\phi$, $A_0=\phi$, $C_0=\phi$, $t=0$;
- ② 更新优势抗体群: 在 B_t 中识别优势抗体, 组成优势抗体群 D_{t+1} ;
- ③ 终止判断: 如果满足算法终止条件, 则输出 D_{t+1} 作为算法求解结果, 算法结束; 否则, $t=t+1$;
- ④ 非支配邻域选择: 选择少数拥挤距离大的优势抗体组成活性抗体群 A_t ;
- ⑤ 克隆: 对 A_t 执行克隆操作得到克隆抗体群 C_t ;
- ⑥ 搜索: 对 C_t 执行重组和超变异操作, 产生 C'_t ;
- ⑦ 更新: 合并 C'_t 和 D_t 得到抗体种群 B_t , 转到②;

NNIA 在 t 时刻的群体进化如图 4.2 所示。

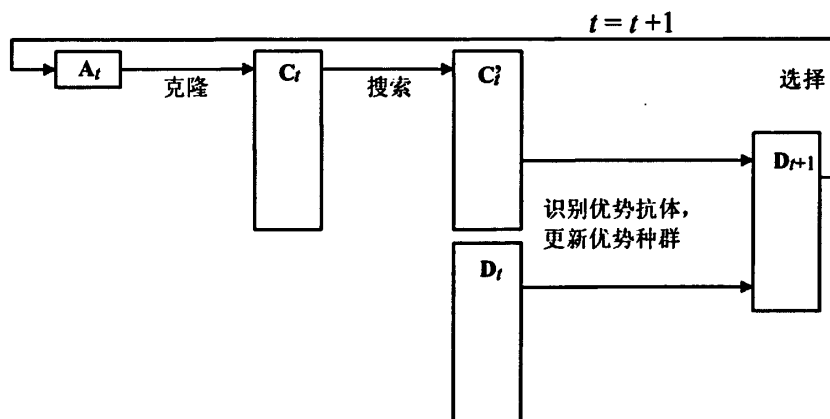


图 4.2 非支配邻域免疫算法的流程

与 NSGA-II、SPEA2、PESA-II 三种代表多目标优化发展水平的算法及 Coello Coello 等提出的 MISA 的对比实验表明, NNIA 是一种非常有效的多目标优化算法。值得一提的是, 当目标个数达到 9 时, 对于较困难的 DTLZ 问题, NNIA 仍能得到较满意的性能, 而 NSGA-II、SPEA2、PESA-II 等却无能为力, 显示了免疫算法在

求解高维多目标优化问题时具有很大的优势。

4.2.2 NNIA+ADP 算法流程

- ① 初始化：随机产生初始抗体种群 B_0 ，令 $D_0=\phi$ ， $A_0=\phi$ ， $C_0=\phi$ ， $t=0$ ；
- ② 更新优势抗体群：在 B_t 中识别优势抗体，组成优势抗体群 D_t ；
- ③ 终止判断：如果满足算法终止条件，则输出 D 作为算法求解结果，算法结束；否则， $t=t+1$ ；
- ④ 非支配个体选择：利用自适应划分选择策略选出优势抗体组成活性抗体群 A_t ；
- ⑤ 克隆：对 A_t 执行克隆操作得到克隆抗体群 C_t ；
- ⑥ 搜索：对 C_t 执行重组和超变异操作，产生 C'_t ；
- ⑦ 更新：合并 C'_t 和 D_t 得到抗体种群 B_t ，转到②；

4.3 相关实验及结果分析

4.3.1 度量标准

实验中我们采用三种度量准则，分别为 Coverage of two sets^[14]、Spacing^[15]和 Smetic^[16]。前两种度量的定义如第三章中所述，Smetic 的定义如下：

Smetric: 设 M 是一个 MOEA 求得的最终近似 Pareto 最优解集，本文中代表最终非支配群体，函数 $S(M)$

$$S(M) := \Lambda(\{\bigcup_i a_i | m_i \in M\}) = \Lambda(\bigcup_{m \in M} \{x | m \prec x \prec x_{ref}\}) \quad \text{式(4-1)}$$

其中 Λ 是勒贝格测度， m_i 是一个非支配个体， x_{ref} 是参考点，根据 $PF_{known} = PF_{true} \Leftrightarrow S(PF_{known}) = \max(S(PF_{known}))$ 我们可以推知，超体积值越大表示对问题的 Pareto 最优解估计越好。此外，Schott^[15]，Rudolph^[17]，Zitzler，Deb 和 Thiele^[18]，Van Veldhuizen 和 Lamont^[19] 等学者也提出类似的收敛性度量的准则。

4.3.2 实验结果及分析

这里使用盒图来说明这些采样的分布。在有缺口的盒图中，缺口表示盒对盒比较的中间带的不确定性的鲁棒估计。符号“+”表示异常值。图 4.3 分别表示 13 问题的结果。图中，左边的盒表示 $I_c(AN, N)$ 的分布，右边的盒表示 $I_c(N, AN)$ 的分布。




图 4.3 NNIA+ADP 和 NNIA 在 13 个问题上获得的两个集合覆盖的统计值




图 4.4 NNIA+ADP 和 NNIA 求解 13 个问题得到的空间分布的评价盒图

图 4.3 说明了对 13 个问题, 运行 30 次时 NNIA+ADP 与 NNIA 的解之间相互支配的情况, 对于 DTLZ 和 ZDT 问题, 两种算法性能差不多, 在低维问题上引入了自适应划分选点方式的 MOEA 在 DEB 上表现较好, 而对 KUR 问题表现不足。

同样的, 这里使用盒图来说明这些采样点的空间分布。在每个图中, 左边的盒表示 $S_p(AN, N)$ 的分布, 右边的盒表示 $S_p(N, AN)$ 的分布。鉴于空间度量的定义, 我们可以得出, 解空间分布越均匀, 其相应的 Spacing 值则小, 它是基于本身解的情况而给出评判, 因此具有很好的指标意义。

图 4.4 很好的展现了 ADP 的优势-分布性, 我们可以直观的看到对于 13 个问题中的大部分, ADP 均表现出很好的性能, 尤其对于 DTLZ 与 ZDT 问题, 估计的 Pareto 最优面较之原算法更加均匀, 多样性得到很大提高。

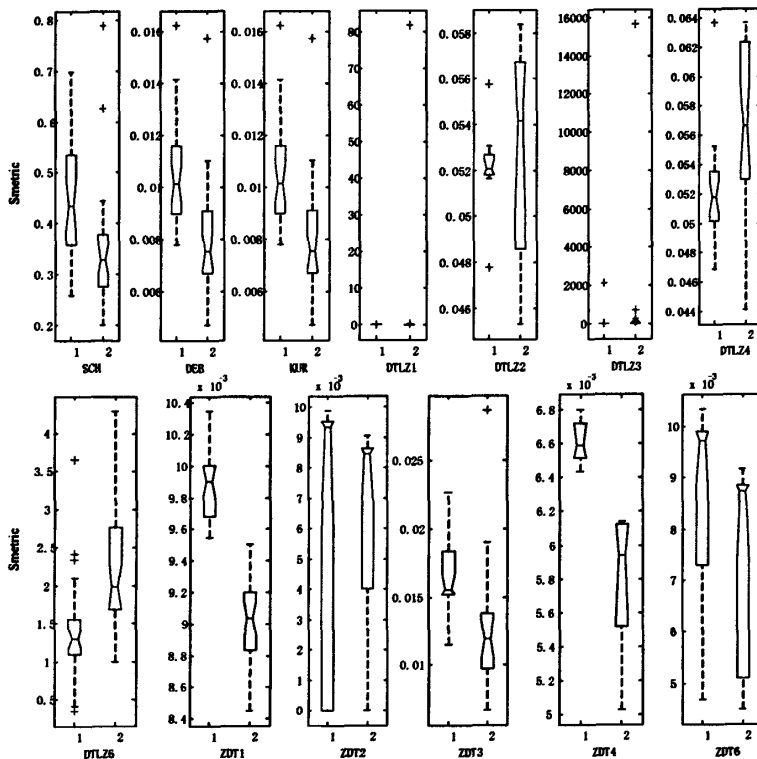


图 4.5 NNIA+ADP 和 NNIA 求解 13 个问题得到的超体积的评价盒图

图 4.5 是对于超体积这个指标, 自适应划分选择策略与拥挤度距离选点方式的区别, 我们可以得到, ADP 在整体上普遍优于拥挤度距离这种选择方式, 在超体积指标上我们可以很明显的得出结论。图中清晰的展示了 NNIA+ADP 与 NNIA 算法在超体积方面的度量情况, 对于 DTLZ 系列问题, 拥挤度距离选点方式略胜于自适应划分, 而在 ZDT 及其他低维目标问题上, ADP 相对表现比较好。

4.4 总结与讨论

由上面的度量评价盒图我们可以得出, 自适应选点策略在解收敛性不变差的情况下, 分布性和多样性都得到了很大程度的提高。

总之, 鉴于以上实验结果, 我们可以做出如下结论:

- (1) 对于低维问题, 自适应划分选点方式能较好的逼近真实的Pareto最优前沿, 而且较之拥挤度距离在解的分布和多样性方面表现较优。
- (2) 对于DTLZ系列问题, 在收敛评价方面, 自适应划分选点策略没有变差, 而在解的分布性上得到很大的提高。
- (3) 对于 ZDT 问题, 从以上度量标准来看, 不论在解的收敛性, 或是解的分布性上, 自适应划分选点方式都明显优于原算法的选点策略。

基于以上实验和分析结果, 我们可以得出结论: 引入了自适应划分选点方式的 MOEA 是行之有效的, 可以作为一种新的选点策略应用于解决多目标问题。

4.5 参考文献

- [1] Yoo J, Hajela P. Immune network simulations in multicriterion design. *Structural Optimization*, 1999, 85-94.
- [2] Coello Coello CA, Cruz-Cortés N. An approach to solve multiobjective optimization problems based on an artificial immune system. *1st International Conference on Artificial Immune Systems*, 2002, 212-221.
- [3] Luh G-C, Chueh C-H, Liu W-W. MOIA: multi-objective immune algorithm. *Engineering Optimization*, 2003, 143-164.
- [4] Freschi F, Repetto M. VIS: An artificial immune network for multi-objective optimization. *Engineering Optimization*, 2006, 38(8):975-996.
- [5] Licheng Jiao, Maoguo Gong, Ronghua Shang, Haifeng DU, Bin Lu. Clonal Selection with Immune Dominance and Anergy Based Multiobjective Optimization. Carlos A. Coello Coello, Arturo Hernández Aguirre, Eckart Zitzler (Eds.): *Proceedings of the Third International Conference on Evolutionary Multi-Criterion Optimization, EMO 2005, Guanajuato, Mexico, March 9-11, 2005*. Springer-Verlag, *Lecture Notes in Computer Science*, 2005, 474-489.
- [6] Bin Lu, Licheng Jiao, Haifeng Du, Maoguo Gong. IFMOA: Immune Forgetting Multiobjective Optimization Algorithm. Lipo Wang, Ke Chen, Yew S. Ong (Eds.):

- Advances in Natural Computation: Proceedings of the First International Conference on natural computation, ICNC 2005, Changsha, China, August 27-29, 2005. Springer-Verlag, Lecture Notes in Computer Science, 2005, 399-408.
- [7] Wenping Ma, Licheng Jiao, Maoguo Gong, Fang Liu. An Novel Artificial Immune Systems Multi-objective Optimization Algorithm for 0/1 Knapsack Problems. Proceedings of the International Conference on Computational Intelligence and Security, CIS 2005, Xi'an, China, 2005, Lecture Notes in Computer Science, Vol. 3801, 2005, 793-798.
- [8] 尚荣华, 焦李成, 公茂果, 马文萍. 免疫克隆算法求解动态多目标优化问题. 软件学报, 2007, 18(11):2700-2711.
- [9] Maoguo Gong, Licheng Jiao, Wenping Ma, Haifeng Du. Multiobjective Optimization Using an Immunodominance and Clonal Selection Inspired Algorithm. Science in China: Series F Information Sciences, 2008, 51(8):1064-1082.
- [10] Maoguo Gong, Licheng Jiao, Haifeng Du, Liefeng Bo. Multiobjective Immune Algorithm with Nondominated Neighbor-based Selection. Evolutionary Computation, MIT Press, 2008, 16(2):225-255.
- [11] De Castro LN, Von Zuben FJ. The Clonal Selection Algorithm with Engineering Applications. In: Proceedings of 2000 GECCO, Workshop on Artificial Immune Systems and Their Applications. IEEE press, 2000, 36-37.
- [12] 焦李成, 杜海峰, 刘芳, 公茂果. 免疫优化计算、学习与识别. 北京: 科学出版社, 2006.
- [13] 莫宏伟. 人工免疫系统原理及应用. 哈尔滨: 哈尔滨工业大学出版社, 2003.
- [14] Deb K, Jain S. Running performance metrics for evolutionary multi-objective optimization. Technical Report, No.2002004, Kanpur: Indian Institute of Technology Kanpur, 2002.
- [15] Schott, JR. Fault tolerant design using single and multicriteria genetic algorithm optimization [MS. Thesis]. Cambridge: Massachusetts Institute of Technology, 1995.
- [16] M. Fleischer, "The measure of Pareto optima: Applications to multi-objective metaheuristics" in Evolutionary Multiobjective Optimization. ser. Lecture Notes in Computer Science, C. M. Fonseca et al., Eds. Berlin, Germany: Springer-Verlag, 2632(2003): (519-533).
- [17] Rudolph G. On a multi-objective evolutionary algorithm and its convergence to the pareto set. In: Proceedings of the 5th IEEE Congress on Evolutionary

- Computation, CEC 1998, IEEE Service Center: Piscataway, New Jersey, 511-516.
- [18] Zitzler E, Thiele L, Laumanns M, Fonseca C M, Fonseca V G. Performance assessment of multi-objective optimization analysis and review. IEEE Transactions on Evolutionary Computation, 2003, 7(2):117-132.
- [19] Van Veldhuizen D A, Lamont G B. On measuring multiobjective evolutionary algorithm performance. In Proceedings of the 2000 IEEE Congress on Evolutionary Computation, CEC 2000, IEEE Service Center: Piscataway, New Jersey, 204-211.
- [20] 张立宁. 基于抗独特型和班德文效应的免疫优化计算及应用. 西安电子科技大学硕士论文, 2008.

第五章 基于免疫克隆的多目标组播路由优化方法

5.1 背景介绍

5.1.1 组播路由问题描述

现代计算机网络包括 Internet 都是分组交换网^[1]。在进行分组交换网设计时,网络的路由选择是需要考虑的重要因素。一个好的路由选择可以使网络的平均时延较低,提高网络的吞吐量。同时,路由选择是一个非常复杂的问题。这是因为,路由选择是网络中的所有节点共同协调工作的结果。其次,路由选择的环境往往是在变化的,而这种变化有时无法事先知道。此外,当网络发生拥塞时,就特别需要有能缓解这种拥塞的路由选择策略,但恰好在这种条件下,很难从网络中的各节点获得所需的路由选择信息。可见路由选择在当前乃至在可预见的未来,都是分组交换网的重要组成部分,其性能的好坏将直接影响到网络整体性能的好坏。

随着网络通讯技术的快速发展以及 Internet 的普及,出现了许多新的网络应用系统,如远程教学、视频会议、计算机协同计算、数据分发和网络游戏等综合性业务。这些新出现的通信业务要求将数据信息从一个节点同时发送到一组目的节点,因此,要求网络必须具有点到多点或多点到多点的通信能力。若采用传统的单播或广播通信方式,会浪费大量的带宽资源而无法满足当前网络信息传输的要求。组播是针对这种情况提出的一种根本的解决方案,它是一种从一个发送者同时向特定多个接收者传送数据的通信过程,由于组播通信是建立树状路由,数据只在树的分枝处复制,能够有效的节约带宽、降低服务器负载、降低网络负载和减少拥塞。

由于组播传输的多媒体数据,量大而且有着相对严格的带宽、时延、时延抖动、丢包率等要求,即带有 QoS 约束。对于实时交互性应用,要求更高。过去传统的那种只能使各种数据流在网络中平均地分享网络资源的传输方式,已经不能很好的满足有 QoS 要求的实时多媒体业务传送的需要,为了寻求数据的组播路径,需要针对组播的特点设计专门的组播路由算法,具有 QoS 约束的组播路由算法,就是按照某种路由策略,利用网络状态信息来构造一棵包含所有组播成员的组播路由,以确定数据的传送路径,同时尽可能满足各种 QoS 需求,即寻找一条端到端的同时满足各种条件的传输路径,以期达到网络资源的最大化利用。

当前研究较多的 QoS 约束组播路由问题有基于带宽约束的组播路由问题、基

于时延约束的组播路由问题、基于时延抖动约束的组播路由问题和基于度约束的组播路由问题等等^[2]。相关研究已经证明, 基于 QoS 约束的最小代价组播路由问题是 NP-complete 问题^[3], 传统的 Bellman-Ford 或 Dijkstra 路由算法很难解决。近年来, 国内外学者提出了许多启发式算法^[4], 一般情况下, 这些算法能在多项式时间内找到合适的解, 但启发式算法只适合特定的网络, 常陷于局部最优, 很难找到全局最优解, 而且这些方法很难并行实现。

进化算法 (evolutionary algorithm, EA) 代表了一类模拟自然进化过程的随机优化方法, 它是一种新兴的搜索技术, 广泛用于解决 NP 难问题; 并且在其发展过程之中已被公认为是多目标优化最适合的方法之一^[5]。多目标进化算法 (multi-objective evolutionary algorithm, MOEA) 研究的兴起也是人们对这门学科研究越来越关注的反映, 同时, 它也是智能优化方法中一项崭新的研究内容。目前, 对于具有 NP 难度网络 QoS 路由的研究已经非常活跃, 其中尤以用遗传算法^[6,7,8]求解的相关研究最为普遍, 并已形成了一些成果和共识, 但我们知道, 多目标最优化问题的最优解一般并不存在, 于是, 在处理问题时, 不得不考虑在“>”或“<”意义下进行比较可行解, 即考虑选择有效解 (或者弱有效解)。从决策分析的角度看, 寻找最佳调和解实际上是根据决策者的某种偏好信息引入完全有序关系。显然, 如果决策者的偏好十分明确清楚而足以给出这种完全有序关系, 则多目标最优化问题就可转化为单目标规划问题去解决。然而, 多目标规划问题的难点之一就在于, 由于问题本身的复杂性, 决定者的偏好信息往往不是十分明确的。

5.1.2 初始抗体群的构造及相关操作算子

结合问题的具体特征, 现有的编码方式一般分为两类, 一类是搜索树模型编码, 尽管这种方式很好地解决了历经进化操作之后产生的非法路径和环路, 但编码解码复杂, 并且交叉和变异操作受限, 并且能否遍历到整个状态空间尚需要进一步的理论证明; 另一类则以访问路径的节点序列为编码准则, 该方法表示自然、简单, 并符合 DeJong 积木块假设。本算法采用上述第二类编码方式, 并对每条染色体设置一个节点访问状态向量, 不仅实现起来简单, 而且经过了进化操作之后不会产生无效链路^[11]。

抗体群的亲合度, 本章指基于度约束和负载均衡的 QoS 组播路由目标函数, 即按 $F = \min(f_1, f_2, f_3)$ 来对抗体进行适应性评价, 其中 f_1 表示组播树的代价 $cost(T)$; f_2 为负载均衡函数 δ^2 , 其取值按 $\delta^2 = \sum (U(e) - \bar{U})^2 / N$ 进行计算, 其中 $\bar{U} = \sum U(e) / N$, 这里 $U(e)$ 为组播树中链路 e 的利用率, 用 $U(e) = \omega / band(e)$ 计算, ω 是业务请求带宽; f_3 为度约束函数 $degree(T)$, 其取值按 $degree(T) = \sum (d_i - k_i)$ 进行计算, d_i 表示节点 i 在组播树 T 中的度, k_i 表示节点的度约束, 则在满足度约束

时, 应有 $d_i \leq k_i$ 。

针对问题的特殊性, 路径交叉运算的交叉位置限制在两个抗体中都含有的节点(起始和目的节点除外)处, 从潜在的交叉位置中随机选择节点作为交叉位置, 交换子路径, 若交叉后链路中存在环路, 则需要执行消环操作。

变异算子用一个很小的概率随机地改变抗体上的基因, 其效果是增加了群体的多样性、扩大了搜索空间。在任意一个抗体中选择两个基因节点 i 和 j , 在 i 和 j 之间选择一条新的路来代替原来的 (i, j) 之间的路。

5.1.3 基于免疫克隆的多目标组播路由优化方法

传统进化算法在解决多目标优化问题时常将多个目标聚合成单目标, 给出唯一解, 不能很好满足决策者的偏好信息要求, 本章提出一种基于免疫克隆^[9]的多目标组播路由优化方法, 它可以给出问题的多个可行解, 决策者可根据自己的偏好信息来寻找最佳调和解。具体实现步骤如下:

- ① 给定算法运行参数, 设定算法终止条件, 利用随机 Dijkstra 算法产生初始抗体群;
 - ② 计算抗体群的亲合度, 找到其中的所有非支配抗体, 利用自适应划分选择对初始抗体群进行修剪, 得到优势抗体群和活性抗体群;
 - ③ 算法终止条件判断: 如果满足终止条件就结束算法, 否则, 继续执行下一步;
 - ④ 根据亲和度的值对活性抗体群执行克隆操作;
 - ⑤ 对克隆后的抗体群进行交叉、变异操作;
 - ⑥ 将交叉、变异后的抗体群与之前的优势抗体群组合在一起;
 - ⑦ 计算此时抗体群的亲合度, 找到其中的所有非支配抗体, 再次利用自适应划分选择修剪方式, 得到优势抗体群和活性抗体群, 转到③
- 具体的算法流程如图 5.1 所示:

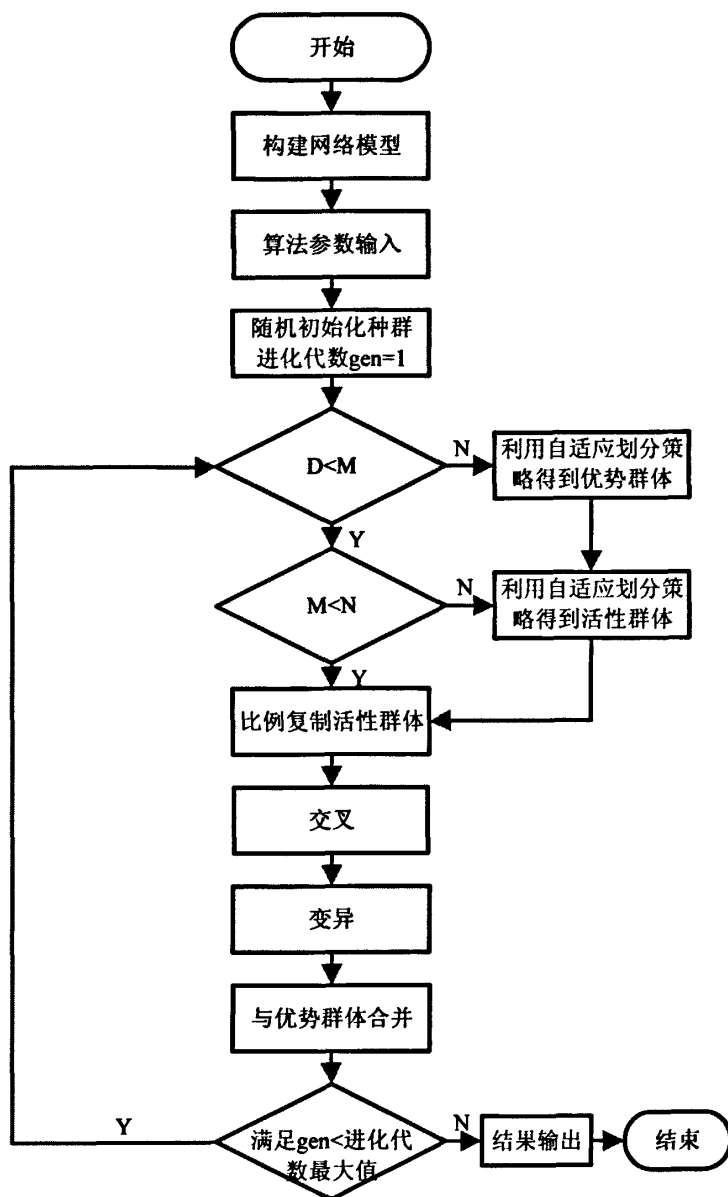


图 5.1 基于免疫克隆的多目标组播路由优化算法流程图

其中 M 为优势群体规模, N 为活性群体规模, D 为抗体群规模。将组播路由优化归结为多目标优化问题, 用人工免疫系统中的免疫克隆思想构造一棵包含所有组播成员的组播路由, 以确定数据的传送路径。利用免疫克隆计算快速的全局收敛性的特点, 搜索问题的可行解, 提供多种备选方案。

5.2 仿真实验

5.2.1 随机网络拓扑的路由仿真平台

这里我们采用 Waxman 算法^[10]来随机生成网络拓扑,并以此作为路由的仿真平台来进行试验, Waxman 算法对每一节点对 (u,v) 定义了一个概率函数: $P(u,v)=\beta \exp(-l(u,v)/La)$, 其中 $l(u,v)$ 是节点对 (u,v) 间的距离; L 是网络中节点对之间的最大距离; α , β 是两个在 0 和 1 之间的参数, α 表示短距离链路数与长距离链路数的比值, α 值越大,表明长距离链路数增多,反之则表明短距离链路数目增多, β 控制网络节点的平均度数, β 值越大,节点间存在连接的概率就越大,网络上连接数目也就越多,网络节点的平均度数增加,反之,网络节点的平均度数减少^[2]。随机网络拓扑生成的具体步骤如下:

- ① 按要求在规定的平面上随机生成一组节点。
- ② 按 Waxman 算法给出的概率在未产生过连接的节点间产生连接。要注意的是,未产生过连接并不是说 2 个节点间不存在连接。只要是 2 个节点间按概率产生连接后,不论 2 节点间的连接是否真正存在,都称这 2 个节点间的连接产生了。
- ③ 所有节点间的连接是否都产生完毕?若没有,则重新执行步骤②。
- ④ 若连接已完成,则采用深度优先搜索遍历算法检测该随机网络是否连通?若是非连通,则清除所有连接,跳至步骤②。
- ⑤ 若网络是连通的,则随机网络产生成功。

产生的随机网络拓扑图如 5.2 所示:




图 5.2 随机网络拓扑的路由仿真

5.2.2 仿真实验结果分析

为了验证基于免疫克隆的多目标组播路由优化方法的优越性，我们将其与传统的基于标准遗传算法^[12]、蚁群算法的组播路由方法^[1]在收敛性、鲁棒性和有效解的优劣性能方面通过以下仿真实验进行了比较。以下仿真实验中使用的遗传算法、蚁群算法和免疫克隆选择算法均以最大迭代次数为终止条件 $G_{\max} = 20$ ，种群规模均为 100，交叉概率 $P_c = 0.45$ ，变异概率 $P_m = 1$ ；克隆算法的优势抗体群规模为 10，活性抗体群规模为 5，克隆比例为 30。以下用 NQoS 表示免疫克隆多目标组播路由优化方法；用 GQoS 表示基于标准遗传算法的组播路由优化方法；用 AQoS 表示基于蚁群算法的组播路由优化方法。




图 5.3 免疫克隆算法的各项指标收敛图

从图 5.3 中可以看出，基于免疫克隆的多目标组播路由优化方法能在较小的进化代数下快速收敛，目标中的代价、负载均衡以及度约束随着进化都能很好的收敛，很好的验证了本算法收敛快的优点。

由图 5.4 可以看出，独立运行本算法 30 次，所得问题解的波动基本平稳，表明了算法的鲁棒性较好，图中出现的跳变是源于本算法是基于随机网络拓扑的路由平台仿真实验，因此不可避免某次抗体群中可能出现劣解，但从图中可以清晰看出，差值之间的误差均在 10^{-1} 以下，因此可以说本算法具有很好的鲁棒性。




图 5.4 免疫克隆算法的各项指标方差图

如图 5.5 所示, NQoS 和 GQoS 相比, 其在同代进化的有效解方面表现优异, 在代价、负载均衡以及度约束三个目标上较之 GQoS 都能得到更优的解, 图中明显可以看出本算法的收敛性能优于 GQoS, 再一次验证了 NQoS 收敛速度快的特点。




图 5.5 免疫克隆算法与标准遗传算法的各项指标比较图




图 5.6 各算法求得解随目的节点所占比例变化的支配关系图

图 5.6 中,随着目的节点占总节点数目比例的增大,基于免疫克隆的多目标组播路由优化方法的优势越来越明显,图中由本算法得到的可行解在大多数情况下,能提供更多的好解,决策者可以根据自己的偏好信息来寻找最佳调和解,从而更大程度上满足了决策者的偏好信息要求。




图 5.7 各算法求得解随总节点平均度变化的支配关系图

从图 5.7 中可以看出, NQoS 能够很好的适应复杂度逐渐增大的网络,当节点的平均度数逐渐增大时,本算法较之其他两种算法,能提供更多合理的备选方案,决策者可以根据自己的偏好信息来寻找最佳调和解,更大程度上符合现实生活中处理网络路由问题的需要。

5.3 总结与讨论

我们知道,多目标最优化问题的最优解一般并不存在,于是,在处理问题时,不得不考虑在“>”或“<”意义下进行比较可行解,即考虑选择有效解(或者弱有效解)。从决策分析的角度看,寻找最佳调和解实际上是根据决策者的某种偏好信息引入完全有序关系。显然,如果决策者的偏好十分明确清楚而足以给出这种完全有序关系,则多目标最优化问题就可转化为单目标规划问题去解决。然而,多目标规划问题的难点之一就在于,由于问题本身的复杂性,决定者的偏好信息往往不是十分明确的。正由于此,具体在实际应用时,应当从服务提供商和用户需求两个角度进行考虑,通过对服务提供商实际情况的考察,同时以用户的实际需求为前提,综合考虑后具体选择其中一个解作为实际的运行方案。

本章提出的基于免疫克隆的多目标组播路由优化方法利用免疫克隆计算快速的全局收敛性,搜索问题的可行解,提供多种备选方案,克服了传统标准遗传算法和蚁群算法等技术的不足,很好的满足决策者的偏好信息要求,基于给出的多个较好可行解,决策者可以根据自己的偏好信息来寻找最佳调和解。

5.4 参考文献

- [1] 田捷. 组播路由算法研究. 武汉理工大学硕士论文, 2005.
- [2] 邹德莉. QoS 组播路由关键算法研究. 大连理工大学硕士论文, 2006.
- [3] Karp R. Complexity of Computer Computations. New York: Plenum Press, 1972, 85-103.
- [4] 王燕琳. 基于 QoS 约束的多播路由问题研究: (博士学位论文). 天津: 天津大学, 2003.
- [5] Fonseca M, Fleming J. An Overview of Evolutionary Algorithm in Multi-objective Optimization [J]. Evolutionary Computing, 1995, 3:1-16.
- [6] Schubert M, Boche H. A Genetic Approach to QoS-Based Transceiver Optimization [J]. IEEE Transaction on Communications. 2007, 8(55): 1557-1566.
- [7] Riedl A, Schupke A. Routing Optimization in IP Network Utilizing Additive and Concave Link Metrics [J]. IEEE Transaction on Network, 2007, 15(5):1136-1148.
- [8] Barollil, Koyama A, SHIRATORI N. A QoS routing method for ad-hoc networks based on genetic algorithm [C]. Proceedings. 14th International Workshop on Database and Expert Systems Applications. 2003:175-179.
- [9] Maoguo Gong, Licheng Jiao, Haifeng Du, Liefeng Bo. Multiobjective Immune

- Algorithm with Nondominated Neighbor-based Selection. Evolutionary Computation, MIT Press, 2008,16(2):225–255.
- [10] Waxman B. Routing of multipoint connections [J]. IEEE Journal on Selected Areas in Communications, 1998, 6(9):1617-1622.
- [11] 黄俊, 刘宴宾. 求解 QoS 路由优化的一种新进化算法. 重庆邮电大学学报, 2008, 20(4), 379-383.
- [12] 杨勇. 基于遗传算法优化 QoS 路由算法的研究. 北京化工大学硕士论文, 2007.

第六章 总结与展望

本文首先由自然免疫系统引出人工免疫系统,通过对免疫系统的总结和概括给出一般典型的免疫算法框架。并同时给出了人工免疫系统在理论分析方面的一些进展。接下来给出了多目标优化问题的相关概念及典型的解决算法,概要介绍了传统解决多目标优化问题的算法及所用到的选点策略。

第三章中通过分析以往典型选择策略,即拥挤距离和网格选择,指出它们存在的缺陷,在此基础上提出了一种新的选择策略-自适应划分选择策略,通过相关仿真实验的比较,验证了这一新策略的有效性。通过和非支配近邻免疫算法(NNIA)的结合,同样得到这一结论。最后通过将改进的非支配近邻免疫算法(NNIA+ADP)应用于组播路由的多目标优化问题中,验证了它的工程应用性。

多目标优化是最优化领域的一个重要的研究方向,因为科学研究和工程实践中许多优化问题都可归结为一个多目标优化问题。多目标优化问题起源于许多实际复杂系统的设计、建模和规划。这些系统所在的领域包括工业制造、城市运输、资本预算、水库管理、能量分配以及网络通信等等,可以说多目标优化问题无处不在。目前,国际上许多学者都致力于这方面的研究。求解多目标优化问题常常分为两种情形:其一是针对实际中碰到的具体的多目标优化问题设计有效的算法;其二是对一般的复杂问题设计高效的优化算法,由于此类问题的可利用信息相对较少,因此很难设计出通用的算法。进化算法的出现为解决此类问题提供了另一种方式,但问题还远未解决,特别当多目标优化问题具有无穷多个 Pareto 最优解,且 Pareto 最优解集在目标函数空间为非凸、分段、不连续或分布不均匀时,现有的多目标优化算法很难获得理想的结果。

多目标进化研究作为一个比较年轻的学科领域,诞生以来无论从理论模型的构建,还是工程应用都取得了一定的进展,但是却依然存在许多亟待解决的问题,因此,进一步研究将免疫系统的进化学习机理、自然防御机理和多样性遗传机理应用于优化搜索的方式和方法,研究和开发新型高效的优化算法,用来解决复杂的多目标问题,将是一个富有挑战性的问题,值得我们继续研究下去。

致 谢

两年的研究生学习生活如白驹过隙，值此毕业论文完成之际，向在我攻读硕士学位期间指导、关心、鼓励、帮助过我的老师、同学、朋友和家人表示我最诚挚的感谢。

在此，首先衷心感谢我的导师杜海峰教授。感谢他把我引入了智能信息处理的广阔领域，使我认识到了这一课题的前沿性和挑战性。杜老师在科研上有敏锐的目光，对复杂问题有独到的见解，使我在研究生期间学习到了很多做研究的方法，这对我以后的工作将大有裨益。

衷心感谢我的师兄公茂果副教授。读研期间，公师兄对我一如既往的信任让我有信心走好每一步，给我提供的每一个机会都使我得到了很大的锻炼，可以说，在这里我提升了自己，改变了自己。公师兄敏锐的眼光、清晰的思路、渊博的学识、以及严谨的态度，都给我留下了深刻的印象，使我在学业和做人方面都受益匪浅。在整个论文的工作期间以及论文撰写的整个过程中，公师兄都给予了亲切热情的指导与关怀。我的整个研究生成长路上都洒满了公师兄辛勤的汗水。再一次，向公师兄致以诚挚的谢意！

感谢师兄弟，师姐妹在各方面给予我的支持和帮助，他们是杜海峰、公茂果、杨咚咚、张立宁、杨杰、李希、刘超、张康、高宜楠、马萌、金晓慧、郑智、刘芳、吴巧娣、左益等，与他们的讨论拓展了我的知识面，感谢他们在学术上的帮助和指导，让我受益良多。感谢这个团队，使我汲取力量继续前行。我的朋友王秀梅、王静、苏开亮、符升高等给我生活上的照顾，并给我莫大的鼓励，祝福他们在今后的科研工作中取得更大的成就，认识你们，给我的生活带来精彩。

特别感谢我的父母，姐姐，姐夫，他们的支持和信任使我迈向了成功的大门，也是我今后人生道路上前进的动力。

最后，衷心感谢论文评审委员会的各位老师对我论文的评阅，谢谢你们辛勤的工作！

研究成果

- [1] Maoguo Gong, Gang Cheng, Licheng Jiao, Chao Liu. Clustering-based Selection for Evolutionary Multi-objective Optimization, 2009 IEEE International Conference on Intelligent Computing and Intelligent Systems, Accepted.
- [2] Maoguo Gong, Chao Liu, Licheng Jiao, Gang Cheng. Hybrid Immune Algorithm with Lamarckian Local Search for Multi-objective Optimization, Memetic Computing, Springer, 2009, in press.
- [3] 公茂果, 程刚, 焦李成, 刘超. 基于自适应划分的进化多目标优化非支配个体选择策略. 计算机研究与发展, 已录用.
- [4] 公茂果, 刘超, 焦李成, 程刚. 基于自适应划分的进化多目标优化非支配个体选择策略. 计算机学报, 待审核.
- [5] 焦李成, 公茂果, 程刚, 王爽, 李阳阳, 马文萍, 尚荣华, 王桂婷, 刘超. 基于免疫克隆的多目标组播路由优化方法. 专利, 待审核.