

中国石油大学（华东）

硕士学位论文

混合智能算法研究及在模糊规划中的应用

姓名：华夏

申请学位级别：硕士

专业：计算机软件与理论

指导教师：裴振奎

20090501

摘 要

智能算法是从自然界得到启发,模仿它的原理而得到的算法。智能算法自产生及发展以来,被广泛应用于解决大规模系统中出现的复杂问题,具有通用、简单、便于并行处理等优点,被认为是对21世纪的计算技术有重大影响的关键技术。

智能算法中的进化算法是仿效生物学中进化和遗传的过程,遵从“生存竞争,优胜劣汰”的原则,从一组随机生成的初始可行群体出发,借助复制、交换(重组)、突变等遗传操作,逐步逼近所研究问题的最优解。本文主要研究了进化算法中的两个比较典型和成熟的算法遗传算法和进化策略,通过对已有理论的研究对比,进一步加深对两种算法的认识。并提出在遗传算法研究的基础上将进化策略和遗传算法结合在一起并引入模拟退火的思想,形成一种改进的混合智能算法。新混合智能算法利用进化策略改进进化算子和选择算子,利用模拟退火思想改进变异算子,克服了原有单一算法易陷入局部最优解和早熟的问题,提高了求解精度。通过数值测试说明了新混合智能算法较之传统算法在求解精度上有了明显改善。

支持向量机是一种新兴的机器学习方法,具有推广能力强,易于高维处理,强大的非线性处理能力等特点。由此提出在以往模糊规划算法研究的基础上,将新生成的混合智能算法与支持向量机相结合,融合进解决模糊规划问题的算法中,提高了原有算法的寻优速率,并与传统的算法作了比较分析。为模糊规划的求解提供了一种新的思路和方法。

关键词: 遗传算法、进化策略、模拟退火、模糊规划、支持向量机

Research of Hybrid Intelligent Algorithm and Applications on Fuzzy Programming

Hua Xia (Computer Software and Theory)

Directed by Prof. Pei Zhenkui

Abstract

The intelligent algorithm is inspired from the nature and realized through imitating the principle of the nature. The intelligent algorithm is widely applied in solving the complicated problems which occur in the large-scale system since it has been invented and developed; it is universal, simple and advantageous for parallel processing. So it is considered to be the key technology that has the major impact to the computation technology in the 21st century.

The evolution algorithm imitates the evolution and the inheritance process of biology and obeys the principle 'Survival of the Fittest'. The EA bases on random generation of initial feasible population and obtains the optimal solution of the problem gradually by means of heredity operations that include replication, crossover and mutation etc. This paper has mainly studied two typical and mature algorithms: the genetic algorithms and the evolution strategies. Through contrasted the existing theory, the understanding of two algorithms is further deepened. A new hybrid intelligent algorithm that combines with evolution strategies and simulated annealing is given in order to increase the probability of escaping from the local optima and improve the precision. The evolution operator and select operator are ameliorated by evolution strategies; the mutation operator is ameliorated by simulated annealing. Numerical results show that the new hybrid intelligent algorithm is superior to the traditional algorithm on accuracy.

Support Vector Machine is a novel machine learning method which has specific advantage to small sample processing, nonlinear processing and high dimensional processing. Therefore, the improved hybrid intelligent and Support Vector Machine are combined to solve fuzzy programming problem. Comparative analysis is given between the new algorithm and the traditional algorithm, and the experiment shows that the new algorithm can enhance the accuracy. The new algorithm provides a new thinking and method for solving fuzzy

programming.

Key words: Genetic Algorithms, Evolution Strategies, Simulated Annealing Algorithm, Fuzzy Programming, Support Vector Machine

关于学位论文的独创性声明

本人郑重声明：所呈交的论文是本人在指导教师指导下独立进行研究工作所取得的成果，论文中有关资料和数据是实事求是的。尽我所知，除文中已经加以标注和致谢外，本论文不包含其他人已经发表或撰写研究成果，也不包含本人或他人为获得中国石油大学（华东）或其它教育机构的学位或学历证书而使用过的材料。与我一同工作的同志对研究所做的任何贡献均已在论文中作出了明确的说明。

若有不实之处，本人愿意承担相关法律责任。

学位论文作者签名： 华夏

日期：2009 年 4 月 6 日

学位论文使用授权书

本人完全同意中国石油大学（华东）有权使用本学位论文（包括但不限于其印刷版和电子版），使用方式包括但不限于：保留学位论文，按规定向国家有关部门（机构）送交学位论文，以学术交流为目的赠送和交换学位论文，允许学位论文被查阅、借阅和复印，将学位论文的全部或部分内容编入有关数据库进行检索，采用影印、缩印或其他复制手段保存学位论文。

保密学位论文在解密后的使用授权同上。

学位论文作者签名： 华夏

日期：2009 年 4 月 6 日

指导教师签名： 裴振全

日期：2009 年 4 月 6 日

第一章 绪论

1.1 课题的提出、目的及意义

生命科学与计算机科学的相互交叉、渗透和促进是上个世纪以来科学技术发展的一个显著特点。专家通过研究人体各个信息处理系统的生理功能及作用机理，从中抽取出相应的人工模型并有效地应用于各个领域。由此而产生了进化算法、人工神经网络等众多智能计算方法，并在传统计算方法无法解决的优化问题中发挥了重大的作用。近十几年来，这些智能算法在我国也得到重视和推广，已成功应用于许多领域。

进化算法是仿效生物学中进化和遗传的过程，遵从“生存竞争，优胜劣汰”的原则而形成的一种智能算法。基本原理是从一组随机生成的初始可行群体出发，通过复制、交换（重组）、突变等遗传操作，逐步得到所研究问题的最优解。从实质而言，进化算法是一种具有自适应调节功能的搜索寻优技术。通常，进化算法包括遗传算法（Genetic Algorithms）、遗传规划（Genetic Programming）、进化策略（Evolution Strategies）、进化规划（Evolutionary Programming）4种典型方法。其中遗传算法和进化策略是本课题所涉及到的两种进化算法。

当今时代是一个信息的时代，信息为人类认识和改造世界提供了知识的源泉，但是人们接触到的信息其实大部分的时候是不确定的信息。在运筹学、管理科学、信息科学、系统科学、计算机科学以及工程技术等众多领域都存在着客观的或人为的不确定性。这些不确定性的表现形式是多种多样的，如随机性、模糊性、粗糙性、模糊随机性以及其它的多重不确定性。然而，对于这些含有不确定性的决策问题，经典的优化理论通常是无能为力的。虽然已有的随机规划和模糊规划可以解决一部分不确定优化问题，但又远远不能满足解决具有多重不确定性的优化问题的需求。因此，建立和完善统一的不确定环境下的优化理论与方法不但具有理论价值，而且具有广阔的应用前景。

模糊数学诞生于20世纪60年代，模糊集的理论与方法也逐渐受到人们的青睐与关注。我们定义含有模糊参数的数学规划为模糊规划。为了求解传统方法所不能解决的模糊规划模型，人们设计了一系列基于模糊模拟的智能算法。比较熟知的方法是利用由模糊模拟、神经元网络和遗传算法相结合形成的混合智能算法来求解模糊规划模型^[1]。传统的混合智能算法来进行解优化，往往易陷入局部最优解，使得最终结果不能保证是全局收敛的。针对这一问题，本课题将改进的混合智能算法和支持向量机相结合，应用到

解决模糊规划中，以克服以往混合智能算法中的局限性，提高算法的效率。这一点具有创新性，有重大的理论意义和应用价值。

1.2 进化算法基本原理

本文主要研究了进化算法领域中两个具有代表性的算法：遗传算法和进化策略，故下面只针对这两种算法进行讨论。

1.2.1 遗传算法的基本原理

遗传算法的实施过程^[2]包括编码、产生初始群体、计算适应度、复制、交换、突变、反复迭代、终止等操作。遗传算法的基本工作步骤是：1、确定初始群体和参数，包括复制率、交换率和突变率，确定终止条件。2、随机生成初始群体。3、计算各个体的适应度。4、根据遗传概率，用下述操作产生新群体：(1)复制。将已有的优良个体复制后添入新群体中，删除劣质个体。(2)交换。将选出的两个个体进行交换，所产生的新个体进入新群体。(3)突变。随机改变某个体的某一字符后，将新个体添入新群体。5、反复执行 3 及 4，直至达到终止条件，其中最佳个体作为遗传算法的结果。

1.2.2 进化策略的基本原理

进化策略的工作过程^[2]包括表达问题、生成初始群体、计算适应度、执行重组、突变、选择新群体等步骤，经过反复迭代，逐渐逼近最优解。进化策略的步骤是：1、确定问题的表达方式和终止条件。2、随机生成初始群体，并计算其适应度。3、根据进化策略，用下述操作产生新群体：(1)重组。将两个父代个体交换目标变量和随机因子，产生新个体。(2)突变。对重组后的个体添加随机量，产生新个体。(3)计算新个体适应度。(4)选择。根据选择策略，挑选优良个体组成下一代群体。4、反复执行 3，直至达到终止条件，其中最佳个体作为进化策略的结果。

1.3 进化算法的研究现状

1.3.1 遗传算法研究现状

进入 90 年代后，遗传算法迎来了兴盛发展时期，无论是理论研究还是应用研究都成了十分热门的课题。尤其是遗传算法的应用研究显得格外活跃，不但应用领域扩大，而且利用遗传算法进行优化和规则学习的能力也显著提高，同时产业应用方面的研究也在摸索之中。此外一些新的理论和方法在应用研究中亦得到了迅速的发展，这些无疑给

遗传算法增添了新的活力。遗传算法的应用研究已从初期的组合优化求解扩展到了许多更新、更工程化的应用方面。

随着应用领域的扩展,遗传算法的研究出现了几个引人注目的新动向:一是基于遗传算法的机器学习,这一新的研究课题把遗传算法从历来离散的搜索空间的优化搜索算法扩展到具有独特的规则生成功能的崭新的机器学习算法。这一新的学习机制对于解决人工智能中知识获取和知识优化精炼的瓶颈难题带来了希望。二是遗传算法正逐渐和神经网络、模糊推理以及混沌理论等智能计算方法相互渗透结合,这对开拓 21 世纪中新的智能计算技术具有重要的意义。三是并行处理的遗传算法的研究十分活跃。这一研究不仅是对遗传算法本身的发展,而且对于新一代智能计算机体系结构的研究都是十分重要的。四是遗传算法正和另一个称为人工生命的崭新研究领域不断渗透结合。所谓人工生命就是用计算机模拟自然界丰富多彩的生命现象,其中生物的自适应、进化和免疫等现象是人工生命的重要研究对象,而遗传算法在这方面无疑会发挥一定的作用,五是遗传算法和进化规划(Evolution Programming, EP)以及进化策略(Evolution Strategy, ES)等进化计算理论日益结合。EP 和 ES 几乎是和遗传算法同时独立发展起来的,同遗传算法一样,它们也是模拟自然界生物进化机制而形成的智能计算方法,既同遗传算法具有相同之处,也有各自的特点。目前,这三者之间的比较研究和彼此结合的研究正形成热点。

1991 年 D. Whitey 提出了基于领域交叉的交叉算子(Adjacency based crossover),这个算子是特别针对用序号表示基因的个体的交叉,并将其应用到了 TSP 问题中,通过实验对其进行了验证。

D.H. Ackley 等提出了随机迭代遗传爬山法(Stochastic Iterated Genetic Hill-climbing, SIGH)采用了一种复杂的概率选举机制,此机制中由 m 个“投票者”来共同决定新个体的值(m 表示群体的大小)。实验结果表明, SIGH 与单点交叉、均匀交叉的神经遗传算法相比,所测试的六个函数中有四个表现出更好的性能,而且总体来讲, SIGH 比现存的许多算法在求解速度方面具有更强的竞争力。

H. Bersini 和 G. Seront 将遗传算法与单一方法(simplex method)结合起来,形成了一种叫单一操作的多亲交叉算子(simplex crossover),该算子在根据两个母体以及还有一个额外的个体产生新个体,事实上它的交叉结果与对三个个体用选举交叉产生的结果一致。同时,文献还将三者交叉算子与点交叉、均匀交叉做了比较,结果表明,三者交叉算子比其余两个有更好的性能。

目前,国内也有不少的专家和学者对遗传算法的交叉算子进行改进。2002年,戴晓明等应用多种群遗传并行进化的思想,对不同种群基于不同的遗传策略,不同的变异算子等来搜索变量空间,并利用种群间迁移算子来进行遗传信息的交流,用以解决经典遗传算法的收敛到局部最优值问题

2004年,赵宏立等针对简单遗传算法在较大规模组合优化问题上搜索效率不高的现象,提出了一种用基因块编码的并行遗传算法(Building-block Coded Parallel GA, BCPGA)。该方法以粗粒度并行遗传算法为基本框架,在染色体群体中识别出可能的基因块,然后用基因块作为新的基因单位对染色体重新编码,产生长度较短的染色体,再用重新编码的染色体群体作为下一轮以相同方式演化的初始群体。

2005年,江雷等针对并行遗传算法求解TSP问题,探讨了使用弹性策略来维持群体多样性的方法,使得算法跨过局部收敛的障碍,向全局最优解方向进化。

1.3.2 进化策略研究现状

Rechenberg、Schwefel 和 Bienert 是进化策略公认的发明者^[3]。1964年,当时他们还在柏林技术大学上学,在设计一种能够评测在风洞中可弯曲的三维物体最小变形的设备的过程中发明了该算法。与其他研究工作一样,开始阶段,他们希望通过传统的数值算法来解决这一问题,但结果是失败的,传统的数值算法无法跳出局部最优解。Rechenberg首先想到了将进化思想应用到算法的设计中,他将进化论中的生物选择、重组、变异应用到参数优化中^[4],可以认为进化策略的思想已经形成,虽然这只是进化策略的一个初始形态,但它涵盖了进化策略的基本思想。Rechenberg的基本思想如下:首先随机产生一个离散的初始个体,然后将一个满足二项分布的变异作用在初始个体上,这样得到一个新的个体,从这两个个体中选择适应值较大的那个个体作为下一代的父个体,这样就完成一次循环。这就是最早期的(1+1)进化策略。

Schwefel 首先将 Rechenberg 的算法付诸于实施^[5], Schwefel 的实验非常成功,算法战胜了局部最优值的陷阱,获得了全局最优解,这一成功对与进化规划而言同样具有里程碑式的意义。Bienert 的贡献在于将进化规划思想应用到具有工业意义的实际具体问题上^[6],该问题是传统算法所不能解决的问题, Bienert 的硕士论文成功解决了这一问题,这一工作结合了进化规划的理论与实践,意义重大。

随后 Rechenberg^[7]进一步改进了进化规划,在解决 n 维凸函数的优化中,给出了算法的收敛性分析,并在此基础上给出了著名的“1/5 成功原则”,即通过外在改变二项

分布的方差的经验值。Rechenberg 又给出了多群体下的进化策略算法，即 $(\mu+1)$ 进化策略，群体内个体间的重组操作也被使用。Rechenberg 的这项工作对于进化策略的进一步发展起到了决定性的作用，群体概念和重组算子的引入从理论上完善了进化策略，为其在实际应用中取得成功奠定了理论基础。但是这一算法由于变异算子缺乏自适应机制而显得先天不足，并未得到广泛推广和应用。

Schwefel^[8]在 $(\mu+1)$ 进化策略的基础上迈出了重要的一步，将之推广到 $(\mu+\lambda)$ 进化策略和 (μ,λ) 进化策略，这两种形式的进化策略成为后来广泛使用的两种形式。进化规划中使用的自适应机制也在进化策略中被使用。

随着并行思想的深入，进化策略在二十世纪九十年代引入了并行概念并取得了一定的成功。同期正是进化计算各个分支相互融合的时期，进化策略研究团体发挥了重要的作用。

在进化策略的理论研究方面，Hans-Georg Beyer 做出了重要的贡献。Beyer 首先建立了进化策略的数学模型，并以微分几何为工具研究了非球面适应值空间的性质，研究了 (μ,λ) 等多种进化策略的收敛性质和算法的动力学性质，为进化策略的进一步发展打下了基础。

国内对进化策略的研究也已经起步，并且取得了很大的成绩，在国内、国际会议上发表了相当多的论著，成功的解决了单峰函数最优化问题^[9,10]，智能试题库系统中的抽题算法^[11]、用柯西分布来改变进化策略的变异算子提高收敛速度^[12]以及对多目标进化算法的研究。

1.4 本文主要研究内容及组织结构

1.4.1 主要研究内容

本文主要研究了混合智能算法和模糊规划的优化算法以及混合智能算法在模糊规划问题中的应用，其中混合智能算法主要研究了两个具有代表性的进化算法：遗传算法和进化策略。主要工作有以下几个方面：

(1) 综述了进化算法中两个典型算法，遗传算法和进化策略，介绍了算法的国内外发展现状，并深入研究了两种算法的原理和应用技术，提出了改进的方向。

(2) 通过对各种算法算子的研究，提出利用遗传算法，进化策略的改进算子，并融入另一个智能算法，模拟退火算法的思想，形成一种新的改进的混合智能算法，用于对函数求解，实验证明新的算法在提高最优解精度和寻优速度上有一定的突破。

(3)探讨了模糊规划原理和现有的模糊规划分类,包括期望值模型、机会约束规划模型、相关机会规划模型。并对其传统的模型算法作了研究。作为下一步将混合智能算法应用于模糊规划的基础。

(4)研究了支持向量机的机理,在以往模糊规划算法的基础上,将新生成的混合智能算法和支持向量机融合在一起解决模糊规划问题,提高了原有算法的寻优率,并与传统的算法作了比较分析。

主要创新点

本文在理论及实践上的创新之处主要有:

(1)分析了几种智能算法的原理和优缺点,将遗传算法、进化策略改进算子和模拟退火算法思想有机的结合在一起,形成一种新的混合智能算法。

(2)在深入研究了模糊规划原理和支持向量机后,提出将新生成的混合智能算法与支持向量机相结合用于解决模糊规划问题。作为解决模糊规划问题的新方法,改进后的算法较之传统的算法,在模糊规划问题的求解中,显示了一定的优势。

1.4.2 组织结构

第一章主要介绍本课题的提出目的及意义,综述进化算法的国内外研究现状,论述了两种典型的进化算法,遗传算法和进化策略的基本原理。

第二章具体综述了进化算法中两种典型算法的原理和操作技术,以及两种算法的比较和融合方向。提出了分别的改进方法和思路。

第三章深入学习研究了模糊理论知识,为混合智能算法在模糊规划中的应用做好充分的理论基础。

第四章提出了一种新的混合智能算法,基于对遗传算法和进化策略的算子研究,将两种算子加以改进并融合在一起,其中在某些环节融入了模拟退火思想。新生成的混合智能算法在实验测试中体现出良好的寻优速度和精确度。

第五章研究了模糊规划的原理和分类,并介绍了支持向量机的理论基础和应用技术。提出了将支持向量机和进化算法相融合进行模糊规划问题的求解。对每一类的模糊规划模型都应用了新生成的混合智能算法来进行求解试验,均取得了满意的效果,对比传统的算法有一定的优势。

第六章在总结本文的工作和创新点的基础上,给出了进一步研究的内容。

第二章 进化算法综述

进化算法就是借用生物进化的规律，通过繁殖-竞争-再繁殖-再竞争，实现优胜劣汰，一步一步地逼近问题的最优解。目前发展比较成熟与完善的两种进化算法是遗传算法和进化策略。

本章将着重阐述上述两种算法。分别对两种算法的基本原理及数学模型等进行描述并对其参数进行分析，随后对两种算法的改进算法以及应用进行综述。

2.1 进化算法的生物学背景

根据达尔文的自然选择学说，地球上所有生物，都经过了长期的进化和繁衍而形成。地球上的生物都具有很强的繁殖能力。在繁殖的过程中生物借助遗传来使后代基本上保持了物种的相似性，部分的生物个体由于变异，具有和父代较为明显的差别，甚至形成了新的物种。由于生物的不断繁殖，生物的数量也在迅速的增加，而自然界中的生物赖以生存的资源空间却是有限的。因此，为了生存，生物就需要竞争，也就是达尔文的“物竞天择，适者生存”学说。在残酷的自然竞争中，根据对环境的适应能力，不适应环境的个体被淘汰了，留下来的都是很优良的个体。自然界中的生物，就是根据这种优胜劣汰的原则，不断地进行进化。

生物群体的进化机制表现为三种形式：

2.1.1 遗传

遗传是借助染色体来完成的。染色体靠的是它所携带的遗传因子，也就是“基因”，基因是贮藏遗传信息的地方，一个基因往往携带着祖辈一种或几种遗传信息，同时又决定着后代的一种或几种性状的特征。基因是一种比染色体小许多倍的微小的物质，即使在光学显微镜下也不可能看到。它们按顺序排列在染色体上。由染色体将它们带入生物个体细胞。每条染色体都是由上千个基因组成的。有两个父代的染色体交叉形成，因为生物个体同时具有两个父代的遗传特征。

2.1.2 变异

生物有机体的属性之一，它表现为亲代与子代之间的差别。变异有两类，即可遗传的变异与不遗传的变异。现代遗传学表明，不遗传的变异与进化无关，与进化有关的是可遗传的变异，后一变异是由于遗传物质的改变所致，其方式有突变与重组。

供自然选择作用的变异是经过生物遗传系统本身加工和组装的,是经过挑选、摒弃、编辑过的贮存的变异。生物体的变异过程是一种突发的、不可逆的过程,是一种小概率事件。在整个生物进化具有举足轻重的作用。生物进化是一个复杂的适应过程问题,是偶然性和必然性相互作用的结果。生物进化是在一定条件下进行的,首先存在一定规模的种群,该种群内的个体间的适应度存在差异,群体保持一定多样性的生物体自我繁殖的能力,即有性生物的生殖和无性生物的克隆。种群内的个体承受着不同性质和不同强度的选择压力,他们决定了种群进化的性质。只有在大量遗传变异的基础上才有可能产生大量的遗传重组,通过大量的遗传重组筛选才有可能获得最佳的基因组合,通过自然选择的作用,一方面保留一些变异另一方面则淘汰一些变异。

2.1.3 选择

亦称“淘汰”。达尔文学说中进化过程的主要机制。是能导致种群在遗传特性上趋异的因素之一。由于对食物和空间的竞争,以及对捕食者的作用,可影响某一种群的组成,结果那些对周围发生有利变异的生物存活下来,不利变异的则被消灭。达尔文把这种生存斗争中,适者生存、不适者被淘汰的过程,叫做自然选择。经过长期的自然选择,微小的有利变异得到积累而成为显著的有利变异,从而产生了适应特定环境的生物新类型。自然选择的作用比遗传突变大得多,自然选择在大小种群中都能成为它们进化性变化的有效动力。自然选择是种群内所产生的经过遗传得来的变化。因为某些个体和其他个体留下更多的后代,许多世代以后,具有能使生物存活和留下更多后代的特征的基因,靠牺牲那些提供较少适应度的基因来增加其频率,只要环境中有足够的变异让不同的遗传体系去适应环境的不同部分,一个种群就能够对自然选择做出反应而分歧,这种对环境异质性充分协调的现象在所有有机体类型中,甚至在种群水平上,都是一种极其普遍的现象。

其实,自然界生物进化的过程就是一个优化的过程,而用到计算机的智能仿生方面,无疑是有借鉴意义的。由此而生成的进化算法,就是对生物进化的模仿。

2.2 遗传算法综述

2.2.1 遗传算法描述

遗传算法(Genetic Algorithm, 简称 GA)是模拟生物在自然环境中的遗传和进化过程而形成的一种随机搜索方法,它是一种典型而富有代表性的进化算法。根据达尔文的

生物进化学说与孟德尔的遗传变异理论，地球上的生物繁殖后代，既有遗传也有变异，依“优胜劣汰、适者生存”的规律使生物种群不断进化。生物的进化大体是通过繁殖、变异、竞争和选择这四中基本形式来实现的。GA中的一系列遗传操作如交叉、变异、选择等算子，正是对这些进化机制的类比和模拟。

根据算法的流程图，Gen代表遗传（迭代）的代次，遗传算法从Gen=0开始。根据所研究问题的表达方式确定字符串长度L，接着随机产生M个初始群体。刚开始时，终止条件不会被满足，于是依次计算群体中各个个体的适应度。根据计算结果，依次执行复制、交换、突变等遗传操作。首先执行复制，其复制概率为 p_r 。图中j代表遗传操作次数，从j=0开始。根据适应度大小，选择优质个体作为复制对象，将复制结果添入新群体中。复制过程不断重复，直到复制次数满足 $p_r \square M$ 。与此同时，从父代群体中删除同样数目的劣质个体，将剩余的个体进入下一代，使新一代群体规模M保持不变。其次执行交换，其交换概率为 p_c 。交换次数从j=0开始。根据个体的适应度每次选择两个个体执行交换，然后将新形成的两个个体代替父代旧个体添入新群体中。交换过程反复执行，直至交换次数满足 $p_c \square M$ 为止。第三个遗传操作是突变，突变概率为 p_m 。突变针对字符进行，发生突变的字符总数为 $p_m \square L \square M$ 。经过复制、交换及突变，产生新一代群体，代次Gen又增加1次。再对新一代群体计算适应度，执行遗传操作。如此重复迭代，直至满足终止条件。

2.2.2 遗传算法流程

基本遗传算法的流程如图2-1：

2.2.3 遗传算法优缺点

遗传算法具有的优点：(1)遗传算法从问题解的串集开始搜索，而不是从单个解开始。这是遗传算法与传统优化算法的极大区别。传统优化算法是从单个初始值迭代求最优解的；容易误入局部最优解。遗传算法从串集开始搜索，覆盖面大，利于全局择优。(2)许多传统搜索算法都是单点搜索算法，容易陷入局部的最优解。遗传算法同时处理群体中的多个个体，即对搜索空间中的多个解进行评估，减少了陷入局部最优解的风险，同时算法本身易于实现并行化。(3)遗传算法基本上不用搜索空间的知识或其它辅助信息，而仅用适应度函数值来评估个体，在此基础上进行遗传操作。适应度函数不仅不受

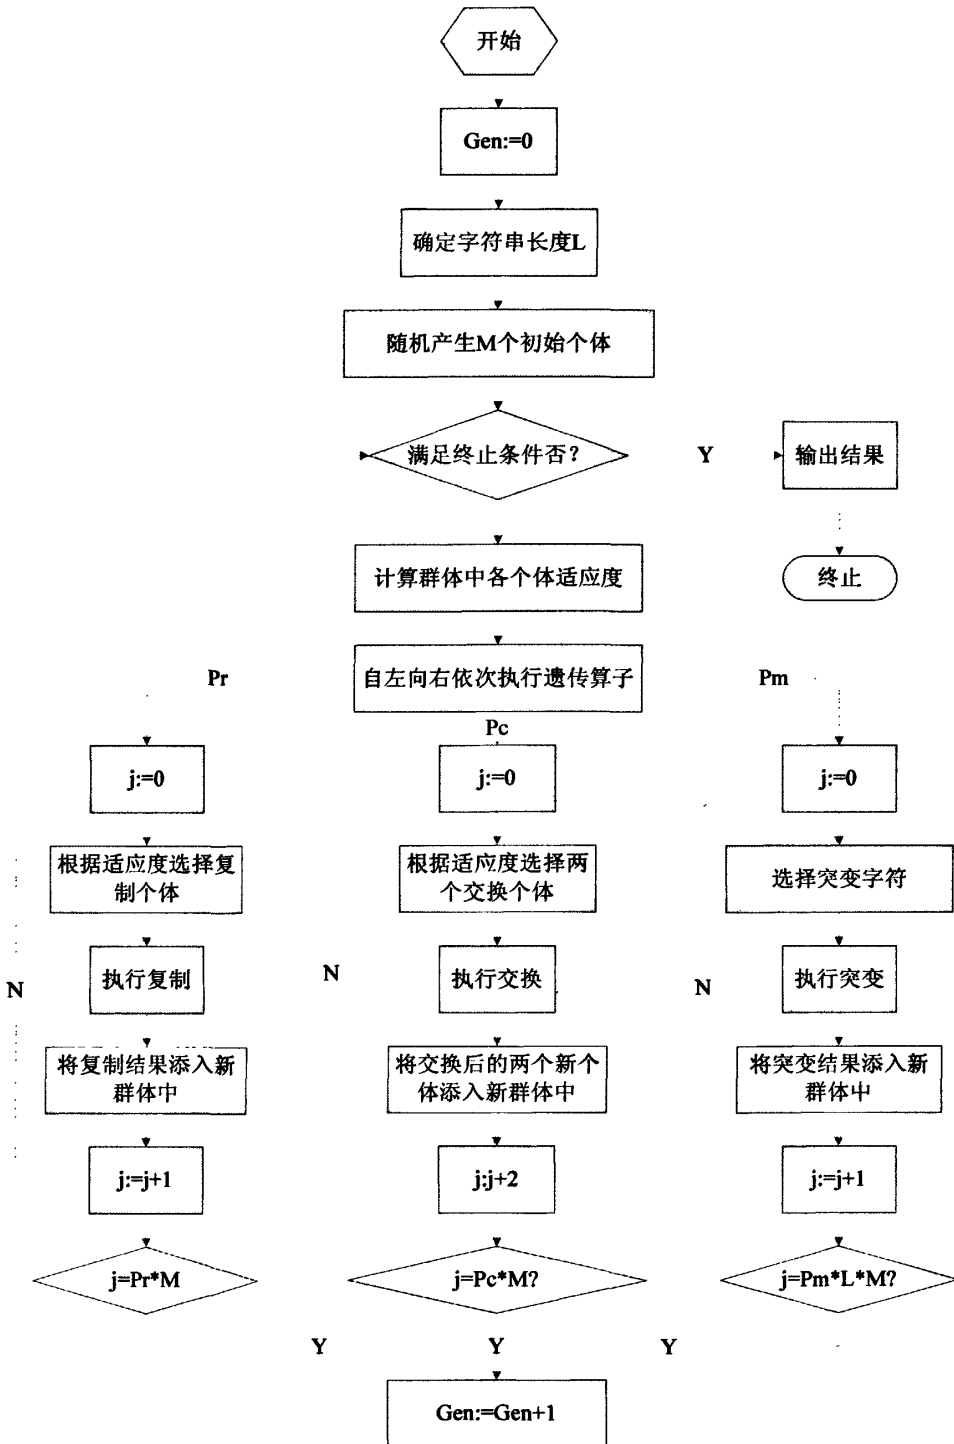


图2-1 遗传算法流程图

Fig2-1 The flow chart of GA

连续可微的约束,而且其定义域可以任意设定。这一特点使得遗传算法的应用范围大大扩展。(4)遗传算法不是采用确定性规则,而是采用概率的变迁规则来指导他的搜索方向。(5)具有自组织、自适应和自学习性。遗传算法利用进化过程获得的信息自行组织搜索时,适应度大的个体具有较高的生存概率,并获得更适应环境的基因结构。

缺点:(1)标准遗传算法有:初期的未成熟收敛、后期搜索迟钝;重要参数如 n (群体规模)、 P_s (选择概率)、 P_c (交叉概率)、 P_m (变异概率) 如何选择。(2)交叉和变异算子如何协调工作,局部搜索能力较弱,单一的群体更新方式难以兼顾多样性和收敛性的要求,收敛速度较慢等问题。(3)鉴于遗传算法的并行性和它在算法结构上的特点,可以很容易地将遗传算法和其它算法混合使用,从而达到扬长避短的作用。其中遗传算法和模拟退火算法的混合在复杂函数最优化问题中得到了重视。但是传统的遗传退火算法在继承了遗传、模拟退火算法优点的同时,仍然难以完全克服遗传算法及模拟退火算法的缺点,如搜索效率不高,可能出现早熟等。

2.2.4 遗传算法的改进方法

由于遗传算法具有开放式的结构,与问题的关联性不大,很容易和其它算法进行结合,所以融合了其它的算法思想和遗传算法思想的混合遗传算法成了目前改进遗传算法研究的一个重要方向。现将比较常见的混合遗传算法介绍如下。

模拟退火遗传算法:模拟退火算法的基本思想是通过模拟高温物体退火过程的方法来找到优化问题的全局最优或近似全局最优解。从统计物理学的观点看,随着温度的降低,物质的能量将逐渐趋近于一个较低的状态,并最终达到某种平衡。遗传算法的局部搜索能力较差,但把握搜索过程总体的能力较强;而模拟退火算法具有较强的局部搜索能力,并能使搜索过程避免陷入局部最优解,但它却对整个搜索空间的了解不多,不便于使搜索过程进入最有希望的搜索区域,从而使得模拟退火算法的运算效率不高。但如果将遗传算法和模拟退火算法相结合,互相取长补短,则有可能开发出性能优良的新的全局搜索算法。目前,已有许多学者将退火机制引入到遗传操作中,使遗传操作产生优良个体的概率增加,并使遗传算法的寻优能力有了明显的提高。

免疫遗传算法:人工免疫算法受生物免疫系统原理的启发,针对求解问题特征进行人工疫苗接种,可充分利用问题本身的信息。和遗传算法结合时,遗传算法的全局搜索能力及免疫算法的局部优化相配合,可大大提高搜索效率。我们可以通过注射疫苗的方法来减少遗传操作的盲目性,加强遗传算法收敛性能,多次的测试结果证明了该改进方

法的有效性。

小生境遗传算法：生物学上，小生境指在特定环境中的一种组织功能，它将每一代个体划分为若干类，每个类中选出若干适应度较大的个体作为一个类的优秀代表，组成一个新种群，再在同一种群中以及不同种群之间进行杂交、变异，产生新一代个体群，同时采用预选择机制或排挤机制或共享机制完成选择操作。解空间中峰周围的子空间中的个体具有相对独立生长繁衍的特性。常用的小生境遗传算法大多在对群体进行选择操作前，计算个体之间的海明距离，如小于事先设定值，则对适应值低的个体处以罚函数，降低其适应值。这样可以保护解的多样性，也可以避免大量重复的解充斥整个解空间。用小生境思想来实现遗传算法的选择操作，使遗传算法的全局寻优能力得到了明显提高。

模糊遗传算法：模糊遗传算法，即融合模糊优化设计思想的遗传算法，它把模糊优化和遗传算法优化结合起来，构成一种混合优化的设计方法。其目的是利用模糊优化设计的优点，克服一般遗传算法优化设计存在的不足，从而使得系统的优化设计更灵活、方便，取得更好的设计效果。首先，在模糊遗传算法中引入“论域”的概念。在这里，“论域”即指用隶属函数来表示遗传算法的优化过程中所采用的约束条件的区间范围。用隶属函数来表示遗传算法的约束条件，以使约束条件能够更容易得到表达，又能够保证遗传子代的选择中能够拥有更广泛的群体组成。其次，在模糊遗传算法中，采用权变理论中的以变应变的思想。模糊遗传算法运用模糊控制的思想来自适应改变遗传算法的种群规模、交叉概率、变异概率、适应度函数以及控制策略等。

混沌遗传算法：混沌是自然界广泛存在的一种非线性现象，它充分体现了系统的复杂性。混沌运动具有类似随机变量的杂乱表现，具有随机性；混沌能在一定范围内按其自身特性不重复地历经所有状态，具有遍历性；初值条件极其微弱的变化会引起混沌系统行为的巨大变化，具有对初始条件的极度敏感性。混沌运动的上述性质作为避免陷入局部极小的优化搜索机制，恰好可以弥补遗传算法易陷入局部最优、收敛速度慢的缺陷。可以利用混沌的遍历性产生初始种群，也可以运用混沌的遍历性对优良个体进行变异操作，混沌遗传算法增强了遗传算法的全局寻优能力。

量子遗传算法：量子遗传算法是量子计算思想与遗传算法结合的产物。与遗传算法类似，它也是一个产生-检验的过程，但其实现跟标准遗传算法不一样。在表达方式上，量子遗传算法将量子的态矢量表述引入染色体编码；在演化机制上，它利用量子门实现染色体演化。这些区别，使得量子遗传算法表现出比标准遗传算法更好的种群多样性、

更强的全局搜索能力和更快的收敛速度。

还有其它的算法已被引入到遗传算法中来（如禁忌-并行、分层等），在此，就不再过多介绍。遗传算法与其它算法和理论的结合已经成为改进遗传算法的一个非常有效的手段。

2.2.5 遗传算法的应用

由于遗传算法的整体搜索策略和优化搜索方法在计算上不依赖于梯度信息或其它辅助知识，而只需要影响搜索方向的目标函数和相应的适应度函数，所以遗传算法提供了一种求解复杂系统问题的通用框架，它不依赖于问题的具体领域，对问题的种类有很强的鲁棒性，所以广泛应用于许多科学，下面我们将介绍遗传算法的一些主要应用领域：

1、 函数优化。

函数优化是遗传算法的经典应用领域，也是遗传算法进行性能评价的常用算例，许多人构造出了各种各样复杂形式的测试函数：连续函数和离散函数、凸函数和凹函数、低维函数和高维函数、单峰函数和多峰函数等。对于一些非线性、多模型、多目标的函数优化问题，用其它优化方法较难求解，而遗传算法可以方便的得到较好的结果。

2、 组合优化

随着问题规模的增大，组合优化问题的搜索空间也急剧增大，有时在目前的计算上用枚举法很难求出最优解。对这类复杂的问题，人们已经意识到应把主要精力放在寻求满意解上，而遗传算法是寻求这种满意解的最佳工具之一。实践证明，遗传算法对于组合优化中的 NP 问题非常有效。例如遗传算法已经在求解旅行商问题、背包问题、装箱问题、图形划分问题等方面得到成功的应用。

此外，GA 也在生产调度问题、自动控制、机器人学、图象处理、人工生命、遗传编码和机器学习等方面获得了广泛的运用。

2.3 进化策略综述

2.3.1 进化策略的发展历程

进化策略（ES）经历了从 $(1+1)$ -ES到 $(\mu+1)$ -ES，再到 $(\mu+\lambda)$ -ES和 (μ,λ) -ES, $(\mu/\rho+\lambda)$ -ES和 $(\mu/\rho,\lambda)$ -ES的演变发展过程。

1. $(1+1)$ -ES

1963 年，德国柏林技术大学的 I.Rechenberg 和 H.P.Schwefel 为了研究风洞中的流体

力学问题,提出了进化策略(Evolution Strategies, 简称 ES)。当时提出的这种优化方法只有一个个体,并由此衍生同样仅为一个的下一代新个体,故称为(1+1)-ES。

进化策略中的个体用传统的十进制实型数表示,即:

$$X^{t+1}=X^t+N(0,\sigma) \quad (2-1)$$

式中 X^t ——第 t 代个体的数值;

$N(0,\sigma)$ ——服从正态分布的随机数,其均值为零,标准差为 σ 。

因此,进化策略中的个体含有两个变量,为二元组 $\langle X, \sigma \rangle$ 。新个体的 X^{t+1} 是在旧个体 X^t 的基础上添加一个独立随机变量 $N(0, \sigma)$ 。假若新个体的适应度优于旧个体,则用新个体代替旧个体;否则,舍弃性能欠佳的新个体,重新产生下一代新个体。在进化策略中,个体这种进化方式称作突变。很明显,突变产生的新个体与旧个体性态差别不大,这符合生物进化的基本状况,因为生物的微小变化总是多于急剧变化。

2. $(\mu+1)$ -ES

早期的(1+1)-ES,没有体现出群体的作用,只是单个个体在进化,具有明显的局限性。随后,Rechenberg又提出 $(\mu+1)$ -ES,在这种进化策略中,父代有 μ 个个体($\mu>1$),并且引入重组(Recombination)算子,是父代个体组合出新的个体。在执行重组时,从 μ 个父代个体中用随机的方法任选两个个体:

$$\begin{cases} (X^1, \sigma^1) = ((x_1^1, x_2^1, \dots, x_n^1), (\sigma_1^1, \sigma_2^1, \dots, \sigma_n^1)) \\ (X^2, \sigma^2) = ((x_1^2, x_2^2, \dots, x_n^2), (\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)) \end{cases} \quad (2-2)$$

然后从这两个个体中组合出如下新个体:

$$(X, \sigma) = ((x_1^{q_1}, x_2^{q_2}, \dots, x_n^{q_n}), (\sigma_1^{q_1}, \sigma_2^{q_2}, \dots, \sigma_n^{q_n})) \quad (2-3)$$

式中 $q_i=1$ 或 2 ,它以相同的概率针对 $i=1,2,\dots,n$ 随机选取。

对重组产生的新个体执行突变操作,突变方式及 σ 的调整与(1+1)-ES相同。

将突变后的个体与父代 μ 个个体相比较,若优于父代最差个体,则代替后者成为下一代 μ 个个体新成员;否则,重新执行重组和突变产生另一个新个体。

$(\mu+1)$ -ES和(1+1)-ES具有相同的策略:只产生一个新个体。 $(\mu+1)$ -ES的特点在于:

- (1) 采用群体,其中包含 μ 个个体;
- (2) 增添重组算子,它相当于遗传算法中的交换算子,从父代继承信息构成新个体。

显然, $(\mu+1)$ -ES比(1+1)-ES有了明显的改进,为进化策略这种新的进化算法奠定了良好基础。

3. $(\mu+\lambda)$ -ES、 (μ,λ) -ES

1975年, Schwefel首先提出 $(\mu+\lambda)$ -ES, 随后又提出 (μ,λ) -ES。这两种进化策略都采用含有 μ 个个体的父代群体, 并通过重组和突变产生 λ 个新个体。它们的差别仅仅在于下一代群体的组成上。 $(\mu+\lambda)$ -ES是在原有 μ 个个体及新产生的 λ 个新个体中(共 $\mu+\lambda$ 个个体)再择优选择 μ 个个体作为下一代群体。 (μ,λ) -ES则是只在新产生的 λ 个新个体中择优选择 μ 个个体作为下一代群体, 这时要求 $\lambda>\mu$ 。总之, 在选择子代新个体时若需要根据父代个体的优劣进行取舍, 则使用“+”记号, 如 $(1+1)$ 、 $(\mu+1)$ 及 $(\mu+\lambda)$; 否则, 改用逗号分隔, 如 (μ,λ) 。

4. $(\mu/\rho+\lambda)$ -ES、 $(\mu/\rho,\lambda)$ -ES

具有重组算子的ES, $\rho \in \{1,2,\dots,\mu\}$, 表示参加重组的个体数量, $\rho=1$ 表示不重组。ES的重组有离散重组 (discrete combination, 也称为优势重组, dominant recombination) 和中间重组 (intermediate recombination)。 $(\mu/\rho+\lambda)$ -ES由于表示的灵活性, 可作为基本ES的通用表示方法称为CES (classical evolution strategies)。以下将以 $(\mu+\lambda)$ -ES泛指基本ES。

2.3.2 基本进化策略描述

图中 Gen 表示进化的代数, 在第 0 代, 根据问题表达是二元组或三元组方式, 随机产生 μ 个初始个体, 并计算它们的适应度。然后依次执行重组和突变操作, 产生新个体。图中 j 统计新个体数目, 重组和突变执行 λ 次, 产生 λ 个新个体。随后计算新个体的适应度, 再根据选择策略, 从 $(\mu+\lambda)$ 个个体中或 λ 个新个体中选择 μ 个个体组成新群体。这样, 便完成一代进化。重复这种进化过程, 直至满足终止条件。

进化策略最初并不仅使用连续参变量进行优化, 离散参变量也被使用, 例如在 1970 年, Klockgether 和 Schwefel 便采用离散的实变量作为变异参量应用进化策略进行优化问题的求解。现在普遍采用的在连续的欧式空间进行优化的思想, 这主要归结于 1973 年 Rechenberg 成功地应用了连续参变量的变异。

设 $f: R^n \rightarrow R$ 是一个求最大值的优化问题, 即

$$\max_{x \in R^n} f(x)$$

其中, $x \in X$ 是一个 n 维的目标参向量, $x=(x_1,\dots,x_n)^T$

在进化策略中的变异方法采取如下方式:

$$X_{t+1}=x_t+\sigma_t Z_t \quad (2-4)$$

其中, $t \in \mathbb{N}$, \mathbf{x}_0 是随机选取的初始值, σ_i 是大于 0 的常数, 称为调整系数, 用来改变变异的速度。 Z_i 是服从于正态分布 $N(0,1)$ 的相互独立的随机向量。

1、问题表达

(1) 二元表达方式。这种表达方式中个体有目标变量 X 和标准差 σ 两部分组成, 每部分又可以有 n 个分量, 即:

$$(X, \sigma) = ((x_1, x_2, \dots, x_i, \dots, x_n), (\sigma_1, \sigma_2, \dots, \sigma_i, \dots, \sigma_n)) \quad (2-5)$$

X 和 σ 之间的关系是:

$$\begin{cases} \sigma'_i = \sigma_i \exp(\tau' N(0,1) + \tau N_i(0,1)) \\ x'_i = x_i + N_i(0,1) \end{cases} \quad (2-6)$$

式中 (x_i, σ_i) ——父代个体的第 i 个分量;

(x'_i, σ'_i) ——子代新个体的第 i 个分量;

$N(0,1)$ ——服从标准正态分布的随机数;

$N_i(0,1)$ ——针对第 i 分量重新产生一次符合标准正态分布的随机数

τ' ——全局系数, 常取 1;

τ ——局部系数, 常取 1。

(2-6)式表明, 新个体是在旧个体基础上随机变化而来。

二元表达方式简单易行, 得到广泛的应用。

(2) 三元表达方式。为了改善进化策略的收敛速度, Schwefel 在二元表达的基础上引入第三个因子——坐标旋转角度 σ 。个体的描述扩展为 (X, σ, α) , 即:

$$(X, \sigma, \alpha) = ((x_1, x_2, \dots, x_i, \dots, x_n), (\sigma_1, \sigma_2, \dots, \sigma_i, \dots, \sigma_n), (\alpha_1, \alpha_2, \dots, \alpha_i, \dots, \alpha_n)) \quad (2-7)$$

三者的关系是:

$$\begin{cases} \sigma'_i = \sigma_i \exp(\tau' N(0,1) + \tau N_i(0,1)) \\ \alpha'_j = \alpha_j + \beta N_j(0,1) \\ x'_i = x_i + z_i \end{cases} \quad (2-8)$$

式中 α_j ——父代个体 i 分量与 j 分量间坐标的旋转角度;

α'_j ——子代新个体 i 分量与 j 分量间坐标的旋转角度;

β ——系数, 常取 0.0873;

z_i ——取决于 σ' 及 α' 的正态分布随机数。

其余符号同(2-6)

旋转角度 α_j 表面上是分量 i 与 j 间坐标的旋转角度，实质上它是分量 i 与分量 j 之间协方差的体现。随机数 z_i 服从正态分布，其数学期望为零，其方差 σ_α^2 取决于突变方差 α^2 及旋转角度 α 。

2、产生初始群体

进化策略中初始群体由 μ 个个体组成，每个个体 (X, σ, α) 内又可以包含 n 个 x_i 、 σ_i 分量及 $\frac{n(n-1)}{2}$ 个 α_j 分量。产生初始个体的方法是随机生成。为了便于和传统的方法比较，可以从某一初始点 $(X(0), \sigma(0), \alpha(0))$ 出发，通过多次突变产生 μ 个初始个体，该初始点从可行域中用随机方法选取。

初始个体的标准差 $\alpha(0)$ ，可用下式计算：

$$\sigma(0) = \Delta X / \sqrt{n} \quad (2-9)$$

式中 ΔX —— 初始点与最优点的距离；

n —— 个体中所含分量个数。

由于 ΔX 在初始时不便确定，可取 $\alpha(0)=3.0$ 。 $\alpha(0)$ 不易取太大，若 $\alpha(0)$ 太大而且 μ 也大时，选择力度不够，易使群体过于分散。尽管 $\alpha(0)$ 较小，但在进化过程中通过个体的自适应调整仍可使搜索点很快散布在整个可行域内。

3、适应度计算

适应度是衡量个体优劣的尺度。由于进化策略采用十进制的实数表达问题，因此适应度的计算更加直观、简便。相对于遗传算法，进化策略中的适应度计算更易于执行。

进化策略中对于约束条件的处理，主要是采用重复试凑法。每当新个体生成，将其代入约束条件中检验是否满足约束条件。若满足，则接纳新个体；否则，舍弃该新个体，借助重组、突变再产生另一个新个体。由于进化策略采用实数编码，这种检验比较直观和简单易行。

4、重组

进化策略中的重组(Recombination)算子相当于遗传算法的交换，它们都是以两个父代个体为基础进行信息交换。进化策略中，重组方式主要有三种：

(1) 离散重组。先随机选择两个父代个体

$$\begin{cases} (X^1, \sigma^1) = ((x_1^1, x_2^1, \dots, x_n^1), (\sigma_1^1, \sigma_2^1, \dots, \sigma_n^1)) \\ (X^2, \sigma^2) = ((x_1^2, x_2^2, \dots, x_n^2), (\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)) \end{cases} \quad (2-10)$$

然后将其分量进行随机变换，构成子代新个体的各个分量，从而得出如下新个体：

$$(X, \sigma) = ((x_1^{q_1}, x_2^{q_2}, \dots, x_n^{q_n}), (\sigma_1^{q_1}, \sigma_2^{q_2}, \dots, \sigma_n^{q_n})) \quad (2-11)$$

式中 $q_i=1$ 或 2。新个体的分量是从两个父代个体随机选取, 而且 x_i 分量的 q_i 不一定要等于 σ_i 分量的 q_i 。

(2) 中值重组。这种重组方式也是先随机选择两个父代个体如式(2-10)然后将父代个体各分量的平均值作为子代新个体的分量, 构成的新个体为:

$$(X, \sigma) = ((x_1^1 + x_1^2)/2, (x_2^1 + x_2^2)/2, \dots, (x_n^1 + x_n^2)/2), ((\sigma_1^1 + \sigma_1^2)/2, (\sigma_2^1 + \sigma_2^2)/2, \dots, (\sigma_n^1 + \sigma_n^2)/2) \quad (2-11)$$

这时, 新个体的各个分量兼容两个父代个体信息, 而在离散重组中则只含有某一个父代个体的因子。

(3) 混杂重组。这种重组方式的特点在于父代个体的选择上。混杂重组时先随机选择一个固定的父代个体, 然后针对子代个体每个分量再从父代群体中随机选择第二个父代个体。也就是说, 第二个父代个体是经常变化的。至于父代两个个体的组合方式, 既可以采用离散方式, 也可以采用中值方式, 甚至可以把中值重组中的 $1/2$ 改为 $[0,1]$ 之间的任一权值。

5、突变

进化策略的突变是在旧个体基础上添加一个随机量, 从而形成新个体。突变的过程为:

$$\begin{cases} \sigma'_i = \sigma_i \exp(\tau' N(0,1) + \tau N_i(0,1)) \\ \alpha'_j = \alpha_j + \beta N_j(0,1) \\ x'_i = x_i + z_i \end{cases} \quad (2-12)$$

式中系数 τ' 、 τ 及 β 按 Schwefel 建议, 可按下式计算:

$$\begin{aligned} \tau &= (\sqrt{2\sqrt{n}})^{-1} \\ \tau' &= (\sqrt{2n})^{-1} \\ \beta &\approx 0.0873 \end{aligned}$$

式中 n ——个体中所含分量数目。

τ' 、 τ 分别为全局步长系数及局部步长系数, 用于对随机量 $N(0,1)$ 进行缩放, 它们相当于人工神经网络中的“学习率”。通常, τ' 及 τ 取为 1。系数 β 涉及旋转角度, 建议取 5 度, 按弧度计算则为 $\pi*5/180 \approx 0.0873$ 。调整 τ' 、 τ 及 β 数值最终影响目标变量 X 。

若取消旋转因子, 进化策略的表达式由三元组变为二元组, 则突变转化为:

$$\begin{cases} \sigma'_i = \sigma_i \exp(\tau' N_i(0,1) + \tau N_i(0,1)) \\ x'_i = x_i + \sigma'_i N_i(0,1) \end{cases} \quad (2-13)$$

若进一步简化, σ_i 都相同时, 上式变为:

$$\begin{cases} \sigma' = \sigma \exp(\tau_0 N_i(0,1)) \\ x'_i = x_i + \sigma' N_i(0,1) \end{cases} \quad (2-14)$$

式中 $\tau_0 = 1/\sqrt{n}$ 。

这也就是进化策略最简单的突变。

进化策略在进行突变时, 一要防止 σ_i 在进化过程中变为零, 从而使 x_i 的进化停止; 另一个是防止旋转角 σ_j 在可行域 $[-\pi, \pi]$ 之外。为此, 要经常检查 σ_i 及 σ_j , 使之符合规定。

6、选择

进化策略中的选择 (Selection) 类似于遗传算法的复制, 它们都体现达尔文的“物竞天择、适者生存”的原则。但是, 进化策略中的选择是确定型操作, 它严格根据适应度的大小, 将劣质个体完全淘汰。选择中不采用轮盘法那种随机方式, 而是使优良个体 100% 的被保留, 劣质个体 100% 的被淘汰。

2.3.3 进化策略流程

基本进化策略的流程如图2-2:

2.3.4 算法优缺点

优点: (1) 进化策略在确定了编码方案, 适应值函数及遗传算子以后, 算法将根据“适者生存, 不适应者淘汰”的策略, 利用进化过程中获得的信息自行组织搜索, 从而不断地向最佳解方向逼近。(2) 进化策略是首先采用自适应机制的进化算法, 它的搜索初始点最初使用的是单一的初始点, 这种方式的进化策略已基本不再使用, 现在普遍使用的进化策略算法也是采用初始群体作为搜索的初始点。(3) 进化策略构造简单、易于实现, 可以采用嵌套方式来应用这一算法。(4) 具有典型的动力学特征, 特别是在 ONE-MAX(1+1) 问题上, 已经有了肯定的结论。

缺点: (1) 每一维的常数的标准偏差 (平均步长) 使收敛最优值的速度变慢; (2) 点对点搜索的不稳定性可能造成停止于局部最小值。

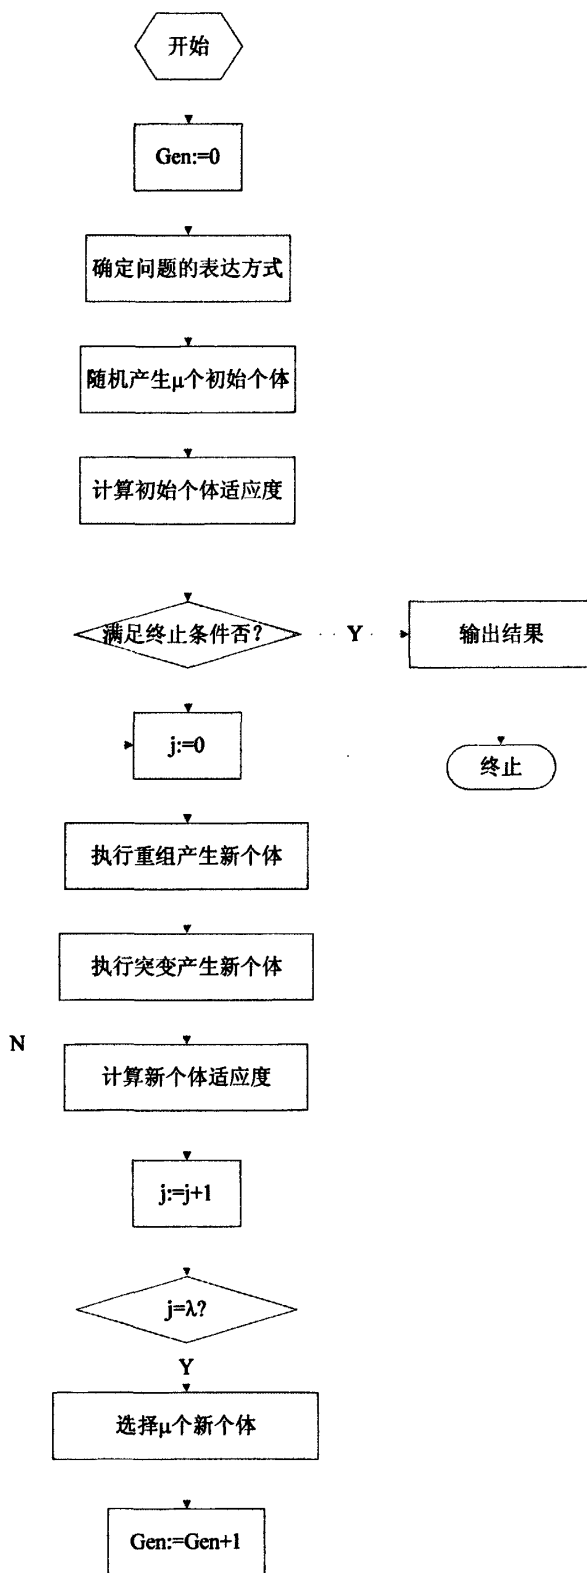


图2-2 进化策略流程图

Fig2-2 The flow chart of ES

2.3.5 进化策略的改进方法

进化策略的演变过程是ES从(1+1)-ES到 $(\mu/\rho+\lambda)$ -ES和 $(\mu/\rho,\lambda)$ -ES, 另外, 专家们从各个角度对进化策略进行了改进。主要是从重组算子, 变异算子和种群规模上加以改进。

(1)改进重组算子:

Kursawe^[13]研究了重组对收敛速度、收敛可靠性的影响, 并把 n_σ 也纳入自适应的参数, 甚至设想把学习率参数 τ 和 τ' 也作为遗传基因参加进化。L. Gruenz^[14]等用球模型函数试验研究了有 σ 自适应(σ SA: σ self-adaptive)和无自适应 $(\mu/\rho,\lambda)$ -ES, 表明 σ SA并不是总能够引导搜索进程指向所希望的区域, 而进化性能对学习率参数 τ 和 τ' 比较灵敏。

Back^[15]等试验了 $\rho=2$ 和 $\rho=\mu$ 时的中间重组效果, 然后通过一组测试函数试验, 表明这两种情况得出的结果并不一致, 只是比无重组的ES提高了收敛速度。另外文献^[16,17]对离散重组和中间重组作了大量对比试验后, 得出结论, 对于大多数情况, 目标变量和策略参数同时使用离散重组, 可以获得鲁棒性。

重组算子的作用机理缺乏理论指导, 而相关的试验结果也相互不一致, 导致可推广性较弱。目前支持重组算子使用的两种理论, 一种是积木块假设BBH(building block hypothesis)^[18,19], 认为不同父个体的优良基因在一起组合, 产生的后代也将同时具有这些优良特性, 但BBH本身也颇受争议; 另一种为遗传修复GR (genetic repair)假设^[20,21], 这一理论与BBH有点相反, 认为重组并不使不同父个体所期望的特征组合到子代, 而是提取它们共同的特征, 所以, 重组是从父代提取它们相似的部分, 对于中间重组算子的遗传修复功能尤其明显。

(2)变异算子的改进:

C. A. Magele^[22]等提出引入所谓“灾难理论”(theory of disaster), 为了提高全局搜索能力以及增大跳出局部极值点的概率, 每隔一定的正常进化代(如100代)后, 用显著增大的变异步长进化若干代(3代)。Kappler^[23]受快速模拟退火原理启发, 引入了Cauchy变异代替(1+1)-ES中的Gauss变异, 发现该方法在处理一维函数优化问题时具有较强的鲁棒性; 姚新等^[24]把Cauchy变异推广到 (μ,λ) -ES, 用一组测试函数做对比试验研究, 结果表明, Cauchy变异具有较强的全局搜索能力, 而局部搜索能力有所下降; 林丹等^[25]从理论上分析比较了Gauss变异、Cauchy变异、均匀变异(uniform mutation)的局部和全局搜索能

力,证明了Gauss变异局部搜索能力最强,均匀变异的全局搜索能力最强,而Cauchy变异的局部和全局搜索能力都居中。王云诚等^[26]用均匀变异算子求解单峰函数,研究了其步长控制策略。刘若辰等^[27]用基于细胞克隆选择学说的克隆算子和Cauchy变异算子改进了ES。 σ SA-ES的步长不能很好地跟踪进化进程^[28],王战权等^[29]试验了变异步长使用对数Cauchy分布。Hashem^[30]提出一种种群年龄函数控制的变异步长,但对不同函数,往往需要不同的变异步长控制方法,使这种方法缺乏灵活性。还有文献^[31,32]提出通过强化学习实现步长的自适应以及通过比较变异成功与否,确定变异的方向,引入非对称概率密度函数实现有向变异^[33,34,35]。文献^[36]提出二方式变异法(two-way mutation),通过试探,改变变异方向和变异步长,取得了良好的效果。

(3)种群规模改进:

在进化算法中,种群多样性的维持是保证全局搜索能力的重要前提,种群规模对ES的多样性具有直接的影响,种群规模大,容易维持多样性,但也会增加个体排序的时间消耗。N. Hansen等^[37]根据进化进程而动态改变种群规模,减小了计算消耗,文献^[38]通过试验研究 λ 维持不变时, λ/μ 比率对ES进化效率的关系,提出自适应改变父种群规模产的策略,L.Schoneman^[39]研究了在动态环境下,种群规模的自适应方法及对种群多样性的影响。种群多样性的维持和选择压的充分性是相互矛盾的两个方面^[40],由于在进化进程中,遗传漂移的作用,使种群朝某个方向漂移而丧失多样性,多种群技术是抑制遗传漂移、维持种群多样性的有效方法^[41]。与多种群GA比较,多种群ES的研究要薄弱的多,大多借鉴GA提出的的原理,如适应值共享、排挤等。在ES中引入多种群技术的研究大都仅仅是为了增强全局搜索能力^[42,43,44],用于求多模态函数多个全局最优解和局部解的ES文献较少^[45]。

2.3.6 进化策略的应用

ES最初被用于连续函数优化,表现出较好的性能,当前,ES在离散组合优化^[46,47,48]、多目标优化^[49,50]、约束优化^[51,52]、含噪声的优化^[53]、并行计算^[54,55,56]等方面也得到了应用。在GA有应用的领域,几乎都可以看到ES的应用。

2.4 遗传算法与进化策略的比较

相同:两者都体现生物进化过程中的“物竞天择、优胜劣汰”的原则,从随机产生的初始可行解出发,经过进化择优,逐渐逼近最优解;两者都是渐进式搜索寻优,经过

多次的反复迭代，不断扩展搜索范围，最终找出全局最优解；两种进化算法都是采用群体的概念。

差别：进化策略源于函数优化处理，它是一种类似于爬山问题的优化方法，方差 σ 相当于爬山的步长，旋转角 α 可比作山坡坡角。遗传算法起源于自适应搜索，强调全方位探查；算子的差别，进化策略的重组算子，不仅可以复制父代个体的部分信息，而且还可以通过中值计算产生新的信息。而遗传算法的交换算子，仅仅是交换父代个体的部分字符，不能产生新的字符。进化策略的突变是在旧个体基础上添加一个正态分布的随机数，从而产生新个体。遗传算法的突变是对旧个体的某个字符进行补运算，将 0 变成 1 或将 1 变成 0。突变是进化策略的主要进化手段。选择是进化策略和遗传算法差别最明显的一种操作。进化策略从 λ 个新个体或从 $(\mu+\lambda)$ 个个体中挑选 μ 个个体组成新群体，而且挑选方法是确定型的。遗传算法的选择体现在复制中，从旧群体中择优插入新群体，挑选方法是随机的轮盘法，优良个体入选率高，但劣质个体有时也会“破例”入选；执行的顺序，进化策略先执行重组，随之为交换，最后是选择。遗传算法先执行选择及复制，其次为交换，最后是突变；参数的差别。遗传算法中的复制概率 p_r 、交换概率 p_c 及突变概率 p_m ，它们在运行过程中原则上是固定的。进化策略的控制因子包括标准差 σ 及旋转角度 α ，它们在运行过程中不断发生自适应调整。

相互借鉴：进化策略和遗传算法作为进化算法的两个分支，是独立出现及平行发展的，在长期实践中它们又相互借鉴，不断完善。在问题的表达方式上，遗传算法已从原来的二进制编码扩展为用十进制实数表达问题，并相应改变突变等算子。在算子方面，最早的进化策略只有突变算子，然后才添加重组算子，这是进化策略借鉴遗传算法中的交换算子。对于突变算子，遗传算法不如进化策略那样重视，通常突变概率 p_m 的取值都很小(0.01)。近年来不少人提高突变概率， p_m 取值达 0.2。遗传算法的交换算子也有向进化策略的重组算子靠拢的迹象。例如，有人建议交换算子采用下述线性组合。

$$\begin{aligned} y_1 &= \alpha x_1 + (1-\alpha)x_2 \\ y_2 &= (1-\alpha)x_1 + \alpha x_2 \end{aligned} \quad (2-15)$$

式中 y_1 、 y_2 ——新个体的目标变量分量；

x_1 、 x_2 ——旧个体的目标变量分量；

α ——系数，介于[0,1]。

实质上这种交换就是进化策略的广义中值重组。

在参数的自适应调整方面，进化策略的这一特征也开始渗透到遗传算法中。例如，遗传算法中的群体规模 M 、突变概率 p_m 已不再是常数，它们可随时间而变化。又如，有人提出在遗传算法内再运行一个参数遗传算法，后者负责调整遗传算法的操作参数。进化策略和遗传算法的相互借鉴是科学发展的正确途径。

第三章 模糊理论知识

3.1 模糊集理论

在经典集合论中，论域 U 上的一个普通集合 A 定义为 U 中某些元素 x 组成的群体。每一个元素或者属于集合 A ，或者不属于集合 A 。这样的集合可以有多种表达方式：列举集合中的元素；通过一系列等式和不等式对集合进行描述。然而在很多情形下这种隶属关系并不是很明确的。例如，“老人”、“著名”、“相似”、“满意”、“大数”、“大约等于 10”等。经典集合论对这种情形并不适用。为了处理这类问题，我们引入模糊集的概念。

定义 3.1 (Zadeh^[57]): 设 U 为论域。 A 为 U 的一个子集，对任意元素 $x \in U$ ，函数 $\mu_A: U \rightarrow [0,1]$ 指定了一个值 $\mu_A(x) \in [0,1]$ 与之对应。 $\mu_A(x)$ 在元素 x 处的值反映了元素 x 属于 A 的程度，我们称集合 A 为模糊子集，而 $\mu_A(x)$ 称为 A 的隶属函数，也就是说， $\mu_A(x)$ 的值越大，元素 x 属于 A 的程度也就越高。

如今，模糊集理论已经得到长足的发展，模糊技术几乎渗透到了所有领域。特别地，Kaufmann^[58]首先提出了模糊变量的概念，之后出现在文献 Zadeh^[59,60]和 Nahmias^[61]中。可能性理论由 Zadeh^[62]提出，许多学者如 Dubois 和 Prade^[67]对其发展起了重要作用。为了发展一套类似于概率论的公理系统，最近 Liu 给出了完善的研究模糊性的公理体系，称之为可信性理论。

模糊集合论就是一门研究模糊信息的数学分支学科。过去，人们一直认为在模糊集合论中可能性测度扮演了概率测度的角色。然而，事实并非如此。与概率测度对应的应该是可信性测度。

假设 θ 为非空集合， $P(\theta)$ 表示 θ 的幂集。如下四条公理构成了可信性理论的公理化基础

公理1 $\text{Pos}\{\theta\}=1$;

公理2 $\text{Pos}\{\emptyset\}=0$;

公理3 对于 $P(\theta)$ 中的任意集合 $\{A_i\}$ ， $\text{Pos}\{\bigcup_i A_i\} = \sup \text{Pos}\{A_i\}$;

公理4 如果 θ_i 是非空集合，其上定义的 $\text{Pos}_i\{\cdot\}$ 满足前三条公理， $i=1, 2, \dots, n$ ，并且 $\theta = \theta_1 \times \theta_2 \times \dots \times \theta_n$ ，则对于每个 $A \in P(\theta)$ ，

$$\text{Pos}\{A\} = \sup \text{Pos}_1\{\theta_1\} \wedge \text{Pos}_2\{\theta_2\} \wedge \dots \wedge \text{Pos}_n\{\theta_n\} \quad (\theta_1, \theta_2, \dots, \theta_n) \in A$$

记作 $\text{Pos} = \text{Pos}_1 \wedge \text{Pos}_2 \wedge \dots \wedge \text{Pos}_n$ 。如果 Pos 满足前三条公理，则称为可能性测度，三元组 $(\theta, P(\theta), \text{Pos})$ 称为可能性空间。为了定义乘积可能性测度，Liu^[63]给出了第四条公理，并且证明了 $\text{Pos} = \text{Pos}_1 \wedge \text{Pos}_2 \wedge \dots \wedge \text{Pos}_n$ 满足前三条公理。这四条公理构成了可信性理论的基础，使得可信性理论的所有内容均可通过其导出。Liu^[64]已经成功建立了可信性公理化体系，丰富了模糊数学的理论底蕴。

定义 3.2 假设 θ 为非空集合， $P(\theta)$ 是 θ 的幂集。如果 Pos 满足前三条公理，则称为可能性测度。

定义 3.3 假设 θ 为非空集合， $P(\theta)$ 是 θ 的幂集。如果 Pos 是可能性测度，则三元组 $(\theta, P(\theta), \text{Pos})$ 称为是可能性空间。

定义 3.4 (Liu^[65]) 假设 $(\theta_i, P(\theta_i), \text{Pos}_i)$, $i=1,2,\dots,n$, 是可能性空间。如果 $\theta = \theta_1 \times \theta_2 \times \dots \times \theta_n$, $\text{Pos} = \text{Pos}_1 \wedge \text{Pos}_2 \wedge \dots \wedge \text{Pos}_n$, 那么 $(\theta, P(\theta), \text{Pos})$ 称为 $(\theta_i, P(\theta_i), \text{Pos}_i)$, $i=1,2,\dots,n$, 的乘积可能性空间。

定义 3.5 假设 $(\theta, P(\theta), \text{Pos})$ 是可能性空间， A 是幂集 $P(\theta)$ 中的一个元素，则称 $\text{Nec}\{A\} = 1 - \text{Pos}\{A^c\}$ 为事件 A 的必要性测度。

定义 3.6 假设 $(\theta, P(\theta), \text{Pos})$ 是可能性空间， A 是幂集 $P(\theta)$ 中的一个元素，则称 $\text{Cr}\{A\} = \frac{1}{2}(\text{Pos}\{A\} + \text{Nec}\{A\})$ 为模糊事件 A 的可信性测度。

3.2 模糊变量

定义 3.7 假设 ξ 为一从可能性空间 $(\theta, P(\theta), \text{Pos})$ 到实直线 R 上的函数，则称 ξ 是一个模糊变量。

定义 3.8 假设 ξ 是可能性空间 $(\theta, P(\theta), \text{Pos})$ 上的模糊变量。我们称

$$\xi_\alpha = \{\xi(\theta) | \theta \in \Theta, \text{Pos}\{\theta\} \geq \alpha\} \quad (3-1)$$

是 ξ 的 α 水平集，而集合 $\{\xi(\theta) | \theta \in \Theta, \text{Pos}\{\theta\} > 0\}$ 称为 ξ 的支撑。

定义 3.9 如果 ξ 是从可能性空间 $(\theta, P(\theta), \text{Pos})$ 到 n 维欧几里德空间的函数，则称 ξ 是一个模糊向量。

定义 3.10 (同一空间上的模糊运算) 假设 $f: R^n \rightarrow R$ 是一个函数， $\xi_1, \xi_2, \dots, \xi_n$ 是可能性空间 $(\theta, P(\theta), \text{Pos})$ 上的模糊变量，则 $\xi = f(\xi_1, \xi_2, \dots, \xi_n)$ 是一个模糊变量，定义为

$$\xi(\theta) = f(\xi_1(\theta_1), \xi_2(\theta_2), \dots, \xi_n(\theta_n)), \forall \theta \in \Theta \quad (3-2)$$

定义3.11(不同空间上的模糊运算)假设 $f: R^n \rightarrow R$ 是一个函数, ξ_i 是可能性空间 $(\theta_i, P(\theta_i), \text{Pos}_i)$ 上的模糊变量, $i=1,2,\dots,n$, 则 $\xi = f(\xi_1, \xi_2, \dots, \xi_n)$ 是乘积可能性空间 $(\theta, P(\theta), \text{Pos})$ 上的模糊变量, 定义为

$$\xi(\theta_1, \theta_2, \dots, \theta_n) = f(\xi_1(\theta_1), \xi_2(\theta_2), \dots, \xi_n(\theta_n)), \forall (\theta_1, \theta_2, \dots, \theta_n) \in \Theta \quad (3-3)$$

定义3.12 假设 ξ 是可能性空间 $(\theta, P(\theta), \text{Pos})$ 上的模糊变量。它的隶属函数可由可能性测度 Pos 导出, 即

$$\mu(x) = \text{Pos}\{\theta \in \Theta \mid \xi(\theta) = x\}, x \in R \quad (3-4)$$

定义3.13 (Liu^[66]) 假设 ξ 为模糊变量, 若函数 $\Phi: [-\infty, +\infty] \rightarrow [0,1]$ 满足

$$\Phi(x) = \text{Cr}\{\theta \in \Theta \mid \xi(\theta) \leq x\}, \quad (3-5)$$

则 Φ 称为模糊变量 ξ 的可信性分布。也就是说, 可信性分布 $\Phi(x)$ 是模糊变量 ξ 取值小于或等于 x 的可信性。一般来说, 可信性分布 $\Phi(x)$ 既不左连续也不右连续。

定义3.14 (Liu^[66]) 假设 ξ 为模糊变量, Φ 为 ξ 的可信性分布。若函数 $\Phi: R \rightarrow [0, +\infty)$ 对所有的 $x \in [-\infty, +\infty]$ 满足

$$\Phi(x) = \int_{-\infty}^x \Phi(y) dy, \quad (3-6)$$

则 Φ 称为模糊变量 ξ 的可信性密度函数。

定义3.15 (Liu^[66]) 设 $(\xi_1, \xi_2, \dots, \xi_n)$ 为模糊向量。若函数 $\Phi: [-\infty, +\infty]^n \rightarrow [0,1]$ 满足

$$\Phi(x_1, x_2, \dots, x_n) = \text{Cr}\{\theta \in \Theta \mid \xi_1(\theta) \leq x_1, \xi_2(\theta) \leq x_2, \dots, \xi_n(\theta) \leq x_n\}, \quad (3-7)$$

则 Φ 称为模糊向量 $(\xi_1, \xi_2, \dots, \xi_n)$ 的联合可信性分布。

定义3.16 (Liu^[66]) 设 $(\xi_1, \xi_2, \dots, \xi_n)$ 为模糊向量, Φ 为 $(\xi_1, \xi_2, \dots, \xi_n)$ 的联合可信性分布。

若函数 $\Phi: R^n \rightarrow [0, +\infty)$ 对所有的 $(x_1, x_2, \dots, x_n) \in [-\infty, +\infty]^n$ 满足

$$\Phi(x_1, x_2, \dots, x_n) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_n} \Phi(y_1, y_2, \dots, y_n) dy_1 dy_2 \dots dy_n, \quad (3-8)$$

则 Φ 称为模糊变量 ξ 的联合可信性密度函数。

定义3.17 (Liu^[67]) 假设 $(\xi_1, \xi_2, \dots, \xi_m)$ 为模糊变量, 若对实数集 R 上的任意的子集

B_1, B_2, \dots, B_m , 有

$$Pos\{\xi_i \in B_i, i=1, 2, \dots, m\} = \min_{1 \leq i \leq m} Pos\{\xi_i \in B_i\}, \quad (3-9)$$

则称 $(\xi_1, \xi_2, \dots, \xi_m)$ 为相互独立的模糊变量。

定义3.18 (Liu^[66]) 设 ξ 为模糊变量, 且 $\alpha \in (0, 1]$, 则

$$\xi_{\sup}(\alpha) = \sup\{r | Cr\{\xi \geq r\} \geq \alpha\} \quad (3-10)$$

称为 ξ 的 α 乐观值。

定义3.19 (Liu^[66]) 设 ξ 为模糊变量, 且 $\alpha \in (0, 1]$, 则

$$\xi_{\min}(\alpha) = \inf\{r | Cr\{\xi \leq r\} \geq \alpha\} \quad (3-11)$$

称为 ξ 的 α 悲观值。

定义3.20 设 ξ 为模糊变量, 则称

$$E[\xi] = \int_0^{\infty} Cr\{\xi \geq r\} dr - \int_{-\infty}^0 Cr\{\xi \leq r\} dr \quad (3-12)$$

为模糊变量 ξ 的期望值。

3.3 模糊规划概论

模糊规划是具有模糊参数的一类不确定规划, 它不仅涉及到非线性规划的复杂算法, 还用到模糊数学的理论和方法, 提取模糊规划问题并不是太困难的事, 但实现起来却是很困难的, 采用遗传算法和模糊模拟进行求解, 经过实例, 能够很好得实现。在应用遗传算法和模糊模拟的求解模糊规划的问题时, 处理约束条件的关键在于删除约束条件中的所有等式; 设计恰当的遗传操作以保证所有新产生的染色体在可行集中。

3.3.1 对约束条件的处理及验证染色体的可行性

在数学规划模型中, 如果存在一些等式约束, 例如, $h_k(x)=0$, $k=1, 2, \dots, q$, 可以通过解这些约束构成的方程组, 用其它的变量替换其中的 q 个变量, 以消除 q 个等式约束。为了保证染色体是可行的, 必须对遗传操作过程中得到的每一个染色体进行检查。当然, 应当注意到一些隐含约束, 即有些点虽然是可行解, 但不可能是最优解。

在遗传初始化操作中, 可行集不一定是凸的, 或很难验证其凸性, 此时必须验证每一后代的可行性。如果两个后代均可行, 则用它们代替其父代, 否则, 保留其中可行的(如果存在的话), 然后, 产生新的随机数 c , 重新进行交叉操作, 直到得到两个可行的

后代或循环给定次数为止，无论如何，仅用可行的后代取代其父代。

3.3.2 具体对个体的交叉和变异

在遗传算法中，存在多种交叉方法，在这里使用算子交叉，首先定义参数 P_c 作为交叉操作的概率，这个概率说明群中有期望值为 $P_c * \text{popsize}$ 个染色体来进行交叉操作。为确定交叉操作的父代，从 $i=1$ 到 popsize 重复以下过程：从 $[0,1]$ 中产生随机数 r ，如果 $r < P_c$ ，则选择 v_i 作为一个父代。用 $v'_1, v'_2, \dots, v'_{\text{popsize}}$ 表示上面选择的父代，并把他们随机分成下面 $(v'_1, v'_2), (v'_3, v'_4), \dots$ 。

以 (v'_1, v'_2) 为例解释怎样对上面所有的对进行交叉操作，首先，从开区间 $(0,1)$ 中产生一个随机数 c ，然后，按下列形式在 v'_1 和 v'_2 之间进行交叉操作，并产生两个后代 X 和 Y

$$X = c * v'_1 + (1-c) * v'_2, \quad (3-13)$$

$$Y = (1-c) * v'_1 + c * v'_2, \quad (3-14)$$

在变异操作中，定义参数 P_m 作为遗传系统中的变异概率，这个概率表明，总体中有期望值为 $P_m * \text{popsize}$ 个染色体用来进行变异操作。

类似于交叉操作中选择父代的过程，由 $i=1$ 到 popsize ，重复下列过程：从区间 $(0,1)$ 中产生随机数 r ，如果随机选择变异方向 d ，如果 $V+M*d$ 是不可行的，那么，再置 M 为0到 M 之间的随机数，直到其可行为止。其中 M 是初始化过程定义的一个足够大的数。如果在预先给定的迭代次数之内没有找到可行解，则置 $M=0$ 。无论 M 为何值，总用 $X=V+M*d$ 代替 V 。

3.3.3 模糊模拟及其应用

对模糊系统，用计算机模糊模拟技术检验下列不等式： $\text{Pos}\{g_i(\xi) \leq 0, i=1,2,\dots,k\} \geq \alpha$ 是否成立，并且计算诸如下面的模糊事件的可能性， $G=\{g_i(\xi) \leq 0, i=1,2,\dots,k\}$ ，以及寻找最大的值使得 $\text{Pos}\{g_i(\xi) \geq f\} \geq \alpha$ ，其中 ξ 为已知模糊向量。根据已知定义计算

$$\text{Pos}\{f(\tilde{a}_1, \dots, \tilde{a}_n) \leq b\} = \text{Sup}\{\min_i \tilde{a}_i(x_i) | f(x_1, \dots, x_n) \leq b, x_1, \dots, x_n \in R\}$$

求解不等式方程 $f(\tilde{a}, \dots, \tilde{b}) \leq b$ ，当 f 复杂时求解相当困难，另外可行解可能有无限组，求出全部解并且准确求出上限值几乎是不可能的，因此根据定义计算可能性不实用，比较实用的方法是利用随机模拟法计算。

3.4 模糊模拟的分类和具体实现

对模糊系统, Liu和Iwamura^[68]提出可以用计算机模糊模拟技术检验下列不等式

$$Pos\{g_i(\xi) \leq 0, i=1,2,\dots,k\} \geq \alpha \quad (3-15)$$

是否成立, 并且可以计算诸如下面的模糊事件的可行性,

$$G = \{g_i(\xi) \leq 0, i=1,2,\dots,k\}, \quad (3-16)$$

以及寻找最大的 f 值使得

$$Pos\{g(\xi) \geq f\} \geq \alpha, \quad (3-17)$$

其中 ξ 为已知模糊向量, 其隶属函数为 $\mu(\square)$ 。

下面介绍一些用来处理此类模糊系统的计算机模糊模拟技术

情况1 检验 $Pos\{g(\xi) \geq f\} \geq \alpha$

由模糊数的运算,

$$Pos\{g_i(\xi) \leq 0, i=1,2,\dots,k\} \geq \alpha \quad (3-18)$$

当且仅当存在一个清晰向量 ξ^0 使得

$$g_i(\xi^0) \leq 0, i=1,2,\dots,k, \quad (3-19)$$

且 $\mu(\xi^0) \geq \alpha$ 。为了能够用计算机检验这个条件, 由模糊向量 ξ 随机生成一个清晰向量 ξ^0 使 $\mu(\xi^0) \geq \alpha$, 即在模糊向量 ξ 的 α 水平截集中随机抽取一个向量。如果模糊向量的 α 水平截集过于复杂, 可以从包含 α 水平截集的超几何体 Ω 中抽取向量 ξ^0 , 然后检验 ξ^0 是否在 α 水平截集中, 拒绝与否依赖于 $\mu(\xi^0) \geq \alpha$ 是否成立。如果向量 ξ^0 满足 $g_i(\xi^0) \leq 0, i=1,2,\dots,k$, 则认为 $Pos\{g_i(\xi) \leq 0, i=1,2,\dots,k\} \geq \alpha$ 成立。否则, 按同样的方法, 由模糊向量 ξ 重新生成清晰向量 ξ^0 并检验约束条件。经过给定的 N 次循环以后, 如果没有生成可行的向量 ξ^0 , 则认为

$$Pos\{g_i(\xi) \leq 0, i=1,2,\dots,k\} \geq \alpha \quad (3-20)$$

不成立。上述过程可以归纳为

步骤1 随机地从模糊向量 ξ 的 α 水平截集中生成清晰向量 ξ^0 ;

步骤2 若 $g_i(\xi^0) \leq 0, i=1,2,\dots,k$, 返回“成立”;

步骤3 重复步骤1和2共N次；

步骤4 返回“不成立”。

情况2 计算 $G = Pos\{g_i(\xi) \leq 0, i = 1, 2, \dots, k\}$

首先置 $G=0$ 。其次由模糊向量 ξ 生成清晰向量 ξ^0 。在实际操作过程中，一般对可能性较低的决策向量不感兴趣，所以可以事先置一水平，如 α_0 ，然后从模糊向量的 ξ 水平截集中随机地生成清晰向量 ξ^0 。如果这个集合难以由计算机描述，可以给出一个大的区域，如包含所有感兴趣的样本的超几何体 Ω 。当然，区域越小，模糊模拟效率越高。若 $g_i(\xi^0) \leq 0, i = 1, 2, \dots, k$ ，且 $G < \mu(\xi^0)$ ，则置 $G = \mu(\xi^0)$ 。重复以上过程直到给定的次数N完成为止。我们把值G作为可能性的估计值。总结以上过程如下

步骤1 置 $G=0$ ；

步骤2 从模糊向量 ξ 的 α_0 水平截集中随机地生成清晰向量 ξ^0 ；

步骤3 若 $g_i(\xi^0) \leq 0, i = 1, 2, \dots, k$ ，且 $G < \mu(\xi^0)$ ，则置 $G = \mu(\xi^0)$ ；

步骤4 重复步骤2和3共N次；

步骤5 返回G。

情况3 处理 $Pos\{g(\xi) \geq f\} \geq \beta$

对模糊约束如

$$Pos\{g(\xi) \geq f\} \geq \beta \quad (3-21)$$

我们的目的是找出最大的f使不等式(3-21)成立。首先，置 $f=-\infty$ 。由模糊向量 ξ 随机生成清晰向量 ξ^0 ，使 $\mu(\xi^0) \geq \beta$ ，即在模糊向量 ξ 的 β 水平截集中随机抽取一个向量，如果 $f < g(\xi^0)$ ，则置 $f = g(\xi^0)$ 。重复以上过程N次，所得的值f即作为估计。总结以上过程如下

步骤1 置 $f=-\infty$ ；

步骤2 从模糊向量 ξ 的 β 水平截集中随机生成清晰向量 ξ^0 ；

步骤3 若 $f < g(\xi^0)$ ，则置 $f = g(\xi^0)$ ；

步骤4 重复步骤2和3共N次；

步骤5 返回f。

情况4 处理 $Pos\{g(\xi) \leq f\} \geq \beta$

对模糊约束如

$$Pos\{g(\xi) \leq f\} \geq \beta \quad (3-22)$$

我们的目的是找到最小的 f 使不等式(3-22)成立。首先,置 $f=+\infty$ 。然后由模糊向量 ξ 随机地生成清晰向量 ξ^0 使 $\mu(\xi^0) \geq \beta$,在模糊向量 ξ 的 β 水平截集中随机抽取一个向量,如果 $f > g(\xi^0)$,则置 $f = g(\xi^0)$ 。重复以上过程 N 次,所得的值 f 即作为估计。总结以上过程如下

步骤1 置 $f=+\infty$;

步骤2 从模糊向量 ξ 的 β 水平截集中随机生成清晰向量 ξ^0 ;

步骤3 若 $f > g(\xi^0)$,则置 $f = g(\xi^0)$;

步骤4 重复步骤2和3共 N 次;

步骤5 返回 f 。

3.5 不确定规划的应用

不确定规划的应用非常广泛。由于现实世界的多变性,绝大多数优化问题都或多或少含有不确定因素,包括模糊因素、随机因素、粗糙因素等。可以说,不确定因素无处不在,因此,考虑不确定环境下的优化问题显然是有实际意义的,并且是值得高度重视的。

如今不确定规划理论已被应用到诸多领域,例如:水库调度、生产过程、存储过程、存储系统、资金预算、网络优化、车辆调度、系统可靠性、作业排序、设备选址、关键路问题等。这些课题的研究一方面说明了不确定规划在实际应用中行之有效,另一方面也反映出不确定规划的研究背景,为不确定规划的研究提供了动力。

第四章 一种改进的混合智能算法

本章提出在遗传算法研究的基础上将进化策略和遗传算法结合在一起并引入模拟退火的思想,形成一种改进的混合智能算法。新混合智能算法克服了原有单一算法易陷入局部最优解和早熟的问题,利用进化策略改进进化算子和选择算子,利用模拟退火思想改进变异算子,提高了求解精度。给出了相应的算法步骤。通过数值测试说明了新混合智能算法较之传统算法在求解精度上有了明显改善。

4.1 改进混合智能算法的提出

遗传算法研究的目标是使算法解的质量高,又具有高的计算效率,使其接近实用化。一方面要得到好质量的解需要大量计算;而另一方面片面追求搜索效率通常会导致早熟,使解的质量降低^[69]。因此考虑将进化策略、模拟退火思想和遗传算法进行有效地结合,达到寻优操作既能跳出局部最优解,又能保证收敛速度的良好效果。

单纯的遗传算法存在这些局限性^[70]:它不能保证所得到的是最佳答案;标准遗传算法并不保证全局最优收敛,只能在一定的约束条件下,实现全局最优。单纯的进化策略存在这些局限性^[70]:每一维的常数的标准偏差(平均步长)使收敛最优值的速度变慢;点对点搜索的不稳定性可能造成停止于局部最小值。设计的混合智能算法将两者的优势充分发挥出来,克服了单一算法的局限性。

进化策略(Evolutionary Strategy,简称ES)是模仿自然选择和遗传机制的一种智能优化算法,它是由德国柏林技术大学的I. Rechenberg和H. P. Schwefel为研究风洞中的流体力学问题提出的。隐含并行性和群体全局搜索性是它的两个显著特征,而且具有较强的鲁棒性。对于一些复杂的非线性系统求解,具有独特的优越性能。目前,这种算法已广泛应用于各种优化问题的处理。如神经网络的训练与设计、系统识别、机器人控制和机器学习等领域。

模拟退火算法(Simulated Annealing,简称SA)是20世纪80年代初期发展起来的一种求解大规模组合优化问题的随机搜索方法,它以优化问题的求解与物理系统退火过程的相似性为基础,利用Metropolis算法并适当地控制温度的下降过程实现模拟退火,从而达到求解全局优化问题的目的。模拟退火算法在求解TSP、VLSI电路设计等NP完全组合优化问题上取得了很好的结果,并能应用于求解连续变量函数的全局优化问题,它具有

适用范围广、求得全局最优解的可靠性高、算法简单和便于实现等优点。

4.2 改进混合智能算法的基本思想

该算法以遗传算法为基础，将进化策略作为一个独立算子，其中引入了进化策略的 (μ, λ) 选择算子，提高算法跳出局部最优的几率，在算子的变异过程中采用模拟退火的思想。精英保留策略，更有利于算法收敛到全局最优。几种算法相互借鉴，起到互补的作用。

4.3 算法实现流程

步骤 1.产生初始群体

随机生成初始群体，并利用神经网络对其进行可行性的检验。编码方案采用实数编码。

步骤2.交叉

随机选取两个配对个体进行交叉，然后随机生成一个0、1标志数，若标志数为“1”，则对两个个体中相应位的基因进行负交叉运算；否则对两个个体中相应位的基因进行正交叉运算。

步骤3.变异

引入模拟退火思想，对需变异的基因位按照Metropolis接受准则判断接受与否。

步骤 4.进化

引入随机步长 σ ，用来调整个体进行变异操作时变异量的大小。根据进化策略的思想产生新个体。

步骤 5.选择

采用进化策略的选择算子 (μ, λ) 。保留迄今为止存在的最优个体。

算法中具体技术的描述：

在变异过程中，对个体中的每个基因都随机生成一个 P ， P 属于 $[0, 1]$ ，若满足 $P > P_m$ (P_m 为变异概率)，则对该位的基因进行变异操作；否则保持不变。下面应用模拟退火思想，对变异结果，按照Metropolis接受准则判断接受与否。即：发生变异的个体与其变异后

的个体适应度值进行比较,若变异后个体较优则接受其作为新个体,并替代变异前个体;否则随机产生一个随机数 r 若满足下式: $\exp(f_1 - f_2/T) > r$ 则接受变异后个体作为新个体。式中: f_1 为变异前个体的适应值; f_2 为变异后个体的适应值; T 为退火温度,退火函数为 $T = T_0 * S_{gen}$, T_0 为初始温度, S 为退火系数, gen 为进化代数。若上面两个条件都不满足则不接受新个体。

在进化过程中,在旧个体基础上增加一个随机量,从而形成新个体,这个随机量由步长 $\sigma \in R_n$ (正态分布的标准差)构成,可以用来调整个体进行变异操作时变异量的大小。根据进化策略的思想^[2],假设群体的个体 $X = \{x, s\}$ 经过变异运算后得到一个新的个体 $X' = \{x', s'\}$, 则新个体的组成元素是:

$$\begin{cases} \sigma'_i = \sigma_i \exp[\tau * N(0,1) + \tau' * N_i(0,1)] \\ x'_i = x_i + \sigma'_i N(0,1) (i=1,2,\dots,n) \end{cases} \quad (4-1)$$

其中, $N(0, 1)$ 和 $N_i(0, 1)$ 是均值为0, 方差为1的正态随机变量, τ 和 τ' 是算子集参数, 其中 $\tau = (\sqrt{2\sqrt{N}})^{-1}$ 和 $\tau' = (\sqrt{2N})^{-1}$, $\tau * N(0,1)$ 和 $\tau_i * N_i(0,1)$ 分别表示变异时的整体步长和个体步长。

在选择过程中,选择不采用轮盘法那种随机方式,而是采用进化策略中以确定方式进行的选择算子 (μ, λ) 选择,使优良个体100%地被保留,劣质个体100%地被淘汰。在新产生的 λ 个个体中选取 μ 个最优者,将它们保留到子代群体中,该选择方式易于跳出局部最优解,而且能够扩大群体多样性,从而有效避免未成熟收敛。保留迄今为止存在的最优个体,保证其不被交叉和变异等遗传算子破坏。具体操作为:计算新群体的适应值,若新群体中的最优个体优于上代保存的最优个体,则用该个体替换上代保留的最优个体;否则用上代的最优个体替换新群体中最差的个体。

4.4 算法测试与比较分析

本实验选择了5个目标函数进行测试,将改进的算法用于解决函数优化的问题。在这些函数中, f_1 、 f_2 是高维单模函数, f_3 、 f_4 是高维多模函数,其局部最小值的数量随着问题维数的增加呈指数级增长。 f_5 是低维函数,仅有几个局部最小值,且最小值之间起伏较小。对于多模函数,最终的结果非常重要,因为它反映了算法跳出局部最优值,找到近似全局最优值的能力。

(1) Sphere model

$$f_1(x) = \sum_{i=1}^n x_i^2 \quad (4-2)$$

(2) Schwefel's Problem

$$f_2(x) = \sum_{i=1}^n |x_i| + \prod_{i=1}^n |x_i| \quad (4-3)$$

(3) Generalized Schwefel's Problem

$$f_3(x) = \sum_{i=1}^n -x_i \sin(\sqrt{|x_i|}) \quad (4-4)$$

(4) Generalized Rastrigin's Function

$$f_4(x) = \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i) + 10] \quad (4-5)$$

(5) Six-Hump Camel-Back Function

$$f_5(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_2^4 \quad (4-6)$$

表4-1 5个函数的最小适应值

Table4-1 The min fitness value of 5 functions

Function	n	S	f _{min}	
			新算法	传统算法
$f_1(x) = \sum_{i=1}^n x_i^2$	30	[-100,100]	0	0.000009
$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	30	[-10,10]	0	0.000023
$f_3(x) = \sum_{i=1}^n -x_i \sin(\sqrt{ x_i })$	30	[-500,500]	-12539.5	-12539.650002
$f_4(x) = \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i) + 10]$	30	[-5.12,5.12]	0	0.000104
$f_5(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_2^4$	2	[-5,5]	-1.0316285	-1.157583

表4-2 函数1测试结果

Table4-2 The of function 1

$f_1(x) = \sum_{i=1}^n x_i^2$	步数	平均最优值偏差	统计方差
传统遗传算法	500	0.5	1.52
传统模拟退火遗传算法	200	2.8×10^{-4}	2.2×10^{-4}
改进的混合智能算法	60	3.9×10^{-6}	5.3×10^{-6}

表4-3 函数2测试结果

Table4-3 The of function 2

$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	步数	平均最优值偏差	统计方差
传统遗传算法	1000	2.69	3.41
传统模拟退火遗传算法	1800	0.32	0.054
改进的混合智能算法	600	0.095	0.097

表4-4 函数3测试结果

Table4-4 The of function 3

$f_3(x) = \sum_{i=1}^n -x_i \sin(\sqrt{ x_i })$	步数	平均最优值偏差	统计方差
传统遗传算法	700	-12.5	5.82
传统模拟退火遗传算法	1500	-13.2	1.35
改进的混合智能算法	100	-13.25	1.9×10^{-4}

表4-5 函数4测试结果

Table4-5 The of function 4

$f_4(x) = \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i) + 10]$	步数	平均最优值偏差	统计方差
传统遗传算法	30	2.3×10^{-3}	2.3×10^{-3}
传统模拟退火遗传算法	300	0.043	0.014
改进的混合智能算法	20	3.9×10^{-4}	4.2×10^{-4}

表4-6 函数5测试结果

Table4-6 The of function 5

$f_5(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_2^4$	步数	平均最优值偏差	统计方差
传统遗传算法	20	2.7×10^{-5}	5.1×10^{-5}
传统模拟退火遗传算法	50	1.7×10^{-6}	3.4×10^{-7}
改进的混合智能算法	10	2.5×10^{-6}	2.8×10^{-6}

从上面的对比可以看出,引入了进化策略算子和模拟退火思想的新混合智能算法较之于传统遗传算法和传统模拟退火遗传算法的寻优能力更好。对传统算法的改进增强了算法搜索能力和突跳能力,因而大大缩短了算法的搜索过程,提高了优化效率和优化质量。

4.5 本章小结

遗传算法所具有的开放式的结构,与问题的关联性不大,很容易和其他算法进行结合,所以将其它智能算法思想融合进遗传算法中是当前遗传算法改进的一个重要方法。基于此本章提出了将进化策略和模拟退火算法混合进遗传算法中来构造一种新的智能

算法。从数值试验的结果可以看到，新算法改良了以往遗传算法中易陷入局部最优解问题。随着技术的不断发展，遗传算法与进化策略两种算法交叉渗透，差异也在不断缩小，通过两者的相互借鉴，必定会产生更多稳定，高效的新算法。

第五章 改进混合智能算法在模糊规划中的应用

当今时代是一个信息的时代，信息为人类认识和改造世界提供了知识的源泉，但是人们接触到的信息其实大部分的时候是不确定的信息。在运筹学、管理科学、信息科学、系统科学、计算机科学以及工程技术等众多领域都存在着客观的或人为的不确定性。这些不确定性的表现形式是多种多样的，如随机性、模糊性、粗糙性、模糊随机性以及其它的多重不确定性。然而，对于这些含有不确定性的决策问题，经典的优化理论通常是无能为力的。虽然已有的随机规划和模糊规划可以解决一部分不确定优化问题，但又远远不能满足解决具有多重不确定性的优化问题的需求。因此，建立和完善统一的不确定环境下的优化理论与方法不但具有理论价值，而且具有广阔的应用前景。

5.1 模糊规划的定义

我们定义含有模糊参数的数学规划称为模糊规划。

$$\begin{cases} \text{Max } f(x, \xi) \\ \text{s.t.} \\ g_j(x, \xi) \leq 0, j=1, 2, \dots, p \end{cases} \quad (5-1)$$

其中 x 是决策向量， ξ 是模糊参数向量， $f(x, \xi)$ 是目标函数， $g_j(x, \xi)$ 是约束函数 $j=1, 2, \dots, p$ 。但是，由于参数的模糊性而导致了目标函数和约束函数的定义不明确。上面的这个例子，从数学角度上来讲，是没有任何意义的。为了给出明确的模糊规划模型，我们必须要考虑其它一些有意义的模糊规划形式，由此而引出了三种模糊规划模型：模糊期望值模型，模糊机会约束规划模型，模糊相关机会规划模型。

5.2 模糊规划的建模方法

确定性规划可分为线性规划、非线性规划、整数规划等，对这些模型的系数简单的进行模糊化不一定是有意义的，比如简单地把约束模糊化，意义就不明确。一种方法就是让最优解满足模糊约束函数的置信水平大于某个数。总结起来，从建模理念的角度来说，模糊规划处理这些不确定因素的基本途径有三条：

- 1) 从期望值的角度考虑，用不确定函数的期望值分别代替原来的目标函数和约束条件中的不确定函数，建立期望值模型。
- 2) 从机会测度的角度考虑。当约束条件中含有不确定变量且必须在观测到不确定变量

实现之前作出决策时，采用一种原则允许所作决策在一定程度上不满足约束条件，即只要求使约束条件得到满足的机会测度不小于预先给定的置信水平。基于此建立机会约束规划模型。

3) 极大化事件实现的机会如概率测度、可能性测度、必要性测度、可信性测度、信任测度等，建立相关机会规划模型。

5.2.1 期望值模型

对于优化问题中出现的不确定变量，相应地都有该变量的数学期望的概念。基于此，第一种建模方法是在期望值约束成立下极大化这些不确定目标函数的数学期望，亦即期望值模型。

$$\begin{cases} \max E[f(x, \xi)] \\ \text{s.t.} \\ E[g_j(x, \xi)] \leq 0, j=1, 2, \dots, p, \end{cases} \quad (5-2)$$

其中为 x 决策向量， ξ 为模糊变量， $f(x, \xi)$ 表示目标函数， $g_j(x, \xi)$, $j=1, 2, \dots, p$ 表示模糊约束函数， E 表示期望值算子。

5.2.2 机会约束规划

由 Charnes 和 Cooper^[71]提出，其允许所作决策在一定程度上不满足约束条件，但该决策使约束条件成立的概率或可能性不小于某一置信水平 α 。典型的机会约束规划可以表示成下面的形式。

$$\begin{cases} \text{Max } \bar{f} \\ \text{s.t.} \\ \text{Cr}\{f(x, \xi) \leq \bar{f}\} \geq \beta \\ \text{Cr}\{g_j(x, \xi) \leq 0, j=1, 2, \dots, p\} \geq \alpha \end{cases} \quad (5-3)$$

其中 x 是决策向量， ξ 是模糊参数， α 和 β 分别是对约束和目标事先给定的置信水平， $\text{Cr}\{\}$ 表示 $\{\}$ 中事件成立的概率或可能性。作为机会约束规划的推广，此类规划可以表示成

$$\begin{cases} \text{Max } [\bar{f}_1, \bar{f}_2, \dots, \bar{f}_m] \\ \text{s.t.} \\ \text{Cr}\{f_i(x, \xi) \leq \bar{f}_i\} \geq \beta_i, i=1, 2, \dots, m \\ \text{Cr}\{g_j(x, \xi) \leq 0, j=1, 2, \dots, p\} \geq \alpha_j, j=1, 2, \dots, p \end{cases} \quad (5-4)$$

这里 β_i , $i=1,2,\dots,m$ 表示对第 i 个目标事先给定的置信水平。根据决策者给定的优先结构和目标水平,我们也可以把模糊系统化成绩会约束目标规划。

$$\left\{ \begin{array}{l} \text{Min } \sum_{j=1}^i P_j \sum_{i=1}^m (u_{ij} d_i^+ + v_{ij} d_i^-) \\ \text{s.t.} \\ \text{Cr}\{f_i(x, \xi) + d_i^- = b_i\} \geq \beta_i, i=1,2,\dots,m \\ \text{Cr}\{g_j(x, \xi) \leq 0, j=1,2,\dots,p\} \geq \alpha_j, j=1,2,\dots,p \\ d_i^-, d_i^+ \geq 0, i=1,2,\dots,m \end{array} \right. \quad (5-5)$$

这里 P_j =优先因子,表示各个目标的相对重要性,且对所有的 j ,有 $P_j \geq P_{j+1}$, u_{ij} =对应优先因子 j 第 i 个目标正偏差的权重因子, v_{ij} =对应优先因子 j 第 i 个目标负偏差的权重因子, d_i^+ =目标 i 偏离目标值的正偏差, d_i^- =目标 i 偏离目标值的负偏差, f_i =目标约束中的机会函数或普通实值函数, g_i =实际约束条件中的函数, b_i =目标 i 的目标值, l =优先权个数, m =目标约束条件个数。正、负偏差 d_i^+ 和 d_i^- 的值是下列不等式成立的最小非负值

$$\left\{ \begin{array}{l} \text{Cr}\{d_i^- \geq b_i - f_i(x, \xi)\} \geq \beta_i \\ \text{Cr}\{d_i^+ \geq f_i(x, \xi) - b_i\} \geq \beta_i, i=1,2,\dots,m \end{array} \right. \quad (5-6)$$

5.2.3 相关机会规划

由 Liu^[72,73]提出。一个复杂的决策系统通常要完成多项任务,称之为事件,决策者往往希望这些事件实现的概率或可能性(机会函数)尽可能的大。相关机会规划是使事件的机会函数在不确定环境下达到的最大的优化理论。不确定环境下典型的相关机会规划可以表示为:

$$\left\{ \begin{array}{l} \max f(x) \\ \text{s.t.} \\ g_j(x, \xi) \leq 0, j=1,2,\dots,p, \end{array} \right. \quad (5-7)$$

其中 x 是一个 n 维决策向量, ξ 是一个模糊向量, $f(x)$ 是一个事件的机会函数, $g_j(x, \xi) \leq 0, j=1,2,\dots,p$ 是不确定环境。值得注意的是,在相关机会规划模型中,不确定环境所描述的可行集并不假定是确定的或清晰的。此类规划的模型可以表示成

$$\left\{ \begin{array}{l} \text{Max } f(x) = [f_1(x), f_2(x), \dots, f_m(x)] \\ \text{s.t.} \\ g_j(x, \xi) \leq 0, j=1,2,\dots,p \end{array} \right. \quad (5-8)$$

其中 $f(x)$ 是由 m 个函数 $f_i(x)$, $i=1,2,\dots,m$ 构成的向量, 在 m 个函数 $f_i(x)$ 中有些是机会函数。带有随机或模糊参数的相关机会目标规划可以看成是复杂不确定决策系统中的目标规划的扩展。在管理目标确定以后, 目标函数是在一定优先结构中极小化偏差。根据决策者制定的优先结构和目标水平, 我们可以把随机或模糊决策系统建成相关机会目标规划。

$$\begin{cases} \text{Min} \sum_{j=1}^i P_j \sum_{i=1}^m (u_{ij} d_i^+ + v_{ij} d_i^-) \\ \text{s.t.} \\ f_i(x) + d_i^- - d_i^+ = b_i, i=1,2,\dots,m \\ g_j(x, \xi) \leq 0, j=1,2,\dots,p \\ d_i^-, d_i^+ \geq 0, i=1,2,\dots,m \end{cases} \quad (5-9)$$

这里 P_j =优先因子, 表示各个目标的相对重要性, 且对所有的 j , 有 $P_j \geq P_{j+1}$, u_{ij} =对应优先因子 j 第 i 个目标正偏差的权重因子, v_{ij} =对应优先因子 j 第 i 个目标负偏差的权重因子, d_i^+ =目标 i 偏离目标值的正偏差, d_i^- =目标 i 偏离目标值的负偏差, f_i =目标约束中的机会函数或普通实值函数, g_i =系统约束条件中的函数, b_i =目标 i 的目标值, l =优先权个数, m =目标约束条件个数, p =实际约束条件个数。

传统的数学规划模型提供清晰向量作为最优解使一些目标达到最优值。但是, 如果从实际的需要出发, 有时我们应该提供模糊决策而不是清晰决策。Bouchon-Meunier 等^[74]总结了各种各样的极大化建立在模糊集上的数值函数的方法。Buckley 和 Hayashi^[75]通过选择一个最优的模糊集去极大化一个实值函数, 为此设计了模糊遗传算法, 并应用到模糊优化问题、模糊极大流问题、模糊回归以及模糊控制等领域。更一般地, Liu 和 Iwamura^[76]提供了带有模糊决策的机会约束规划的理论框架, 而 Liu^[77]建立了带有模糊决策的相关机会规划等一系列模型, 并为求解这些模糊模型设计了基于模糊模拟的遗传算法。

5.3 模型的算法研究

1) 在转化为确定模型计算(间接算法)

对于模糊规划模型, 其主要还在怎样去分析模型。对于不确定的模型, 很自然的想法就是把不确定的模型转化为确定的模型。例如, 对于随机机会约束模型, 传统的处理机会约束的方法是把机会约束规划转化为它们各自的等价形式。但是, 要做到这一点是

很难的，只有在特殊的情况下才能做到，因而对于广大的不确定模型来说，依赖于传统方法，即使对于机会约束线性规划的计算有时也是相当困难的。这种算法本质上是间接算法。

2) 模糊模拟

模糊模拟与有关算法的结合不是简单的结合，而是在相关算法中根据需要嵌入模糊模拟，如刘宝碇将随机模拟嵌入到遗传算法中来求解随机规划模型就是一种较为成功的算法。

对于含有模糊变量的规划模型，从可能性测度和可信性测度出发，可以计算模糊事件的可能性、可信性、临界值以及期望值。

3) 基于模糊模拟的智能算法(直接算法)

随着计算机的高速发展，基于模糊模拟的遗传算法被设计用来计算机会约束规划，使得复杂的机会约束规划可以不必通过转化为确定性数学规划而直接得到计算。

对于不确定优化，智能算法包括神经网络、模拟退火以及遗传算法等，为了提高效率，可以将几种方法有效的结合起来，从而形成混合智能算法。刘宝碇先生把神经网络和遗传算法有机的结合起来，首先使用模糊模拟产生训练样本，然后利用这些数据训练神经网络逼近不确定函数，最后把神经网络嵌入到遗传函数，从而得到混合智能算法，其过程如下：

步骤1.用模拟产生一组数据，即训练样本。

步骤2.训练神经网络以便逼近不确定函数。

步骤3.初始产生`pop_size`个染色体，其中可能使用前面训练的神经网络检验染色体的可行性。

步骤4.对染色体进行交叉操作以及变异操作，其中用神经网络检验后代的可行性。

步骤5.使用神经网络计算所有染色体的目标值。

步骤6.根据目标值计算每个染色体的适应度。

步骤7.旋转赌轮，选择染色体。

步骤8.重复4~7步，直到给定的次数。

步骤9.最好的染色体作为优化问题的最优解。

4) 基于不确定模拟的传统算法

在解决确定规划的研究中所建立的算法，如求解线性规划的单纯形算法，非线性规划的梯度法，牛顿法等，我们可以称为传统算法。传统算法主要用于解决确定性系数的

规划问题，难以直接用于不确定规划中，在这方面的研究也比较少，因而研究传统算法在不确定规划的应用具有重要意义。对于随机线性模型，丁晓东在其博士论文中提出了基于随机模拟的单纯形法，效果比刘宝碇的遗传算法还好。把传统算法应用于不确定模型的关键在于把不确定模拟嵌入到传统算法的每一步中，而不是简单的抽样。

5.4 支持向量及介绍

5.4.1 支持向量机的提出

支持向量机(Support Vector Machine, SVM)是基于统计学习理论^[78,79]中的经验风险最小(Structure Risk Minimization, SRM)归纳原理提出来的。是近几年发展起来的新型的较通用的知识发现方法。SVM 来源于线性可分情况下的最优分类面，即以最大间隔将数据分开。在线性不可分的情况下，可通过利用一个非线性映射，将输入空间映射到一个维数更高的特征空间，在此空间中构造最优分类超平面。

统计学习理论(Statistical Learning Theory, SLT)是一门研究及与经验数据的机器学习理论的科学，在统计学习理论中包括这么几个核心问题：VC 维、推广性的界和结构风险最小化。

VC 维和推广性的界：

在 VC 维概念的基础上，得到构造性的与分布无关的界。利用这些界，可以找到学习机器所取得的风险的界。一个指示函数集 $Q(z, \pi), \pi \in \Lambda$ 的 VC 维，是能够被集合中的函数以所有可能的 2^h 种方式分成两类的向量 z_1, \dots, z_h 的最大数目 h (也就是能够被这个函数集打散的向量的最大数目)。一个有限的 VC 维意味着快的收敛速度，VC 维越大，则机器学习越复杂，容量越大。

考虑有限 VC 维 h 的函数集。使用下面的构造性表达式：

$$\varepsilon = 4 \frac{h(\ln \frac{2l}{h} + 1) - \ln(\frac{\eta}{4})}{l} \quad (5-10)$$

则下面的构造性界成立：对指示函数集中的所有函数的经验风险 $R_{emp}(w)$ 和实际风险 $R(w)$ 之间以至少 $1-\eta$ 的概率满足下式关系：

$$R(w) \leq R_{emp}(w) + \sqrt{\frac{h(\ln(2n/h) + 1) - \ln(\eta/4)}{n}} \quad (5-11)$$

从与样本分布无关的构造性界中可以看出，学习机器的推广性能是由函数集的 VC

维而不是其自由参数个数控制的，其大小与函数集的容量大小有关。

结构风险最小化：

实现原则可以有两种思路，一是保持置信范围固定通过选择一个适当的结构，在每个子集中求最小经验风险，然后选择使最小经验风险和置信范围之和最小的子集，显然这种方法比较费时，当子集数目很大甚至无穷时不可行。因此有第二种思路保持经验风险固定，并最小化置信范围，即设计函数集的某种结构使每个子集中都能取得最小的经验风险，然后只需选择适当的子集使置信范围最小，则这个子集中使经验风险最小的函数就是最优函数。支持向量机方法实际上就是上述第二种思想的具体体现。后一种思路的一个优点是不需要知道函数集的具体维值，只需知道不同函数集之间维的相对大小。基于此，统计学习理论提出新的策略是把函数集构造为一个函数子集系列 S_1, S_2, \dots, S_k ，使各个子集按 VC 维的大小排列，不妨设 $h_1 \leq h_2 \leq \dots \leq h_k$ ，在每个子集中寻找最小经验风险，在子集间折中考虑经验风险和置信度从而获得期望风险最小。

所以，支持向量机的基本思想可描述为：通过非线性变换将输入空间变换到一个高维空间，然后在新空间中求取最优线性分类面，非线性变换是通过定义适当的内积函数实现的。在最优分类面中采用适当的内积函数 $K(x_i, x_j)$ 就可实现某一非线性变换后的线性分类，而计算复杂度却没有增加。

5.4.2 支持向量机的思想和算法

支持向量机主要包括支持向量分类机和支持向量回归机两种类型，在本文中用到的即是支持向量回归机。

支持向量回归机是SVM在回归问题中的应用，其实现的基本思想是：通过一个非线性映射 $\Phi(x)$ ，将输入空间的 n 维样本向量 X 映射到高维特征空间 H 中，并在该空间中利用结构风险最小化原则构造线性决策函数，进行线性回归，其本质上就是一个线性约束的凸二次规划优化求解问题。其中，非线性变换是通过原空间的核函数代替高维特征空间中的内积运算来实现的。

对于数据 $\{x_i, y_i\}, i=1, \dots, n, x_i \in \mathbb{R}^d, y_i \in \mathbb{R}$ ，考虑用线性回归函数 $f(x) = \omega \cdot x + b$ 拟合构造超平面，并假设所有训练数据都可以在精度 ε 下无误差的用线性函数拟合。即：

$$\begin{cases} y_i - \omega \cdot x_i - b \leq \varepsilon \\ \omega \cdot x_i + b - y_i \leq \varepsilon \end{cases} \quad (5-12)$$

$$i = 1, \dots, n$$

这里的最优化问题等价与最小化 $\frac{1}{2}\|\omega\|^2$ 。即

$$\begin{aligned} \min_{\omega \in R^d, b \in R} \frac{1}{2}\|\omega\|^2, \\ \text{s.t.} \begin{cases} y_i - \omega \square x_i - b \leq \varepsilon \\ \omega \square x_i + b - y_i \leq \varepsilon \end{cases} i=1, \dots, n \end{aligned} \quad (5-13)$$

上式的对偶问题是

$$\begin{aligned} \min_{\alpha_i^{(*)} \in R^{2n}} \frac{1}{2} \sum_{i,j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j)(x_i \square x_j) + \varepsilon \sum_{i=1}^n (\alpha_i^* - \alpha_i) - \sum_{i=1}^n y_i (\alpha_i^* - \alpha_i) \\ \text{s.t.} \begin{cases} \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0, \\ \alpha_i^* \geq 0, i=1, \dots, n \end{cases} \end{aligned} \quad (5-14)$$

这里有两种情况，包括有*和无*两种情况。求得最优解 $\bar{\alpha}^{(*)} = (\bar{\alpha}_1, \bar{\alpha}_1^*, \dots, \bar{\alpha}_n, \bar{\alpha}_n^*)^T$ 计算 $\bar{\omega} = \sum_{i=1}^n (\bar{\alpha}_i, \bar{\alpha}_i^*) x_i$ ，并且选择 $\bar{\alpha}$ 的正分量 $\bar{\alpha}_j > 0$ ，据此计算 $\bar{b} = y_i - (\bar{\omega} \square x_j) - \varepsilon$ ；或者选择 $\bar{\alpha}^*$ 的正分量 $\bar{\alpha}_j^* > 0$ ，据此计算 $\bar{b} = y_i - (\bar{\omega} \square x_j) - \varepsilon$ ；构造硬 ε -带超平面 $y = (\bar{\omega} \square x) + \bar{b}$ 和决策函数 $f(x) = (\bar{\omega} \square x) + b = \sum_{i=1}^n (\bar{\alpha}_i^* - \bar{\alpha}_i)(x_i \square x) + \bar{b}$ 。如果计算出的 $\bar{\alpha}_i \neq 0$ 或 $\bar{\alpha}_i^* \neq 0$ ，则称训练集中的输入 x_i 为支持向量。这种算法就是线性硬 ε -带支持向量回归机。

5.4.3 支持向量机的特点

支持向量机是近年来发展起来的一种新型通用的机器学习方法，在许多分类问题和函数拟合问题上都获得了很好的效果。传统的知识发现技术虽然已经发展的较为成熟，但本身仍存在无法避免的缺陷。如多元统计分析对数据的要求太过严格，人工神经网络存在“过学习”现象，传统统计学无法应用于小样本训练等。而支持向量机很大程度的克服了以上的问题，为知识发现技术提供了新的发展空间。

支持向量机在解决小样本、非线性及高维模式识别问题中表现出了特有的优越性。

(1) 它是建立在统计学习理论的维理论和结构风险最小化归纳原则基础之上，根据有限样本信息在模型的复杂性和学习能力之间寻求最佳折衷，以获得最好的推广能力；(2) 它由构成的分类器可以最大化类与类之间的间隔，克服了人工神经网络和传统分类法的诸多缺点，具有较高的泛化能力；(3) 算法用非线性映射把数据映射到一个高维特征空

间, 然后进行线性分类, 将原问题转化为一个二次规划问题, 与传统分类算法比较, 在运算速度、结果精度等方面都有着明显的优越性。

支持向量的理论研究也已基本成熟, 并以构建整个理论框架。近几年更是涌现出大量理论研究成果, 为支持向量机的进一步应用奠定了理论基础。Anthony等^[80]给出了关于硬领域支持向量机学习误差的严格理论界限; Shawe-Taylor等^[81]给出了关于软领域支持向量机和回归情况下的误差界限; Weston^[82]和Vapnik等研究了其推广性能及在多值分类和回归问题的拓展问题; Smola和Scholkopf^[83]提出了支持向量机一般意义下的损失函数数学描述等。

5.5 基于改进混合智能算法和支持向量机的模糊规划求解

算法描述:

步骤1、用模糊模拟技术为不确定函数产生输入输出数据。

步骤2、根据产生的数据训练一个支持向量回归机来拟和模糊规划函数。

- (1) 设已知训练集 $T = \{(x_1, y_1), \dots, (x_n, y_n)\} \in (X \times Y)^n$, 其中 $x_i \in X = R^d, y_i \in Y = R, i = 1, \dots, n$;
- (2) 选择适当的正数 ε 和 C ; 选择适当的核 $K(x, x')$;
- (3) 构造并求解最优化问题

$$\begin{aligned} \min_{\alpha^* \in R^{2n}} & \frac{1}{2} \sum_{i,j=1}^n (\alpha_i^* - \alpha_j)(\alpha_j^* - \alpha_j) K(x_i \square x_j) + \varepsilon \sum_{i=1}^n (\alpha_i^* - \alpha_i) - \sum_{i=1}^n y_i (\alpha_i^* - \alpha_i) \\ \text{s.t.} & \begin{cases} \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0, \\ 0 \leq \alpha_i, \alpha_i^* \leq \frac{C}{n}, i = 1, \dots, n \end{cases} \end{aligned} \quad (5-15)$$

得到最优解 $\bar{\alpha}^{(*)} = (\bar{\alpha}_1, \bar{\alpha}_1^*, \dots, \bar{\alpha}_n, \bar{\alpha}_n^*)^T$

- (4) 构造决策函数

$$f(x) = \sum_{i=1}^n (\bar{\alpha}_i^* - \bar{\alpha}_i) K(x_i \square x) + \bar{b} \quad (5-16)$$

其中 \bar{b} 按下列方式计算: 选择位于开区间 $(0, \frac{C}{n})$ 中的 $\bar{\alpha}_j$ 或 $\bar{\alpha}_k^*$, 若选择

的是 $\bar{\alpha}_j$, 则 $\bar{b} = y_j - \sum_{i=1}^n (\bar{\alpha}_i^* - \bar{\alpha}_i)(x_i \square x_j) + \varepsilon$; 若选择的是 $\bar{\alpha}_k^*$, 则

$$\bar{b} = y_k - \sum_{i=1}^n (\vec{\alpha}_i - \bar{\alpha}_i)(x_i \boxtimes x_k) - \varepsilon。$$

步骤3、利用上一章改进的混合智能算法来对拟合的函数进行解优化。选择出最好的个体作为最优解。

5.6 实验与分析

5.6.1 期望值模型实验

$$\begin{cases} \max E[\sqrt{|x_1 - \xi_1| + |x_2 - \xi_2| + |x_3 - \xi_3|}] \\ s.t. \\ x_1^2 + x_2^2 + x_3^2 \leq 10, \end{cases} \quad (5-17)$$

其中 ξ_1 , ξ_2 和 ξ_3 分别是三角模糊变量 $(-4, -2, 0)$, $(-2, 0, 2)$ 和 $(0, 2, 4)$ 。通过运行该算法 1000 代, 我们找到了最优解

$$x_1^* = -1.7784, \quad x_2^* = -1.8813, \quad x_3^* = -1.8243,$$

其目标值为 3.81。只用遗传算法进行解优化所取得的最优目标值是 3.77。

5.6.2 机会约束规划实验

$$\begin{cases} \max 2x_1 + 3x_2 \\ s.t. \\ Pos\{\tilde{a}x_1 + x_2 \leq \tilde{b}\} \geq 0.90 \\ Pos\{x_1 + \tilde{c}x_2 \leq \tilde{d}\} \geq 0.85 \\ x_1 + x_2 \leq 100 \\ x_1, x_2 \geq 0, \end{cases} \quad (5-18)$$

其中 \tilde{a} 为梯形模糊数 $(1, 1.5, 2.5, 3)$, \tilde{b} 是模糊数, 其隶属函数为

$$\mu_{\tilde{b}}(\xi) = \exp[-\frac{1}{10}|\xi - 150|], \quad (5-19)$$

\tilde{c} 是三角模糊数 $(1, 2, 3)$, \tilde{d} 是模糊数, 其隶属函数为

$$\mu_{\tilde{a}}(\xi) = \exp[-\frac{1}{10}|\xi - 130|]. \quad (5-20)$$

为了使用模糊模拟检验一个给定的解 x 是否可行, 取 \tilde{a} , \tilde{b} , \tilde{c} 和 \tilde{d} 的 α 水平截集为 $[1,3]$, $[140,160]$, $[1,3]$ 和 $[120,140]$ 。经过 300 代运算以后, 该算法所给出的最好解为

$$(x_1^*, x_2^*) = (62.63, 37.36),$$

其目标值为 237.34。只用遗传算法进行解优化所取得的最优目标值 237.11。

5.6.3 相关机会规划实验

$$\begin{cases} \max Cr\{x_1^2 + x_2^2 + x_3^2 = 1\} \\ s.t. \\ \tilde{b}(x_1 + x_2 + x_3) \geq \tilde{a} \\ x_1, x_2, x_3 > 0, \end{cases} \quad (5-21)$$

其中 \tilde{a} 为三角模糊变量 $(0,1,2)$, 模糊变量 \tilde{b} 的隶属函数为

$$\mu_{\tilde{a}}(\xi) = \exp(-|\xi - 2|). \quad (5-22)$$

在此模型中, 事件为 $x_1^2 + x_2^2 + x_3^2 = 1$, 记为 ε , 其相关支撑 $\varepsilon^{**} = \{x_1, x_2, x_3\}$ 。根据不确定原理, 事件 ε 的机会函数为

$$f(x) = Cr \left\{ \begin{array}{l} x_1^2 + x_2^2 + x_3^2 = 1 \\ \tilde{b}(x_1 + x_2 + x_3) \geq \tilde{a} \\ x_1, x_2, x_3 > 0 \end{array} \right\}, \quad (5-23)$$

用染色体 $V=(v_1, v_2)$ 表示模型的一个解, 它可按下面方式进行解码

$$x_1 = v_1, x_2 = v_2, x_3 = \sqrt{1 - v_1^2 - v_2^2}.$$

显然, 有 $x_1^2 + x_2^2 + x_3^2 = 1$ 。利用模糊模拟为不确定函数 $U: (v_1, v_2) \rightarrow f(x)$ 产生输入输出数据。通过运行该算法 400 代, 所给出的最优解为

$$(x_1^*, x_2^*, x_3^*) = (0.6123, 0.6130, 0.2315),$$

对应事件的可能性为 $f(x^*)=0.9133$ 。只用遗传算法进行解优化所取得的最优解为 $(x_1^*, x_2^*, x_3^*)=(0.6016, 0.6020, 0.2575)$ ，对应事件的可能性为 $f(x^*)=0.8209$ 。

通过三个模糊规划模型的数值对比试验，可以看出，其中引入了进化策略的 (μ, λ) 选择算子后，算法跳出局部最优的几率大大增加了，而在算子的变异过程中采用的模拟退火的思想，精英保留策略能够保证算法收敛到全局最优。通过这几种算法相互借鉴，融合了改进的混合智能算法和支持向量机的新算法较之原算法在目标函数的优化结果上有明显的改善。

5.7 本章小结

利用混合智能算法如进化算法、人工神经网络等来解决模糊规划问题是当前处理不确定优化问题的一个趋势。支持向量机是一种新型的知识发现方法，在解决小样本、非线性及高维模式识别中表现出了许多特有的优越性，因此本章提出将支持向量机与改进的混合智能算法相结合，用于处理模糊规划问题。实验证明新算法比传统的智能算法具有更高的求解精度。由此为不确定优化提供了一种新的处理方式。

结论

本文研究总结

本文主要研究了混合智能算法和模糊规划的优化算法以及混合智能算法在模糊规划问题中的应用，其中混合智能算法主要研究了两个具有代表性的进化算法：遗传算法和进化策略以及支持向量机。主要工作有以下几个方面：

(1)综述了进化算法中两个典型算法，遗传算法和进化策略，介绍了算法的国内外发展现状，并深入研究了两种算法的原理和应用技术，提出了改进的方向。

(2)通过对各种算法算子的研究，提出利用遗传算法，进化策略的改进算子，并融入另一个智能算法，模拟退火算法的思想，形成一种新的改进的混合智能算法，用于处理函数的解优化，实验证明新的算法在提高最优解精度和寻优速度上有一定的突破。

(3)探讨了模糊规划原理和现有的模糊规划分类，包括期望值模型、机会约束规划模型、相关机会规划模型。并对其传统的模型算法作了研究。作为下一步将混合智能算法应用于模糊规划的基础。

(4)在以往模糊规划算法研究的基础上，探讨了支持向量机的的理论基础和应用技术。提出将新生成的混合智能算法与支持向量机相融合来解决模糊规划问题，提高了原有算法的寻优率，并与传统的算法作了比较分析。

主要创新点

本文在理论及实践上的创新之处主要有：

(1)分析了几种智能算法的原理和优缺点，将遗传算法、进化策略改进算子和模拟退火算法思想有机的结合在一起，形成一种新的混合智能算法，与传统算法相比，新的混合智能算法更容易跳出局部最优解，在求解精度与速度上优于传统算法。

(2)在深入研究了模糊规划原理和相关解决算法后，提出将新生成的混合智能算法与支持向量机相结合用于解决模糊规划问题。作为解决模糊规划问题的新方法，改进后的算法较之传统的算法，在规划问题的求解中，显示了一定的优势。

进一步的工作

(1)关于进化算法:

进化理论技术蓬勃发展的同时也暴露出一些亟待解决的问题。算法的收敛性将严重影响控制系统的稳定性,尤其对于实时控制,可能使整个系统陷入恶性循环完全失去控制。即便算法在实质上隐含高度并行性,当种群规模庞大及搜索空间广阔时,算法的收敛速度及搜索效率便成为突出问题,所以进化计算应该同智能控制的其他技术有效结合。在过渡过程初期,为加快响应速度,以传统方法为主,过渡过程中期便可采用进化计算辨识控制系统模型以及优化控制器参数,而为避免控制器参数的剧烈改变所引起的干扰影响,可以在过渡过程后期全面恢复到传统控制状态,以利于整个系统平稳地达到目标状态。随着应用领域的拓展,进化算法的研究呈现出几个引人注目的发展动向:一个GA与TS、SA、NN等智能计算方法相互渗透和日益结合。这是21世纪新的智能计算技术发展的一个主导方向。二是GA和EP、ES等进化算法日趋结合。三是进化算法的并行处理研究将十分活跃。四是进化算法将渗透到许多崭新的研究领域,如人工生命等。在未来的混合智能系统中,进化算法的地位是毋庸置疑的。进化算法的发展前景广阔而迷人。

(2)关于不确定规划:

不确定规划模型的扩充:目前已有三大类不确定规划一期望值模型,机会约束规划和相关机会规划。从理论上说,还应有其它类型的不确定规划。

不确定规划模型的数学性质:如灵敏度分析,上下界的估计,对偶定理,最优性条件及各种确定或清晰的等价类等。

模型的计算问题:我们已尝试过基于随机/模糊模拟的遗传算法,但它目前只能适用于小规模的问题,所以有必要作进一步的改善以适应更大规模的问题。此外,我们还可以根据模型的数学性质,设计一些特殊的传统算法,并考虑应用新的智能算法以及并行算法等。

不确定规划的进一步的应用:例如考虑在模式识别、排队系统、环境保护、质量控制、风险分析等领域的应用。

参考文献

- [1] 刘宝碇,赵瑞清,王纲,等.不确定规划及应用[M].北京:清华大学出版社,2008.
- [2] 云庆夏.进化算法[M].北京:冶金工业出版社,2000.
- [3] Thomas Back, Fogey D.B., Zbigniew Michalewicz, Evolutionary Computation Basic Algorithms and Operators[M].Bristol and Philadelphia: Institute of Physics Publishing, 2000.
- [4] Rechenberg, L, Cybernetic Solution Path of an Experimental Problem[M].Royal Aircraft Establishment Library Translation 1965,11-22.
- [5] Schwefel,H-P, Kybernetische Evolution als Strategie der experimentllen Forschung in der Stromungstechnik Dipl.-Ing[A].Technical University Berlin, 1965.
- [6] Bienert, P.aufsbu einer Optimierungsautomatik for drei parameter Dipl.-Ing[A]. Technical University Berlin, 1967.
- [7] Rechenberg, L, Evolutionsstrategie:Optimierung trchnischer Systeme nach Prinzipien der biologischen Evolution.Stuttgart[M]. Frommann-Holzboog,1973.
- [8] Schwefel, H-P, Numerical Optimization of Computer Models[M], Chichester: Wiley, 1981.
- [9] 王云诚.唐焕文单峰函数最优化问题的进化策略[J],计算数学,2000.
- [10] 徐宗本,李国,解全局优化问题的仿生类算法(I)—模拟进化算法[J],运筹学杂志, 1995,14(2):1-13.
- [11] 欧阳柳波.李学勇.吴克寿基于进化策略的抽题算法设计[J].计算技术与自动化,2004.3.
- [12] 王战权.赵朝义.云庆夏进化策略中基于柯西分布的变异算子改进探讨[J].系统工程 1999.7.
- [13] Kursawe, F. Towards self-adapting evolution strategies[A]. Evolutionary Computati on 1995 IEEE Intenraitonal Conference[C].1995:283-288.
- [14] L. Gruenz, H.G Beyer. Some observations on the interaction of recombination and self-a daptation inevoluiton strategies[A]. Evolutionary Computation,1999. CEC'99. Proceedings of the 1999 Congress[C],1999:6-9.
- [15] Back,T. Eiben, A.E. Generalizations of intermediate recombination in evolutions strategies[A]. Evolutionary Computation,1999. CEC'99. Proceedings of the 1999

Congress[C].1999:1566-1573.

[16] Ming Chang, Ohkura. K, Ueda. K, Some experimental observations of $(\mu/\mu, \lambda)$ -evolution strategies[A]. Evolutionary Computation, 2001.Proceedings of the 2001 Congress[C], 2001:663-670.

[17] Y. Matsumura, K. Ohkura, K.Ueda. Advantages of global discrete combination in $(\mu/\mu, \lambda)$ -evolutions strategies[A]. Evolutionary Computation, 2002.CEC'02. Proceedings of the 2002 Congress[C].2002:1848-1853.

[18] D. Goldberg. Genetic algorithms in search, optimization, and machine learning[M]. Addison Wesley, MA, 1989.

[19] J.H. Holland. Hidden order: How adaptation builds complexity[M]. Addison Wesley, MA, 1995.

[20] H. G. Beyer. Toward a theory of evolution strategies: on the benefits of sex-the $(\mu/\mu, \lambda)$ theory[J]. Evolutionary computation, 1995, 5(3):218-235.

[21] H.G. Beyer. An alternative explanation for the manner in which genetic algorithms operates[J]. Bio System, 1997, 41(8):115.

[22] C. A. Magele, K. Preis, W. Renhart, etc. Higher order evolution strategies for the global optimization of elector magnetic devices. IEEE Trans. On Magnetics, 1993, 29(2):1775-1778.

[23] C .Kappeler."Are evolutionary algorithms improved by large mutation?"[A]. Parallel Problem Solving from Nature(PPSN)IV (H.M Voigt, W Ebeling, I.Rochenberg, and H. P. Schwefels. Vol.114) of Lecture Notes in Computer Science[C], Berlin, Springer-Verlag, 1996:346-355.

[24] X. Yao and Y. Liu." Fast evolution strategies"[A]. Proc.4th, IEEE conf on Evolutionary Programming VI, P. J Ange line, R. Reynolds, J. Mc Donnell, and R. Eberthart, eds. Berlin, Germany Springer-Verlag.[C]1997:151-161.

[25] 林丹,李敏强,寇纪淞.进化规划和进化策略中变异算子的若干研究[J].天津大学学报,2000,33(5):627-630.

[26] 王云诚,唐焕文.单峰函数最优化问题的一个快速收敛进化策略[J].小型微型计算机系统,2002, 23(11):1390-1392.

[27] 刘若辰,杜海峰,焦李成.基于柯西变异的免疫单克隆策略[J].西安电子科技大学学报,2004,31(4):551-556.

- [28] 王战权,赵朝义.进化策略中变异算子的改进研究[J].计算机仿真,1999,16(3):8-11.
- [29] 王战权,赵朝义,夏云庆.进化策略中基于柯西分布的变异算子改进探讨[J].系统工程,1999,17(4):49-54.
- [30] Hashem, M.M.A, Watanabe, M. Izumi, K. Evolution strategy a new time-variant mutation for fine local tuning SICE '97[A]. Proceedings of the 36th SICE Annual Conference. In ternational Session Papers[C],1997:1099-1100.
- [31] Sang Hwan Lee, Hyo Byung Jun, Kwee Bo Sim. Performance improvement of evolution strategies using reinforcement learning[A]. Fuzzy Systems Conference Proceedings, 1999[C]. IEEE'99. 1999 IEEE Intenrational,1999:22-25.
- [32] S. D. Muller, N.N. Schraudlph, P. D. Koumoutsakos. Step size adaptation in evolution strategies using reinforcement learning[A]. Evolutionary Computation,2002. CEC'02. Proceedings of the 2002 Congress[C], 2002:151-156.
- [33] L. Hildebrand; B. Reusch, Fathi, M, Directed mutation-a new self-adaptation for evolution strategies[A]. Evolutionary Computation,1999. CEC 99.Proceedings of the 1999 Congress[C], 1999:1550-1557.
- [34] Q. Zhou and Yanda Li. Directed variation in evolutions strategies[J]. IEEE trans On Evolutionary computation,2003,7(4):356-366.
- [35] Yu Yongquan; Huang Ying; Zeng Bi; Chen Xianchu; Learning fuzzy model for nonlinear system using evolutions strategies with adaptive direction mutation[A]. Fuzzy Systems,2003.FUZZ '03[C].The 12th IEEE Intenrational Conference, 2003:237~241.
- [36] Yong Liang, Kwong Sak Leung. Two-way mutation evolution strategies[A]. CEC'02. Proceedings of the 2002 Congress on Evolutionary Computation[C],2002:789-794.
- [37] N.Hansen, A.Gawelczyk; A.Ostermeier. Sizing the population with respect to the local progress in(1, λ)-evolution strategies-atheoretical analysis[A]. Evolutionary Computation,1995, IEEE Intenrational Confeernce[C],1995:80-85.
- [38] Tao Yuan Huang; Yung Yaw Chen. Parental population sizing in evolutionary strategies[A]. Evolutionary Computation,2001.Proceedings of the 2001 Congress[C], 2001:1351-1358.
- [39] L.Schonemann. The impact of population sizes and diversity on the adaptability of evolution strategies in dynamic environments[A]. Evolutionary Computation, CEC 200

4 Congress[C], 2004:1270-1277.

[40] 王正志,薄涛著.进化计算[M].长沙:国防科技大学出版社,2000.

[41] 郭观七.进化计算的遗传漂移分析与抑制技术[D].长沙:中南大学,2003.

[42] K. Izumi, M. Hashem, M.A.Watanabe. A nevolutions strategy with competing subp opulations[A].Computational Intelligence in Robotics and Automation[C],1997:306-311.

[43] B. Porter, F. Xue. Niche evolution strategy for global optimization[A]. Evolutionar y Computation, Proceedings of the 2001 Congress[C], 2001:1086-1092.

[44] H. Fuger, G. Stein, U. Stilla. Multi-population evolution strategies for structural image analysis[A]. Evolutionary Computation, 1994.IEEE World Congress on Computational Intelligence, Proceedings of the First IEEE Conference[C],1994:229-234.

[45] C.H. Kim, H.K. Jung, K.C.Choi. An algorithm formulti modal functionopt imization based on evolutions strategy[M]. IEEE Trans. On magnetics.2004,40(2):1224-1227.

[46] O. Frangois. An evolutionary strategy for global minimization and its Markov chain analysis[M]. IEEE Trans, on evolutionary computation, 1998, 2(3):7790.

[47] Jianbo Cai, G.Thierauf. Evolution strategies for solving discrete optimization problems[J]. Advances in engineering software, 1996:177-183.

[48] C. Ebenau, J. Rottschaefer, G.Thierauf. An advanced evolutionary strategy with an adapitve penalty functon for mixed-discrete structural optimization[J]. Advances in engineering software.2005,36(1):29-38.

[49] L. Costa, P. Oliveira. An evolution strategy for multiobjecitve optimization[A]. Evolutionary Computation,2002.CEC'02.Proceedings of the 2002 Congerss[C], 2002:97-102.

[50] S.M. Yang, D.G Shao, Y.J.Luo. A novel evolution strategy for multiobjecitve optimization problem[J]. Applied mathematics and computation.2005.

[51] Z. Michalewicz, D. Dasgupta, R.G Le and M.Schoenauner. Evolutionary algorithms for constrained engineering problems[J]. Computer Ind. Engng.1996,30(4):851-870.

[52] E.M.Montes and C.A.C.Coello. A simple multi-membered evolution strategy to sol ve constrained optimizaiton problems[J]. IEEE Trans. On Evolutionary computation.200 5,9(1):1-17.

[53] D.V.Arnold and H.G.Beyer. Investigation of the(μ,λ)-ES in the presence of noise[A]. Evolutionary Computation,2001.Proceedings of the 2001 Congress[C], 2001:332-339.

- [54] R.Berlich, M.Kunze. Parallel evolutionary algorithms[J]. Nuclear instruments & methods in physics research. 2003,50(2):467-470.
- [55] Guo Guanqi and Yu Shouyi. Evolutionary parallel local search for function optimization[J]. IEEE traps. On System, man, cybernetics-Part B,2003,33(6):864-876.
- [56] V.Rupela, G.Dozier. Parallel and distributed evolutionary computations for multimodal function optimization[A]. World Automation Congress, 2002. Proceedings of the 5th Biannual[C], 2002:307-312.
- [57] Bialas W F and Karwan M H. Two-level linear programming[J]. Management Science, 1984, 30:1004-1020.
- [58] Biswal M P. Fuzzy programming technique to solve multi-objective geometric programming problems[J]. Fuzzy Sets and Systems, 1992, 51(7):61-71.
- [59] Bit A K, Biswal M P and Alam S S. Fuzzy programming approach to multicriteria decision making transportation problem[J]. Fuzzy Sets and Systems, 1992, 50(5):135-141.
- [60] Bitran G R. Linear multiple objective problems with interval coefficients[J]. Management Science, 1980, 26(2):694-706.
- [61] Bortolan G. An architecture of fuzzy neural networks for linguistic processing[J]. Fuzzy Sets and Systems, 1998, 100(12):197-215.
- [62] Bouchon-Meunier B, Kreinovich V, Lokshin Aetal. On the formulation of optimization under elastic constraints[J]. Fuzzy Sets and Systems, 1996, 81[2]:5-29.
- [63] Buckley J J. Possibility and necessity in optimization[J]. Fuzzy Sets and Systems, 1988, 25(1):1-13.
- [64] Buckley J J. Stochastic versus possibilistic programming. Fuzzy Sets and Systems [J],1990, 34(2):173-177.
- [65] Liu B. Toward fuzzy optimization without mathematical ambiguity[J]. Fuzzy Optimization and Decision Marking, 2002, 1(1):43-63.
- [66] Liu B. Theory and Practice of Uncertain Programming[M]. Heidelberg: PhysicaVerlag,2002.
- [67] Liu B. Uncertainty Theory: Toward Axiomatic Foundations. Lecture Note, Tsinghua University,2003.
- [68] Liu B, Iwamura K. A note on chance constrained programming with fuzzy

coefficients[M]. To appear in Fuzzy Sets and Systems.

[69] 一种快速自适应遗传算法及其仿真研究[J]. 沐阿华,周绍磊,于晓丽.系统仿真学报, 2004,16(4): 122-123.

[70] 浅析遗传算法与进化策略[J]. 冯萍等.长春大学学报, 2005, 15(2): 26.

[71] Charnes AWW. Coper. Chance-constrained programming[J]. Management Science, 1959,1(6):73-79.

[72] Liu B. Dependent-chance programming: Aclass of stochastic programming[J]. Computers & Mathematics with Applications,1997,12(34):89-104.

[73] Liu B. Uncertain Programming[M]. John Wiley & Sons. York 1999.

[74] Bouchon-Meunier BV. KreinovichA. Lokshin, H. T. Nguyen. On the formulation of optimization under leastic constraints (with control in mind)[J]. Fuzzy Sets and Sysems,1996,81(10):5-29.

[75] Buckley JJY. Hayashi. Fuzzy genetic algorithm and applications[J]. Fuzzy Seys and Systems. 1994,32(61):129-136.

[76] Liu B. Dependent-chance programming with fuzzy decisions[J]. IEEE Transactions on Fuzzy Systems, 1999. 3(7):354-360.

[77] 刘宝锭,赵瑞清.随机规划与模糊规划[M].北京:清华大学出版社,1988.

[78] Vapnik V N. The Nature of Statistical Learning Theory[M], Springer, Berlin,1995.

[79] Vapnik V N. An overview of Statistical Learning theory[J]. IEEE Trans. Neural Networks, 1999, 10(5):988-999.

[80] M.Anthony, P.Bartlett. Learning in Neural Networks: Theoretical Foundations[M]. Cambridge University Press,1999.

[81] J.Shawe-Taylor, N.Cristianini. Margin Distribution and Soft Margin[M]. In A.Smol a, P.Bartlett, B.Scholkopf, and D.Schuermans, editors, Advances in Large Margin Classifiers, MIT Press, Cambridge, MA,2000:349-358.

[82] J.Weston. Leave-One-Out Support Vector Machines[A]. IJCAI[C]1999:727-733.

[83] A.Smola, B.Scholkopf, K.R.Muller. Convex Cost Functions for Support Vector Regression[A]. In L.Niklasson, M.Bodtn, and T.Ziemke, editors, Proceedings of Eighth International Conference on Artificial Neural Networks[C], Perspectives in Neural Computing, Berlin, Springer-Verlag,1998.

攻读硕士学位期间取得的学术成果

- [1] PeiZhenkui, HuaXia, LiuJian. Improvement of Hybrid Intelligent Algorithm and Application in Fuzzy Programming[A]. ISICA 2008[C].China University of Geosciences, 2008.

致谢

感谢导师裴振奎副教授三年来对我的培养，让我得以完成硕士论文的全部工作。三年里，裴振奎老师在学术研究上给予了我很大的帮助和鼓励，裴振奎老师严谨的工作作风和实事求是的学术精神，将在今后的工作学习中时时激励我，使我受益一生。

感谢计算机与通信工程学院，为我提供了一个可以深入学习的机会，以及学院所有老师，感谢他们对我的传道授业解惑。

感谢同门刘健同学对我在学习和生活上的无私帮助，三年来共同的交流和讨论使我们在学术研究上一起进步，收获成绩。

感谢所有的朋友，是你们一直陪伴在我身边，给我精神的鼓励和关怀，你们是我继续下去的动力。

特别感谢我的父母和亲人，感谢你们的爱和支持。请接受我最真挚的祝福。

谨以此文献给所有关心和帮助过我的老师、同学和朋友！